

GENMO: A GENERALIST Model for Human MOTion

详细方法讲解、框架拆解与全文中文翻译

论文: Jiefeng Li, Jinkun Cao, Haotian Zhang, Davis Rempe, Jan Kautz, Umar Iqbal, Ye Yuan,
NVIDIA, ICCV 2025.

本文档分为两部分: 第一部分从问题定义、运动表示、条件融合、GENMO 模块、可变长推理和双模式训练等角度, 对方法和框架进行逐层讲解; 第二部分按照原论文结构给出完整中文翻译, 并保留公式、图表和实验数据。

GENMO: A GENERALIST Model for Human MOTion

Jiefeng Li Jinkun Cao Haotian Zhang Davis Rempe Jan Kautz Umar Iqbal Ye Yuan
NVIDIA

<https://research.nvidia.com/labs/dair/genmo>




图1 (原论文): GENMO 统一人体动作估计与生成, 并支持视频、2D关键点、文本、音乐与3D关键帧等条件。

目录

第一部分 方法与框架详细讲解

1. 论文要解决的核心问题
2. 统一建模：把“估计”改写成受约束的“生成”
3. 输入、条件与条件掩码
4. 联合局部-全局运动表示
5. GENMO 总体网络框架
6. Multi-Text Injection 与多文本注意力
7. 可变长度与混合多模态条件
8. 双模式训练范式
9. 估计引导的 2D 数据生成训练
10. 不同数据/条件如何选择训练模式
11. Music-to-Dance 路径单独拆解
12. 实验结果与消融结论
13. 方法的优点、边界与关键理解

第二部分 论文全文中文翻译

参考文献（书目信息保留，标题译为中文）

第一部分 方法与框架详细讲解

1. 论文要解决的核心问题

传统人体动作研究通常把“动作生成（generation）”和“动作估计（estimation）”分成两套模型。生成任务关心的是：给定文本、音乐、关键帧等较抽象条件，产生多样且合理的动作；估计任务关心的是：给定视频、2D 骨架等观测，尽可能精确地恢复真实动作。两者虽然都在学习人体时序动力学与运动学结构，但训练目标不同，长期被割裂处理。

GENMO 的核心目标是把这两类任务统一到一个条件扩散模型中。作者的关键判断是：动作估计本质上也可以看成一种“受观测条件严格约束的动作生成”。一旦做出这个重写，视频、2D 关键点、文本、音乐、3D 关键帧等都可以被视为条件信号，只是它们对输出分布的约束强弱不同。

- 视频 / 2D 关键点属于强条件：给定观测后，正确动作的自由度较低，输出更接近确定性估计。
- 文本 / 音乐属于抽象条件：同一句文本或同一段音乐可以对应许多合理动作，需要保持生成多样性。
- GENMO 用同一个扩散去噪器同时承担这两类任务，但训练时采用不同模式，使模型既能“准”又能“多样”。

2. 统一建模：把“估计”改写成受约束的“生成”

设需要生成或估计的动作序列为 x ，长度为 N 。模型接收条件集合 C 以及对应的条件掩码 M ，输出完整动作序列。统一后的问题可以写成：

$$x_0 = G(x_t, t, C, M)$$

其中 x_t 是扩散过程某一时刻的带噪动作； t 是扩散时间步； C 可以同时包含视频特征、相机运动、2D 骨架、音乐、边界框和文本； M 指示这些条件在哪些帧上有效。

这种统一形式非常重要：网络不需要为 video-to-motion、text-to-motion、music-to-dance 分别设计独立生成头，而是把所有任务归一为“在条件约束下恢复干净动作 x_0 ”。任务差异主要体现在条件信号和训练模式，而不是网络主体。

3. 输入、条件与条件掩码

论文把条件分成两类。第一类是与动作帧天然对齐的逐帧条件，例如视频特征、相机运动、2D 骨架、音乐和 2D 边界框；第二类是没有天然帧级对齐关系的文本。

条件类型	符号	时间结构	进入网络的主要方式
视频特征	$c_{\text{video}} \in \mathbb{R}^{N \times d_{\text{video}}}$	逐帧对齐	MLP 编码 + 时间掩码 + 加法融合
相机运动	$c_{\text{cam}} \in \mathbb{R}^{N \times d_{\text{cam}}}$	逐帧对齐	MLP 编码 + 时间掩码 + 加法融合
2D 骨架	$c_{2d} \in \mathbb{R}^{N \times d_{2d}}$	逐帧对齐	MLP 编码 + 时间掩码 + 加法融合
音乐	$c_{\text{music}} \in \mathbb{R}^{N \times d_{\text{music}}}$	逐帧对齐	MLP 编码 + 时间掩码 + 加法融合
2D 边界框	$c_{\text{bbox}} \in \mathbb{R}^{N \times d_{\text{bbox}}}$	逐帧对齐	MLP 编码 + 时间掩码 + 加法融合

条件类型	符号	时间结构	进入网络的主要方式
			合
文本	$c_{\text{text}} \in \mathbb{R}^{M \times d_{\text{text}}}$	token 级、非帧对齐	Multi-Text Injection / Masked MHA

对于每种逐帧条件 c_* ，GENMO 定义同尺寸的条件掩码 m_* 。条件存在时掩码为 1，缺失时为 0；条件特征先乘掩码，将缺失位置置零，再参加融合。这样同一条序列可以在不同时间段由不同模态控制，例如前 10 秒跟随视频、中间 10 秒跟随文本、后 10 秒跟随音乐。

4. 联合局部-全局运动表示

要让同一个模型同时完成“生成”和“估计”，动作表示必须兼顾两类任务。纯文本动作生成常使用以人体自身朝向为基准的局部表示，因为它与相机无关、适合建模动作模式；视频估计则更喜欢相机坐标或世界坐标，因为这样和图像观测容易对齐。GENMO 因此采用联合局部-全局表示。

论文基于 Gravity-View（重力-视角）坐标体系表达全局轨迹。第 i 帧动作由以下部分组成：

- $\Gamma_{\text{gv}}^i \in \mathbb{R}^6$ ：人体在 gravity-view 坐标中的全局朝向（6D 旋转表示）。
- $v_{\text{root}}^i \in \mathbb{R}^3$ ：根节点局部速度，用于描述全局平移轨迹。
- θ^i ：SMPL 关节旋转，论文用 6D 旋转表示。
- $\beta^i \in \mathbb{R}^{10}$ ：SMPL 人体形状参数。
- $t_{\text{root}}^i \in \mathbb{R}^3$ ：根节点平移。
- $\pi^i = (\Gamma_{\text{cv}}^i, t_{\text{cv}}^i)$ ：相机到世界的姿态，其中包含 6D 相机朝向和 3D 相机平移。
- $p^i \in \mathbb{R}^6$ ：手和脚（脚跟、脚尖）的接触标签。

$$x^i = (\Gamma_{\text{gv}}^i, v_{\text{root}}^i, \theta^i, \beta^i, t_{\text{root}}^i, \pi^i, p^i) \quad (1)$$

这种表示的意义在于：局部姿态负责“动作长什么样”，gravity-view 轨迹负责“人在世界中怎么移动”，相机姿态负责“这个动作在视频里如何被观察”，接触标签则给脚滑、手脚静止等几何约束提供监督。

注意：论文主文把表示写成概念性组合形式，没有在这一页给出一个统一的数值总维数 D 。不要把式 (1) 直接等同于某个代码版本中的固定特征维数；实现细节属于代码/补充材料层面。

5. GENMO 总体网络框架




Figure 2. **GENMO Model Design** supports the generation of variable-length motion sequences in a single pass and enables seamless integration of multimodal conditioning signals.

图2（原论文）：GENMO 模型设计。下方是带噪动作和逐帧条件的加法融合，中间为逐帧动作 token，上方堆叠 L 个 GENMO Module，最终输出干净动作。

整个框架可以分成四层：条件编码与掩码、Additive Fusion、L 个 GENMO Module、动作输出头。

第一层：条件编码。每种逐帧条件都使用独立的 MLP 投影到相同隐空间。条件先乘掩码，因此不存在的模态不会给网络注入错误信号。

第二层：Additive Fusion。所有有效逐帧条件的隐特征直接求和，再与带噪动作 x_t 的 MLP 表征融合，得到每一帧的 motion token。其思想不是把所有模态在通道维上无限拼接，而是先映射到同一 latent space，再做加性汇聚，使网络能够自然接受任意子集的条件。

$$f_{\text{cond}}(i) = \sum_{c \in C_{\text{frame}}} \text{MLP}_c(c(i) \odot m_c(i))$$

$$f_{\text{motion}}(i) = \text{Fuse}(\text{MLP}_x(x_t(i)), f_{\text{cond}}(i))$$

第三层：GENMO Module。每个模块由 Multi-Text Injection Block 和 RoPE-based Transformer 构成，并重复 L 次。文本先通过专门的跨注意力机制注入；随后 RoPE Transformer 在动作时间轴上建模长程时序关系。

第四层：网络输出。经过 L 个模块后，输出与动作时间轴等长的干净动作 x_0 。扩散训练时它学习直接预测 clean motion，而推理时通过 DDIM 等去噪过程逐步得到动作。

为什么采用 RoPE？绝对位置编码通常与训练最大长度绑定；RoPE 在注意力中编码相对位置关系，使模型更适合长度变化，并为后面的滑动窗口注意力提供自然基础。

6. Multi-Text Injection 与多文本注意力




Figure 3. **Multi-text attention** enables flexible conditioning with multiple text inputs, each constrained to its specified time window.

图3（原论文）：Multi-Text Attention。每个文本提示只在用户指定的动作时间窗口内对相应帧产生跨注意力影响。

文本和音乐最大的不同是：音乐是逐帧对齐条件，而文本是 token 序列，没有天然的“第 7 个词对应第 103 帧”关系。如果把文本 token 直接拼到动作序列某个位置，会人为引入时间偏置。GENMO 因此把文本当作独立条件序列，通过跨注意力注入。

当用户给出 K 个文本提示，并为每个提示指定一个时间窗口时，GENMO 为每个文本建立二值窗口掩码 Ω_k 。动作特征作为 Query，文本特征作为 Key/Value，只有动作时间步落在该文本的窗口内时，对应注意力才有效。

$$f_{out} = \sum_{k=1}^K \text{MaskedMHA}(f_{in}, c_{text}^k, \Omega_k) \quad (2)$$

$$\Omega_k(i,j)=1 \text{ (若动作时间步 } i \text{ 位于文本 } k \text{ 的时间窗口内)}, \text{ 否则为 } 0 \quad (3)$$

窗口边界本身会带来离散切换，但后续 RoPE Transformer 会继续在动作时间轴上做时序建模，因此最终动作可以在不同文本指令之间产生平滑过渡。

7. 可变长度与混合多模态条件

GENMO 宣称能够在一次扩散推理中生成任意长度动作。关键不是“模型从来没有长度上限”，而是其时间建模使用相对位置机制，并在推理阶段采用滑动窗口注意力：每个动作 token 只关注 W 帧邻域内的 token。这样序列可以比训练时更长，而单个 token 的计算量仍受 W 控制。

对于混合模态，策略非常清晰：文本走 Multi-Text Attention；视频、音乐、2D 骨架等逐帧条件走时间掩码和 Additive Fusion。这个分工避免把所有模态强行统一成同一种时间结构。

8. 双模式训练范式




Figure 4. **Variance of video/text conditioned predictions.** Left: Intermediate predictions across 50 DDIM denoising steps. Right: Predictions with 10 different initial noises (including zero-noise).

图 4（原论文）：视频条件的动作估计比文本条件的动作生成更确定。作者据此提出“估计模式 + 生成模式”的双模式训练。

如果只使用标准 DDPM 生成损失，理论上视频条件也可以通过扩散得到动作，但作者发现这样不够精确。原因是视频估计和文本生成的输出分布方差不同：视频把动作约束得很强，正确答案接近单峰；文本条件则天然对应多种合理动作。

作者通过图 4 观察到：视频条件下，不同扩散时间步和不同初始噪声得到的动作差异很小，模型表现得近似确定性；文本条件下，预测差异显著更大。于是他们让同一个扩散网络以两种训练模式工作。

8.1 生成模式（Generation Mode）

生成模式就是标准扩散训练。先从干净动作 x_0 前向加噪得到 x_t ，随机采样时间步 t ，再让网络从 x_t 和条件中预测 x_0 ：

$$L_{\text{gen}} = E_{\{t, x_{t_0} \sim q(x_{t_0}|x_0)\}} [\| x_{t_0} - G(x_{t_0}, t, C, M) \|^2] \quad (4)$$

该模式保留从抽象条件生成多样动作的能力，因此文本和音乐训练只使用生成模式。

8.2 估计模式 (Estimation Mode)

估计模式把问题当成回归/MLE。论文主文公式使用纯高斯噪声 z 和最大扩散步 T ，让网络在“最难的噪声状态”下一步直接恢复条件所确定的动作：

$$L_{\text{est}} = E_{\{z \sim N(0, I)\}} [\| x_0 - G(z, T, C, M) \|^2] \quad (5)$$

直观上，生成模式要求网络学会整个去噪过程的分布；估计模式额外强化“第一步就根据强条件给出接近正确答案”的能力。这对于视频/2D 骨架等低方差任务特别重要。

8.3 几何正则 L_{geo}

仅在运动特征空间做 MSE 并不足以保证几何正确，因此作者把预测动作解码成 SMPL 关节和顶点，并在世界坐标和相机坐标中加入顶点位置、关节位置与接触约束；若只有 2D 标注，还使用 2D 重投影损失。这些几何损失把“特征误差”约束为“真实人体几何误差”。

9. 估计引导的 2D 数据生成训练

GENMO 的另一个关键贡献是：即使某些互联网视频只有 2D 关键点而没有可靠 3D 动作，也能用来增强生成模型。作者利用模型自身的估计能力构造伪 3D，再用 2D 重投影进行约束。

1. 用视频或 2D 骨架作为强条件，在估计模式下得到伪干净动作 $\hat{x}_0 = G(z, T, C)$ 。
2. 对 $\hat{x}_0$ 再做前向扩散，采样带噪动作 $\hat{x}_t$ 。
3. 让模型在生成模式下预测动作，并把预测动作投影到 2D。
4. 使用真实 2D 关键点监督投影结果，从而把大量只有 2D 标注的野外视频用于扩散生成训练。

$$L_{\text{gen-2D}} = E [\| x_{2d} - \Pi(G(\hat{x}_t, t, C)) \|^2] \quad (6)$$

这一步体现了“估计与生成互相帮助”：估计模式先把 2D 数据提升为伪 3D 先验，生成模式再从丰富的互联网动作分布中获益。

10. 不同数据 / 条件如何选择训练模式

条件/数据特征	输出分布特点	训练模式
视频、2D 骨架等强观测条件	低方差、接近确定性	估计模式 + 生成模式
文本、音乐等抽象条件	高方差、多解	仅生成模式
有干净 3D 标注	可直接监督动作	标准扩散生成损失 + 几何损失
只有 2D 标注	无真实 3D	估计引导伪 3D + 2D 重投影

因此，论文中的“统一模型”不是说所有样本都用同一种 loss，而是说同一个网络共享参数，通过样本级 loss mask 选择当前样本应该激活哪些目标。

11. Music-to-Dance 路径单独拆解

如果只关心音乐生成舞蹈，GENMO 主框架可以被理解为一个更简单的子路径。音乐属于逐帧对齐的抽象条件，论文明确规定它只使用 generation mode。

- 输入：音乐特征序列 `c_music`，与目标动作帧时间对齐。
- 条件掩码：`m_music` 指示哪些帧有音乐条件。
- 条件编码：音乐特征通过专属 MLP 投影到 motion latent dimension。
- 融合：音乐隐特征与带噪动作 token 做加法融合。
- 时序建模：RoPE Transformer 在动作时间轴上学习音乐节奏、动作节奏和长时结构。
- 训练：只走标准扩散 generation objective，不需要 estimation mode。
- 推理：从噪声开始，根据整段音乐条件通过 DDIM 等采样得到完整动作。

主论文没有在正文给出 `d_music` 的具体数值、音频采样率、MFCC/节拍特征细节等，因此这些不能仅从论文主文确定；若要复现音乐特征提取，应查官方代码或补充材料。

12. 实验结果与消融结论

音乐生成方面，AIST++上的结果很有代表性。Music-only 专用模型取得最低 FID，但统一 GENMO 在多样性、物理合理性和音乐-动作相关性指标上更好：

方法	FIDk ↓	FIDm ↓	Divk ↑	Divm ↑	PFC ↓	BAS ↑
FACT	86.43	43.46	6.85	3.32	2.2543	0.1607
Bailando	28.16	9.62	7.83	6.34	1.754	0.2332
EDGE	42.16	22.12	3.96	4.61	1.5363	0.2334
GCDance	36.81	20.10	6.44	6.47	-	0.2346
GENMO (music only)	16.10	13.91	8.47	7.26	0.7340	0.2282
GENMO (generalist)	40.91	18.51	10.09	7.48	0.3702	0.2708

解释：generalist 版本因为训练数据更异构，FID 不如专用 music-only，但其动作多样性和音乐节拍相关性更强；这说明多任务数据会扩展动作先验，却可能牺牲与单一评测分布的贴合程度。

消融方面，Diffusion-only 和 Regression-only 都不如双模式。说明生成先验能够帮助估计，而估计模式又能增强扩散模型在强条件下的准确性。不同 DDIM 步数的实验还显示：视频估计对步数不敏感，单步就能得到较一致结果；文本生成对步数更敏感，体现了两类任务方差的本质差异。

13. 方法的优点、边界与关键理解

GENMO 真正的创新点不是“用了 Transformer + diffusion”本身，而是三个层面的统一：任务统一、条件统一、训练统一。任务统一是把估计写成受约束生成；条件统一是逐帧模态用 mask+加法融合、文本用时间窗口跨注意力；训练统一是同一个模型在样本级选择 estimation / generation loss。

- 优点 1：单模型覆盖视频估计、音乐生成、文本生成和关键帧插值，参数共享带来跨任务知识迁移。
- 优点 2：条件可以在时间轴上混合，适合复杂编辑与长序列控制。

- 优点 3: RoPE + sliding-window attention 降低了长度扩展对绝对位置编码的依赖。
- 优点 4: 2D-only 野外视频可以通过估计引导训练反哺生成, 减少对干净 3D mocap 的依赖。
- 边界 1: 不同动作表示之间的转换会产生分布偏移, 论文自己在 HumanML3D 实验中明确讨论了这一问题。
- 边界 2: 论文的 “arbitrary length” 依赖滑动窗口注意力和训练外泛化, 不能理解为无限长度绝无误差积累。
- 边界 3: music-only 场景只使用生成模式, 因此双模式训练的优势主要来自 generalist 共享, 而不是音乐数据本身直接用回归模式。

一句话总结框架: GENMO 把所有任务都写成 “条件扩散恢复动作”, 逐帧条件经 MLP 和掩码加法融合, 文本经多文本时间窗跨注意力注入, RoPE Transformer 统一建模时间关系; 训练时根据条件强弱选择 “估计回归模式” 或 “扩散生成模式”, 并利用几何/2D 投影损失把运动特征监督落实到真实人体几何。

第二部分 论文全文中文翻译

以下翻译按照原论文主文结构逐节进行。参考文献编号与原文保持一致；公式编号、图表编号和实验数字均按原文保留。

论文题目

GENMO: 一个用于人体运动的通才模型 (A GENeralist Model for Human MOtion)

作者: Jiefeng Li、Jinkun Cao、Haotian Zhang、Davis Rempe、Jan Kautz、Umar Iqbal、Ye Yuan; NVIDIA。

项目主页: <https://research.nvidia.com/labs/dair/genmo>

图 1 说明: GENMO 在一个统一框架中整合人体动作估计与生成, 并支持多种条件信号, 包括单目视频、2D 关键点、文本描述、音乐和 3D 关键帧。GENMO 能够从动态相机视频中准确估计全局人体动作, 也能够无缝处理任意组合、任意持续长度的条件信号, 并在不同条件之间生成平滑过渡。所有这些都通过一次前馈式扩散推理实现, 无需复杂后处理。

摘要

传统的人体动作建模通常将动作生成与动作估计视为两个独立任务, 并分别设计专用模型。动作生成模型关注从文本、音频或关键帧等输入中创建多样、逼真的动作; 动作估计模型则旨在从视频等观测中重建准确的动作轨迹。尽管二者共享对时间动态和运动学结构的底层表示, 这种任务分离仍限制了知识迁移, 并要求维护多套模型。我们提出 GENMO——一个统一的人体动作通才模型, 在单一框架中连接动作估计与动作生成。我们的核心洞见是: 可以将动作估计重新表述为受约束的动作生成, 其中输出动作必须精确满足观测到的条件信号。

通过利用回归与扩散之间的协同作用, GENMO 既能实现准确的全局动作估计, 又能支持多样化动作生成。我们还提出一种估计引导的训练目标, 利用带有 2D 标注和文本描述的野外视频提升生成多样性。此外, 我们提出的新架构能够处理可变长度动作, 并能在不同时间区间内混合使用文本、音频、视频等多模态条件, 从而提供灵活控制。统一建模带来了双向收益: 生成先验能够改善遮挡等困难条件下的动作估计, 而多样的真实视频数据又能增强生成能力。大量实验表明, GENMO 作为通才框架能够在单一模型内成功处理多种人体动作任务。

1. 引言

人体动作建模是计算机视觉与计算机图形学中的长期研究主题, 并广泛应用于游戏、动画和 3D 内容创作。这些创意应用通常要求精确且直观的用户控制。设想一个场景: 用户希望生成一段由多种模态共同控制的动作序列——先从视频片段开始, 随后过渡到按照文本描述执行动作, 再与音频提示同步, 并最终与另一段视频对齐, 同时还通过用户定义的关键帧进行细粒度控制。这样的序列不仅要精确复现视频中观

观察到的人体动作，还要体现文本或音乐描述的意图，并始终满足指定关键帧。尽管近年来各个单项任务都取得了显著进展，但要在多种模态之间同时实现这种精度和灵活性仍然十分困难。

具体而言，视频动作估计通常采用以精度为中心的确定性预测，而文本/音乐到动作的生成则需要覆盖所有可能的合理动作，因此要求较高的多样性。尽管两类任务共享时间动态和运动学结构等共同表示，它们仍通常被独立处理。这种分离阻碍了任务间知识迁移，也要求维护多套独立模型。

近期研究揭示了动作估计与动作生成之间的协同关系。生成模型[22,49,60]能够为动作估计提供鲁棒先验，尤其适用于世界坐标估计等具有挑战性的场景[6,31,37,69]。反过来，用于估计的大规模视频数据也能够通过丰富模型学习到的动作分布，提高生成模型的真实感[40]。这推动我们开发一个能够跨多模态同时处理两类任务的通才模型。然而，两类任务的目标存在明显冲突：生成任务需要从文本或音频等抽象输入中产生多样且合理的输出；估计任务则必须从视频、关键点等具体观测中精确重建动作。因此，如何在一个统一架构中同时平衡多样生成与精确重建，并充分利用共享表示，仍然非常困难。

为解决上述问题，我们提出 GENMO——一个统一动作估计与生成的人体动作通才模型。我们将动作估计表述为满足观测信号约束的条件动作生成。这样的统一带来了协同收益：生成先验能够提升遮挡等困难估计场景中的动作合理性，而丰富的视频数据又能扩大生成动作的多样性，而且无需真实 3D 标注。

GENMO 建立在扩散模型框架之上，并引入新的双模式训练范式：（1）估计模式：向 GENMO 扩散去噪器输入初始化噪声并使用最大的扩散时间步，迫使模型根据条件信号产生动作的最大似然估计；

（2）生成模式：遵循传统扩散训练方式，根据预定义噪声调度采样带噪动作和时间步，使模型学习条件下丰富的生成分布。双模式训练使 GENMO 既能进行精确估计，又能进行多样化生成。我们进一步提出估计引导训练目标，有效利用只有 2D 标注的野外视频，从而显著扩展生成能力。与此同时，我们的架构能够处理可变长度动作，并无缝整合位于不同时间区间的任意多模态条件组合。值得强调的是，GENMO 能够通过一次前馈扩散过程完成多条件动作生成，无需复杂后处理。

通过大量实验，我们在涵盖全局/局部动作估计以及音乐到舞蹈、文本到动作、动作插值等任务的综合测试中验证了 GENMO。实验结果表明，GENMO 在全局动作估计、局部动作估计和音乐到舞蹈生成等多个任务上达到最先进水平，证明了统一通才框架在人体动作建模中的有效性。

本文贡献概括如下：

- 提出 GENMO，这是首个将最先进全局动作估计与灵活人体动作生成统一起来的通才模型，支持视频、音乐、文本、2D 关键点和 3D 关键帧等条件。
- 提出的架构能够在无需复杂后处理的情况下，基于任意数量和任意组合的多模态输入无缝生成可变长度动作。
- 提出新的双模式训练范式以探索回归和扩散之间的协同作用，并提出估计引导训练目标，使模型能够有效利用野外视频。
- 证明了双向收益：生成先验可以改善遮挡等困难条件下的估计，而多样视频数据又能增强生成表达能力。

2. 相关工作

2.1 人体动作生成

近年来，人体动作生成取得了显著进展[3,7,10–12,19,20,22,23,46,46,49,53,60,62,67,73,74,82]，并使用了多种条件信号，例如文本[8,13,18,27]、动作类别[15]、语音[1,81]、音乐[38,54,57,59,61,62]以及场景/物体[21,33,66,70,78]。近期，多模态动作生成[4,43,75,80]也开始受到关注，可以同时接收多种输入模态。然而，大多数现有方法只关注生成任务，并不支持动作估计。例如方法[75]虽然支持视频输入，却把视频仅作为生成条件，因此输出动作只是宽松模仿视频内容，而不是精确匹配。相比之下，我们的方法联合处理生成和估计，因此能够获得更加精确的视频条件结果。

对于长序列动作生成，现有方法大多依赖临时设计的后处理策略，将多个固定长度片段拼接起来[2,45,48,76]。相比之下，我们提出一种新的扩散架构，能够在不依赖复杂后处理的情况下，以多模态条件生成任意长度的连续动作。

AMASS[44]等现有数据集在规模和多样性方面仍有限。为缓解 3D 数据不足，Motion-X[40]和 MotionBank[68]利用 2D 视频以及 3D 姿态估计器[52,72]扩充数据，但由此得到的动作往往包含伪影。我们的方法则直接使用带 2D 标注的野外视频，不需要显式 3D 重建，从而减少对噪声 3D 数据的依赖，同时提升鲁棒性和多样性。

2.2 人体动作估计

从图像[28,35,50]、视频[9,14,30]甚至稀疏标记数据[34,47,71]中估计人体姿态已经得到广泛研究。近期工作主要关注在世界坐标中恢复全局人体动作[31,37,52,65,69,72]。该问题天然病态，因此这些方法通常利用生成先验约束人体动作，并利用 SLAM 约束相机运动。然而，这些方法往往涉及计算成本较高的优化或额外的后处理阶段。

更近期的方法尝试以前馈方式估计全局人体动作[51,52,65,77]，以提高推理速度。我们的工作沿着这一方向进一步推进，在统一扩散框架中联合建模生成和估计，并在训练中共享表示与生成先验，从而获得更合理的估计结果。

3. 人体动作通才模型

GENMO 通过把动作估计和动作生成都表述为条件动作生成来统一二者。具体而言，模型根据条件信号集合 C 及其对应的条件掩码集合 M ，合成长度为 N 的人体动作序列 x ，其中 N 可以任意大。条件集合 C 可以包含一种或多种以下信号：视频特征 $c_{\text{video}} \in \mathbb{R}^{N \times d_{\text{video}}}$ 、相机运动 $c_{\text{cam}} \in \mathbb{R}^{N \times d_{\text{cam}}}$ 、2D 骨架 $c_{2d} \in \mathbb{R}^{N \times d_{2d}}$ 、音乐片段 $c_{\text{music}} \in \mathbb{R}^{N \times d_{\text{music}}}$ 、2D 边界框 $c_{\text{bbox}} \in \mathbb{R}^{N \times d_{\text{bbox}}}$ ，或者描述动作的自然语言 $c_{\text{text}} \in \mathbb{R}^{M \times d_{\text{text}}}$ ，其中 M 为文本 token 数量。条件掩码 M 由每种条件 c_* 对应的掩码 $m_* \in \mathbb{R}^{N \times d_*}$ 构成。掩码矩阵与条件特征尺寸相同，当某个条件特征可用时对应元素为 1，否则为 0。

联合局部与全局动作表示。现在介绍用于 x 的动作表示。大多数文本到动作方法采用以人体自身为中心、去除朝向的局部坐标表示；而在动作估计任务中，为了更好地与图像特征对齐，人体动作通常表示在相机坐标系中。为了获得统一的生成和估计模型，我们采用一种通用人体动作表示，同时编码自我中心动作、相机空间动作以及相机姿态。

具体而言，我们采用 Gravity-View 坐标体系[51]。在第 i 帧，人体全局轨迹包含 gravity-view 朝向 $\Gamma_{gv}^i \in \mathbb{R}^6$ 和局部根速度 $v_{root}^i \in \mathbb{R}^3$ 。第 i 帧的局部动作使用 SMPL[42]参数表示，包括关节角 $\theta^i \in \mathbb{R}^{24 \times 6}$ 、形状参数 $\beta^i \in \mathbb{R}^{10}$ 和根平移 $t_{root}^i \in \mathbb{R}^3$ 。相机姿态通过相机到世界变换 $\pi^i = (\Gamma_{cv}^i, t_{cv}^i)$ 表示，其中 $\Gamma_{cv}^i \in \mathbb{R}^6$ 是相机视角朝向， $t_{cv}^i \in \mathbb{R}^3$ 是相机平移。此外，我们加入 $p^i \in \mathbb{R}^6$ 的接触标签，用于手和脚（脚跟、脚尖）。完整动作序列 $x = \{x^i\}_{i=1}^N$ 由 N 个人体姿态组成，每个姿态包含全局动作、局部动作和相机姿态：

$$x^i = (\Gamma_{gv}^i, v_{root}^i, \theta^i, \beta^i, t_{root}^i, \pi^i, p^i) \quad (1)$$

3.1 统一的估计与生成设计

本节介绍 GENMO 的架构设计，并解释它如何在单一模型中统一动作估计与动作生成。如图 2 所示，模型把带噪动作序列 x_t 、条件 C 和条件掩码 M 转换为干净动作序列 x_0 。初始阶段是 Additive Fusion 模块，它把 x_t 转换为逐帧动作 token。该模块为 C 中每种条件分别设置专用 MLP 进行处理，再通过求和将各种条件特征合并为统一条件表示，并进一步与带噪动作 x_t 融合，生成动作 token 序列。随后，该序列进入 L 个 GENMO 模块，每个模块由一个基于 RoPE 的 Transformer block 和我们提出的 Multi-Text Injection Block 构成。

我们的架构使用旋转位置编码 RoPE[56]，它根据相对时间位置计算注意力。这使网络能够处理可变长度序列，也能适应图像、2D 骨架等本身缺乏明确时间顺序的条件。

文本条件会带来特殊挑战。与视频、音乐等逐帧对齐模态不同，文本并不与动作帧一一对应。传统的“把文本拼到动作序列中”的方式并不合适，因为把文本插入任意位置都会引入时间偏置。为解决这一问题，我们提出新的 Multi-Text Injection Block，使模型既能处理文本条件动作生成，又能接收多个带用户指定时间窗口的文本输入 K 。该模块由一个 Transformer block 构成，其核心是本文提出的 multi-text attention 机制。

如图 3 所示，多文本注意力同时处理 K 个文本嵌入序列 $c_{text}^1, c_{text}^2, \dots, c_{text}^K$ 和输入动作特征序列 f_{in} ，得到输出序列 f_{out} ：

$$f_{out} = \sum_{k=1}^K \text{MaskedMHA}(f_{in}, c_{text}^k, \Omega_k) \quad (2)$$

$$\Omega_k(i, j) = 1 \text{ (若 } i \text{ 位于文本 } k \text{ 的时间窗口内), 否则为 } 0 \quad (3)$$

其中 MaskedMHA 表示传统多头注意力的掩码版本。对于每个文本输入 k ，我们使用二值掩码 Ω_k ：当动作时间步 i 位于文本 k 指定的时间窗口内时取 1，否则取 0。通过用 Ω_k 约束注意力权重，我们把每个文本提示的影响限制在相应时间区间内。该多文本注意力机制可以处理任意数量的文本输入，每

个文本都可以具有用户定义的时间窗口长度。虽然时间窗口边界处的 mask 会产生不连续性，但后续 RoPE Transformer 能够建模时间动态，从而生成平滑动作。

任意动作长度推理。我们的架构对动作序列使用相对位置编码而非绝对位置编码，因此 GENMO 可以在一次扩散前向过程中生成任意长度动作，并自然地在不同时间区间内包含多个文本输入。推理时，我们在 RoPE Transformer 中采用滑动窗口注意力，每个 token 只关注 W 帧邻域内的 token。这使模型能够生成比训练序列更长的动作，同时保持计算效率和动作过渡的平滑连贯。

混合多模态条件。当同时使用多个模态时，我们采用如下原则：不具备帧级对齐的文本条件通过专门的多文本注意力处理；视频、音乐、2D 骨架等帧对齐条件则通过时间掩码处理。对于每种条件 c_* ，使用同尺寸掩码 m_* 指示每一帧上该特征是否全部或部分存在；同时将条件特征乘以 mask，使缺失特征归零。这种简单而有效的策略能够在不同条件模态之间实现无缝切换，同时保持时间一致性。

3.2 双模式训练范式

作为扩散模型，GENMO 理论上可以使用标准 DDPM[24]目标训练：

$$L_{\text{gen}} = E_{\{t \sim [1, T], x_t \sim q(x_t | x_0)\}} [\|x_0 - G(x_t, t, C, M)\|^2] \quad (4)$$

其中 t 是采样的扩散时间步， x_t 是由前向扩散过程采样得到的带噪动作。理想情况下，用该目标训练的模型应该能够生成满足条件 C 和 mask M 的动作，因此当提供视频 c_{video} 或 2D 骨架 c_{2d} 时，也可以用于动作估计。然而我们发现，仅靠这一生成式训练目标不足以产生与输入视频精确一致的动作。

我们观察到动作估计与文本到动作生成之间存在根本区别：动作估计结果的方差显著更低。为研究这一现象，我们分别训练文本到动作扩散模型和视频条件动作估计扩散模型，并可视化它们在所有扩散步骤以及不同初始潜变量噪声下的预测（图 4）。结果显示，视频条件模型表现得更加确定：第一步预测与后续各步非常相似，变化很小；而文本到动作模型在不同扩散步骤之间存在更大差异。

这一观察对动作估计具有重要意义：第一步预测的精度非常关键，因为扩散早期引入的错误很难在后续步骤中纠正。基于这一洞见，我们提出由（1）估计模式和（2）生成模式组成的双模式训练范式。直观上，该方法在保留模型生成能力的同时，强化第一步预测质量。

估计模式。在估计模式中，我们把问题写成回归任务，并通过最大似然估计学习条件分布 $q(x|C, M)$ 。对应 MSE 目标为：

$$L_{\text{est}} = E_{\{z \sim N(0, I)\}} [\|x_0 - G(z, T, C, M)\|^2] \quad (5)$$

与使用带噪动作 x_t 不同，我们把纯高斯噪声 $z \sim N(0, I)$ 作为模型输入，并配合最大扩散时间步 T 。这样可以让估计模式与扩散模型内在的方差特性相匹配，从而避免估计模式与生成模式发生冲突。

为进一步提高预测动作质量，我们沿用已有方法[49,60]加入几何正则损失 L_{geo} 。具体而言，把预测动作解码为 SMPL 关节和顶点，然后在世界坐标与相机坐标中分别约束顶点位置、关节位置以及关节接触。当只有 2D 标注时，则使用 2D 重投影损失来约束预测动作。

生成模式。对于具有干净 3D 标注 x_0 的数据，可以直接使用公式(4)的标准扩散目标训练生成模式。本节重点讨论只有 2D 标注的情况。

相比 3D 标注，2D 姿态标注更容易获得，可以通过人工标注或在大规模视频上运行鲁棒 2D 姿态估计器得到。2D 数据也比现有 3D 动捕数据具有更多样性，因为后者通常受限于被试数量、动作类型、外观与环境。

利用 GENMO 自身的估计能力，我们能够自然地把 2D 数据用于生成模式训练。具体而言，我们提出估计引导的生成训练策略：首先以视频或 2D 骨架为条件，通过估计模式生成伪干净动作 $\hat{x}_0=G(z,T,C)$ ；然后通过前向扩散 $q(\hat{x}_t|\hat{x}_0)$ 得到带噪动作 $\hat{x}_t$ ；最后使用真实 2D 关键点标注 x_{2d} ，对模型预测的干净动作施加 2D 重投影损失：

$$L_{\text{gen-2D}} = E_{\{\hat{x}_t \sim q(\hat{x}_t|\hat{x}_0), t \sim [1,T]\}} [\|x_{2d} - \Pi(G(\hat{x}_t,t,C))\|^2] \quad (6)$$

其中 Π 表示 2D 投影函数。在生成模式下，我们同样使用前述几何损失 L_{geo} 对预测动作进行正则化。

训练模式选择。我们使用带有不同模态的数据集训练模型。当某种条件信号很强、会使动作分布更加确定时，例如视频或 2D 骨架，我们同时使用估计模式和生成模式训练 GENMO。相反，当条件更加抽象、导致动作分布更具生成性时，例如文本和音乐，我们只使用生成模式。这一模式选择原则同时适用于 3D 数据与 2D 数据。为了高效组成 batch，我们使用 loss mask 为每个样本选择性激活相应目标，从而保证只有合适的训练模式参与优化。

4. 实验

我们在四类任务上评估 GENMO，包括视频到动作、音乐到舞蹈、文本到动作以及动作插值。除特别说明外，所有实验都使用一个同时针对所有任务联合训练的一体化 checkpoint。

数据集。 GENMO 在覆盖多种任务的数据上训练：（1）AMASS[44]动作捕捉数据；（2）BEDLAM[5]、Human3.6M[26]和 3DPW[63]等动作估计数据；（3）AIST++[38]音乐到舞蹈数据；（4）HumanML3D[16]文本到动作数据；（5）Motion-X[40]中的 2D 关键点与文本描述。完整训练过程与实现细节见补充材料。评估方面，使用 RICH[25]与 EMDB[29]评估全局人体动作估计，使用 3DPW[63]评估局部动作估计，使用 AIST++[38]评估音乐到舞蹈，使用 HumanML3D[16]与 Motion-X[40]评估文本到动作。

评估指标。 音乐到舞蹈遵循标准指标[38,61]，报告 FID、Diversity、PFC 和 BAS。文本到动作遵循既有工作[16,60]，报告 R-Precision（Top 3）、FID、Diversity 和 MultiModal Dist。动作插值使用关键帧的 WA-MPJPE 和 PA-MPJPE。动作估计使用 MPJPE、PA-MPJPE 和 PVE 衡量局部动作，使用 Acceleration Error 衡量平滑性；全局动作估计使用 W-MPJPE100 与 WA-MPJPE100，并用 RTE 百分比衡量长序列误差累积，同时报告 Jitter 与接触阶段 Foot Sliding。

4.1 动作估计评估

全局动作估计。我们将 GENMO 与从动态相机视频恢复世界坐标人体动作的最先进方法进行比较。为了公平比较使用不同 SLAM 系统的方法，也报告使用数据集真实相机参数的结果。如表 1 所示，GENMO 持续优于只针对人体动作估计训练的专用方法。例如在 EMDB 上，我们的方法使用与 TRAM 相同的 SLAM 系统和视频编码 backbone，却将 W-MPJPE 从 222.4 mm 降低到 202.1 mm。我们认为这种优势来自统一生成-估计框架，其中生成先验提升了重建动作质量。GENMO 在 RICH 上同样优于现有方法。

局部动作估计。表 2 显示 GENMO 在大多数局部 3D 动作指标上超过现有方法。去掉 2D-only 训练后性能下降，说明估计引导的 2D 训练目标有效。在更困难的 3DPW-XOCC 遮挡数据上，生成先验也帮助 GENMO 在严重遮挡和截断条件下保持鲁棒。

表1 世界坐标人体动作估计 (原论文数据)

模型	EMDB WA-MPJPE100	EMDB W-MPJPE100	RTE	Jitter	FS	RICH WA-MPJPE100	RICH W-MPJPE100	RTE	Jitter	FS
GLAMR	280.8	726.6	11.4	46.3	20.7	129.4	236.2	3.8	49.7	18.1
TRACE	529.0	1702.3	17.7	2987.6	370.7	238.1	925.4	610.4	1578.6	230.7
SLAHMR	326.9	776.1	10.2	31.3	14.5	98.1	186.4	28.9	34.3	5.1
COIN	152.8	407.3	3.5	-	-	-	-	-	-	-
WHAM (DPVO)	135.6	354.8	6.0	22.5	4.4	109.9	184.6	4.1	19.7	3.3
WHAM (GT extr.)	131.1	335.3	4.1	21.0	4.4	109.9	184.6	4.1	19.7	3.3
GVHMR (DPVO)	111.0	276.5	2.0	16.7	3.5	78.8	126.3	2.4	12.8	3.0
GVHMR (GT extr.)	109.1	274.9	1.9	16.5	3.5	78.8	126.3	2.4	12.8	3.0
TRAM (DROID-SLAM)	76.4	222.4	1.4	-	-	-	-	-	-	-
GENMO (DROID-SLAM)	74.3	202.1	1.2	17.8	8.8	75.3	118.6	1.9	15.0	6.7
GENMO (GT extr.)	69.5	185.9	0.9	17.7	8.6	75.3	118.6	1.9	15.0	6.7

注：括号中的 24 表示用于计算 WA-MPJPE100、W-MPJPE100 与 Jitter 的关节数量。数值越低越好。

表2 相机空间动作估计指标

模型	3DPW PA	3DPW MPJPE	3DPW PVE	3DPW Accel	RICH PA	RICH MPJPE	RICH PVE	RICH Accel	EMDB PA	EMDB MPJPE	EMDB PVE	EMDB Accel
CLIFF*	43.0	69.0	81.2	22.5	56.6	102.6	115.0	22.4	68.1	103.3	128.0	24.5
HybrIK*	41.8	71.6	82.3	-	56.4	96.8	110.4	-	65.6	103.0	122.2	-
HMR2.0	44.4	69.8	82.2	18.1	48.1	96.0	110.9	18.8	60.6	98.0	120.3	19.8
ReFit*	40.5	65.3	75.1	18.5	47.9	80.7	92.9	17.1	58.6	88.0	104.5	20.7
VIBE*	51.9	82.9	98.4	18.5	68.4	120.5	140.2	21.8	81.4	125.9	146.8	26.6
TRACE*	50.9	79.1	95.4	28.6	-	-	-	-	70.9	109.9	127.4	25.5
SLAHMR	55.9	-	-	-	52.5	-	-	9.4	69.5	93.5	110.7	7.1
PACE	-	-	-	-	49.3	-	-	8.8	-	-	-	-
WHAM*	35.9	57.8	68.7	6.6	44.3	80.0	91.2	5.3	50.4	79.7	94.4	5.3
GVHMR*	36.2	55.6	67.2	5.0	39.5	66.0	74.4	4.1	42.7	72.6	84.2	3.6
TRAM*	35.6	59.3	69.6	4.9	-	-	-	-	45.7	74.4	86.6	4.9
GENMO* (无 2D 训练)	35.2	55.4	67.0	4.8	40.6	66.4	75.4	4.0	44.3	76.0	88.9	4.3
GENMO*	34.6	53.9	65.8	5.2	39.1	66.8	75.4	4.1	42.5	73.0	84.8	3.8

注：*表示使用 3DPW 训练集训练的模型。PA=PA-MPJPE。

4.2 动作生成评估

音乐到舞蹈比较。我们在 AIST++数据集[38]上评估音乐到舞蹈生成，结果见表3。除了其他 SOTA 方法，还比较了一个仅在 AIST++上训练的音乐到舞蹈专用 GENMO 变体。值得注意的是，跨多个估计/生成任务联合训练的通才模型在动作多样性、物理合理性和音乐-动作相关性上明显更好，这体现在更高的 Divk、Divm、BAS 和更低的 PFC 上。虽然通才 GENMO 的 FID 高于 music-only 专用版本，但这是预期现象，因为通才模型训练数据更加异构，覆盖多个任务和领域。

方法	FIDk ↓	FIDm ↓	Divk ↑	Divm ↑	PFC ↓	BAS ↑
FACT	86.43	43.46	6.85	3.32	2.2543	0.1607
Bailando	28.16	9.62	7.83	6.34	1.754	0.2332
EDGE	42.16	22.12	3.96	4.61	1.5363	0.2334
GCDance	36.81	20.10	6.44	6.47	-	0.2346
GENMO (music only)	16.10	13.91	8.47	7.26	0.7340	0.2282
GENMO	40.91	18.51	10.09	7.48	0.3702	0.2708

文本到动作比较。我们在 HumanML3D（表4）和 Motion-X（表5）上评估文本到动作能力。相比基线 MDM[60]，GENMO 在动作保真度和文本对应性上更好。为了评估 2D 数据训练的影响，作者还比较了去掉 Motion-X 2D 数据训练的模型。结果表明，加入 2D 训练能够显著改善 HumanML3D 和 Motion-X 上的动作生成表现，验证了在 GENMO 框架中利用 2D 数据训练文本动作生成的有效性。

方法	表示	R@3 ↑	FID ↓	MM Dist ↓	Diversity→
Real	HumanML3D	0.797	0.002	2.974	9.503
T2M	HumanML3D	0.740	1.067	3.340	9.188
MDM	HumanML3D	0.611	0.544	5.566	9.559
M2DM	HumanML3D	0.763	0.352	3.134	9.926
EMDM	HumanML3D	0.786	0.112	3.110	9.551
MoMask	HumanML3D	0.781	0.204	2.779	-
GENMO (无 2D 训练)	SMPL	0.556	0.245	3.128	11.660
GENMO	SMPL	0.632	0.216	3.466	11.342

方法	R@3 ↑	FID ↓	MM Dist ↓	Diversity→
Real	0.791	0.001	2.823	11.702
MDM	0.313	2.389	6.745	8.720
GENMO (无 2D 训练)	0.401	0.515	5.210	12.124
GENMO	0.472	0.207	4.801	11.719

关于 HumanML3D 性能的讨论。尽管 GENMO 比 EMDM[79]等 SOTA 方法表现差，作者认为主要原因是表示方式不同：GENMO 使用 SMPL 参数统一表示估计与生成，而 SOTA 方法使用 HumanML3D 表示，该表示同时也是 FID 与 R-Precision 评估编码器所采用的表示。这种表示不匹配给 GENMO 带来内在劣势：训练时需要把 HumanML3D 真实动作双向转换到 SMPL，评估时又需要把生成动作从 SMPL 转回 HumanML3D。转换过程不可避免地改变骨长、关节角和关节速度，引入分布偏移，从而影响指标并限制 GENMO 在 HumanML3D 专用指标上的性能上限。

动作插值实验。我们进一步通过动作 in-betweening 评估条件动作生成能力，采用既有扩散方法 [60]：在每个去噪步骤前用关键帧姿态覆盖带噪动作。实验分别在 HumanML3D 和 Motion-X 测试集上进行，每条序列随机使用 2 个或 5 个关键帧。如表 6 所示，联合估计与生成训练优于纯扩散基线；加入 2D-only 数据并与视频条件动作估计联合训练，也进一步提升了插值质量。

模型	HumanML3D 2KF	HumanML3D 5KF	Motion-X 2KF	Motion-X 5KF
Diffusion-only	71.6/98.8	46.3/70.4	97.6/154.9	56.3/106.9
w/o Estimation	64.9/97.5	47.5/72.6	97.9/151.0	69.6/116.4
w/o 2D Training	56.4/85.1	36.7/59.5	68.3/136.8	44.6/98.6
GENMO	53.5/85.3	37.1/58.5	58.8/122.7	40.5/89.5

注：表中为 PA-MPJPE/WA-MPJPE。

4.3 消融研究

估计模式的影响。作者训练只使用生成模式的“Diffusion-only”版本。表 7 显示，在 RICH 和 EMDB 全局动作估计上，去掉估计目标会显著降低性能，证明估计目标对于提高预测动作与输入视频的一致性非常关键。表 6 的动作插值结果也显示，估计目标能够改善插值。

生成模式的影响。作者又把统一模型与纯回归基线进行比较。纯回归基线只使用估计模式，类似传统人体动作估计模型。表 7 显示，完整 GENMO 持续优于纯回归版本，说明生成先验能够提升人体动作估计质量。

模型	RICH WA-MPJPE100	RICH W-MPJPE100	EMDB WA-MPJPE100	EMDB W-MPJPE100
Diffusion-only	88.9	143.9	128.6	307.7
Regression-only	87.0	141.0	121.1	300.1
GENMO	81.3	130.6	114.6	281.7

不同推理步数。作者使用标准 DDIM[55]评估去噪步数的影响。结果显示，动作估计对步数相对稳定，而文本到动作生成更加敏感。特别地，单步去噪就足以产生与视频一致的人体动作，而 5 步在估计上达到最佳性能，说明少量生成先验可以提升估计，但过多随机性未必继续有益。

DDIM 步数	HumanML3D FID	EMDB W-MPJPE100	EMDB MPJPE
1 (Regression)	0.260±0.101	280.0	73.0
2	0.242±0.083	276.8	72.5
5	0.231±0.091	274.9	72.2
10	0.237±0.126	275.8	72.3
50	0.216±0.119	278.7	72.7

5. 结论

本文提出 GENMO，一个连接人体动作估计与动作生成的通才框架。我们证明，GENMO 能够利用共享表示带来协同收益：生成先验提高困难条件下动作估计的鲁棒性，而多样视频数据又丰富生成能力。GENMO 能够在一次推理中生成可变长度动作，并支持文本、视频、音乐、2D 关键点和 3D 关键帧的灵活

控制。GENMO 在动作估计和动作生成基准上取得最先进表现，同时降低对 3D 动作捕捉数据的依赖。大量实验证明，GENMO 不仅能用单一框架处理多种人体动作任务，而且能超过任务专用模型。

参考文献（书目信息保留，标题中文翻译）

- [1] Alexanderson et al., 2023. Listen, denoise, action! audio-driven motion synthesis with diffusion models. 【听、去噪、行动！基于扩散模型的音频驱动动作合成。】
- [2] Athanasiou et al., 2022. TEACH: Temporal action composition for 3D humans. 【TEACH：面向 3D 人体的时序动作组合。】
- [3] Barsoum et al., 2018. HP-GAN: Probabilistic 3D human motion prediction via GAN. 【HP-GAN：基于 GAN 的概率 3D 人体动作预测。】
- [4] Bian et al., 2024. MotionCraft: Crafting whole-body motion with plug-and-play multimodal controls. 【MotionCraft：通过即插即用多模态控制构造全身动作。】
- [5] Black et al., 2023. BEDLAM: A synthetic dataset of bodies exhibiting detailed lifelike animated motion. 【BEDLAM：具有细致逼真动画动作的人体合成数据集。】
- [6] Bogo et al., 2016. Keep it SMPL: Automatic estimation of 3D human pose and shape from a single image. 【Keep it SMPL：从单幅图像自动估计 3D 人体姿态与形状。】
- [7] Cervantes et al., 2022. Implicit neural representations for variable length human motion generation. 【用于可变长度人体动作生成的隐式神经表示。】
- [8] Chen et al., 2023. Executing your commands via motion diffusion in latent space. 【通过潜空间动作扩散执行你的指令。】
- [9] Choi et al., 2021. Beyond static features for temporally consistent 3D human pose and shape from a video. 【超越静态特征：从视频恢复时间一致的 3D 人体姿态与形状。】
- [10] Chopin et al., 2021. Human motion prediction using manifold-aware Wasserstein GAN. 【基于流形感知 Wasserstein GAN 的人体动作预测。】
- [11] Cohan et al., 2024. Flexible motion in-betweening with diffusion models. 【基于扩散模型的灵活动作插值。】
- [12] Dai et al., 2024. MotionLCM: Real-time controllable motion generation via latent consistency model. 【MotionLCM：基于潜一致性模型的实时可控动作生成。】
- [13] Ghosh et al., 2021. Synthesis of compositional animations from textual descriptions. 【从文本描述合成组合式动画。】
- [14] Goel et al., 2023. Humans in 4D: Reconstructing and tracking humans with transformers. 【Humans in 4D：使用 Transformer 重建与跟踪人体。】
- [15] Guo et al., 2020. Action2Motion: Conditioned generation of 3D human motions. 【Action2Motion：条件式 3D 人体动作生成。】
- [16] Guo et al., 2022. Generating diverse and natural 3D human motions from text. 【从文本生成多样且自然的 3D 人体动作。】
- [17] Guo et al., 2022. Generating diverse and natural 3D human motions from text. 【从文本生成多样且自然的 3D 人体动作。】
- [18] Guo et al., 2022. TM2T: Stochastic and tokenized modeling for the reciprocal generation of 3D human motions and texts. 【TM2T：用于 3D 人体动作与文本双向生成的随机 token 化建模。】
- [19] Guo et al., 2024. MoMask: Generative masked modeling of 3D human motions. 【MoMask：3D 人体动作的生成式掩码建模。】
- [20] Habibie et al., 2017. A recurrent variational autoencoder for human motion synthesis. 【用于人体动作合成的循环变分自编码器。】
- [21] Hassan et al., 2021. Stochastic scene-aware motion prediction. 【随机场景感知动作预测。】
- [22] He et al., 2022. NeMF: Neural motion fields for kinematic animation. 【NeMF：用于运动学动画的神经动作场。】
- [23] Henter et al., 2020. MoGlow: Probabilistic and controllable motion synthesis using normalising flows. 【MoGlow：基于归一化流的概率可控动作合成。】
- [24] Ho et al., 2020. Denoising diffusion probabilistic models. 【去噪扩散概率模型。】
- [25] Huang et al., 2022. Capturing and inferring dense full-body human-scene contact. 【捕获并推断密集全身人体-场景接触。】
- [26] Ionescu et al., 2014. Human3.6M: Large scale datasets and predictive methods for 3D human sensing in natural environments. 【Human3.6M：自然环境 3D 人体感知的大规模数据集与预测方法。】
- [27] Jin et al., 2023. Act as you wish: Fine-grained control of motion diffusion model with hierarchical semantic graphs. 【Act as you wish：通过层次语义图细粒度控制动作扩散模型。】

- [28] Kanazawa et al., 2018. End-to-end recovery of human shape and pose. 【端到端恢复人体形状与姿态。】
- [29] Kaufmann et al., 2023. EMDB: The Electromagnetic Database of Global 3D Human Pose and Shape in the Wild. 【EMDB: 野外全局 3D 人体姿态与形状电磁数据库。】
- [30] Kocabas et al., 2020. VIBE: Video inference for human body pose and shape estimation. 【VIBE: 用于人体姿态和形状估计的视频推理。】
- [31] Kocabas et al., 2024. PACE: Human and motion estimation from in-the-wild videos. 【PACE: 从野外视频估计人体与动作。】
- [32] Kong et al., 2023. Priority-centric human motion generation in discrete latent space. 【离散潜空间中的优先级中心人体动作生成。】
- [33] Kulkarni et al., 2023. NIFTY: Neural object interaction fields for guided human motion synthesis. 【NIFTY: 用于引导人体动作合成的神经物体交互场。】
- [34] Lee and Joo, 2024. Mocap everyone everywhere: Lightweight motion capture with smartwatches and a head-mounted camera. 【随时随地捕捉每个人: 基于智能手表和头戴相机的轻量动作捕捉。】
- [35] Li et al., 2021. HybriK: A hybrid analytical-neural inverse kinematics solution for 3D human pose and shape estimation. 【HybriK: 用于 3D 人体姿态与形状估计的混合解析-神经逆运动学。】
- [36] Li et al., 2023. NIKI: Neural inverse kinematics with invertible neural networks for 3D human pose and shape estimation. 【NIKI: 基于可逆神经网络的 3D 人体姿态与形状神经逆运动学。】
- [37] Li et al., 2024. COIN: Control-inpainting diffusion prior for human and camera motion estimation. 【COIN: 用于人体与相机动作估计的控制修补扩散先验。】
- [38] Li et al., 2021. AI Choreographer: Music conditioned 3D dance generation with AIST++. 【AI 编舞者: 基于 AIST++ 的音乐条件 3D 舞蹈生成。】
- [39] Li et al., 2022. CLIFF: Carrying location information in full frames into human pose and shape estimation. 【CLIFF: 将全帧位置信息引入人体姿态与形状估计。】
- [40] Lin et al., 2023. Motion-X: A large-scale 3D expressive whole-body human motion dataset. 【Motion-X: 大规模 3D 表现性全身人体动作数据集。】
- [41] Liu et al., 2025. GCDance: Genre-controlled 3D full body dance generation driven by music. 【GCDance: 音乐驱动的风格可控 3D 全身舞蹈生成。】
- [42] Loper et al., 2015. SMPL: A skinned multi-person linear model. 【SMPL: 蒙皮多人线性模型。】
- [43] Luo et al., 2024. M3GPT: An advanced multimodal, multitask framework for motion comprehension and generation. 【M3GPT: 用于动作理解与生成的先进多模态多任务框架。】
- [44] Mahmood et al., 2019. AMASS: Archive of motion capture as surface shapes. 【AMASS: 以表面形状形式归档动作捕捉数据。】
- [45] Petrovich et al., 2024. Multi-track timeline control for text-driven 3D human motion generation. 【文本驱动 3D 人体动作生成的多轨时间线控制。】
- [46] Pinyoanuntapong et al., 2024. MMM: Generative masked motion model. 【MMM: 生成式掩码动作模型。】
- [47] Ponton et al., 2023. SparsePoser: Real-time full-body motion reconstruction from sparse data. 【SparsePoser: 从稀疏数据实时重建全身动作。】
- [48] Qian et al., 2023. Breaking the limits of text-conditioned 3D motion synthesis with elaborative descriptions. 【利用细化描述突破文本条件 3D 动作合成的限制。】
- [49] Rempe et al., 2021. HuMoR: 3D human motion model for robust pose estimation. 【HuMoR: 用于鲁棒姿态估计的 3D 人体动作模型。】
- [50] Sarandi and Pons-Moll, 2024. Neural localizer fields for continuous 3D human pose and shape estimation. 【用于连续 3D 人体姿态与形状估计的神经定位场。】
- [51] Shen et al., 2024. World-grounded human motion recovery via gravity-view coordinates. 【基于 Gravity-View 坐标的世界锚定人体动作恢复。】
- [52] Shin et al., 2024. WHAM: Reconstructing world-grounded humans with accurate 3D motion. 【WHAM: 以准确 3D 动作重建世界锚定人体。】
- [53] Shiobara and Murakami, 2021. Human motion generation using Wasserstein GAN. 【基于 Wasserstein GAN 的人体动作生成。】
- [54] Siyao et al., 2022. Bailando: 3D dance generation by actor-critic GPT with choreographic memory. 【Bailando: 带编舞记忆的 Actor-Critic GPT 3D 舞蹈生成。】

- [55] Song et al., 2020. Denoising diffusion implicit models. 【去噪扩散隐式模型。】
- [56] Su et al., 2024. RoFormer: Enhanced transformer with rotary position embedding. 【RoFormer: 使用旋转位置编码增强 Transformer。】
- [57] Sun et al., 2022. You never stop dancing: Non-freezing dance generation via bank-constrained manifold projection. 【你永不停止舞蹈: 基于 bank 约束流形投影的非冻结舞蹈生成。】
- [58] Sun et al., 2023. TRACE: 5D temporal regression of avatars with dynamic cameras in 3D environments. 【TRACE: 3D 环境动态相机下 Avatar 的 5D 时间回归。】
- [59] Tang et al., 2018. Dance with melody: An LSTM-autoencoder approach to music-oriented dance synthesis. 【随旋律起舞: 基于 LSTM 自编码器的音乐导向舞蹈合成。】
- [60] Tevet et al., 2023. Human motion diffusion model. 【人体动作扩散模型。】
- [61] Tseng et al., 2023. EDGE: Editable dance generation from music. 【EDGE: 从音乐生成可编辑舞蹈。】
- [62] Valle-Perez et al., 2021. Transflower: Probabilistic autoregressive dance generation with multimodal attention. 【Transflower: 带多模态注意力的概率自回归舞蹈生成。】
- [63] von Marcard et al., 2018. Recovering accurate 3D human pose in the wild using IMUs and a moving camera. 【使用 IMU 和移动相机在野外恢复准确 3D 人体姿态。】
- [64] Wang and Daniilidis, 2023. ReFit: Recurrent fitting network for 3D human recovery. 【ReFit: 用于 3D 人体恢复的循环拟合网络。】
- [65] Wang et al., 2024. TRAM: Global trajectory and motion of 3D humans from in-the-wild videos. 【TRAM: 从野外视频恢复 3D 人体全局轨迹与动作。】
- [66] Wang et al., 2022. HUMANISE: Language-conditioned human motion generation in 3D scenes. 【HUMANISE: 3D 场景中的语言条件人体动作生成。】
- [67] Xu et al., 2023. ActFormer: A GAN-based transformer towards general action-conditioned 3D human motion generation. 【ActFormer: 面向通用动作条件 3D 人体动作生成的 GAN Transformer。】
- [68] Xu et al., 2024. MotionBank: A large-scale video motion benchmark with disentangled rule-based annotations. 【MotionBank: 带解耦规则标注的大规模视频动作基准。】
- [69] Ye et al., 2023. Decoupling human and camera motion from videos in the wild. 【从野外视频中解耦人体与相机运动。】
- [70] Yi et al., 2024. Generating human interaction motions in scenes with text control. 【在场景中通过文本控制生成人人交互动作。】
- [71] Yi et al., 2021. TransPose: Real-time 3D human translation and pose estimation with six inertial sensors. 【TransPose: 使用六个惯性传感器实时估计 3D 人体平移与姿态。】
- [72] Yuan et al., 2022. GLAMR: Global occlusion-aware human mesh recovery with dynamic cameras. 【GLAMR: 动态相机下的全局遮挡感知人体网格恢复。】
- [73] Zhang et al., 2022. MotionDiffuse: Text-driven human motion generation with diffusion model. 【MotionDiffuse: 扩散模型驱动的文本人体动作生成。】
- [74] Zhang et al., 2023. ReMoDiffuse: Retrieval-augmented motion diffusion model. 【ReMoDiffuse: 检索增强动作扩散模型。】
- [75] Zhang et al., 2024. Large motion model for unified multi-modal motion generation. 【用于统一多模态动作生成的大型动作模型。】
- [76] Zhang et al., 2023. DiffCollage: Parallel generation of large content with diffusion models. 【DiffCollage: 使用扩散模型并行生成大规模内容。】
- [77] Zhang et al., 2024. RoHM: Robust human motion reconstruction via diffusion. 【RoHM: 基于扩散的鲁棒人体动作重建。】
- [78] Zhang et al., 2025. FORCE: Dataset and method for intuitive physics guided human-object interaction. 【FORCE: 直观物理引导人体-物体交互的数据集与方法。】
- [79] Zhou et al., 2024. EMDM: Efficient motion diffusion model for fast and high-quality motion generation. 【EMDM: 用于快速高质量动作生成的高效动作扩散模型。】
- [80] Zhou and Wang, 2023. UDE: A unified driving engine for human motion generation. 【UDE: 人体动作生成的统一驱动引擎。】
- [81] Zhu et al., 2023. Taming diffusion models for audio-driven co-speech gesture generation. 【驯服扩散模型: 音频驱动的共语手势生成。】
- [82] Zhu et al., 2023. Human motion generation: A survey. 【人体动作生成: 综述。】