

GigaBrain-WBC-0.5：用于环境交互鲁棒全身控制的行为 世界模型

方法与框架讲解 + 全文中文翻译

原文： **GigaBrain-WBC-0.5: A Behavior World Model for Robust Whole-Body Control with Environment Interaction**

作者： Ziyang Cheng, Tianshu Tang, Jinxin Lan, Xinze Chen, Yuhan Gong, Zhichao Liu, Changzhong Wu, Yahao Mao, Zongyan Deng, Mingxuan Ma, Huasen Xi, Yilong Liu, Yutong Wu, Xiaofeng Wang, Yang Wang, Yun Ye, Guan Huang, Xiaojie Jin, Zheng Zhu, Jiwen Lu

版本： arXiv:2608.18234v1, 2026-08-18

说明：本 PDF 前半部分先从“它解决什么问题、网络如何连接、输入输出是什么、为什么能称为世界模型、训练和部署如何闭环”几个层面讲解方法；后半部分按原文结构给出完整中文翻译。公式、数值、文献编号均保持原文含义。参考文献的正式英文题名与出版信息按原文保留，以避免改变可检索的书目信息。

第一部分 方法与框架讲解

1. 这篇论文到底做了什么？


这篇论文不是在做“文本/音乐生成机器人动作”的高层动作生成模型，而是在做人形机器人的低层全身运动跟踪控制器。它的输入仍然是一个上游系统给出的参考动作，例如 VR 遥操作、运动学规划器或离线动作回放；它的任务是以 50 Hz 实时输出 29 个关节的 PD 目标，让 Unitree G1 在真实动力学约束下尽可能跟上参考动作，同时保持平衡、利用环境接触，并在参考指令不合理或机器人摔倒时继续工作。

传统大规模 motion tracker 的核心思想是：把尽可能多的人体动作重定向到机器人上，通过强化学习训练一个统一跟踪策略。这样，机器人可以走、跑、蹲、跳、跳舞、起身。但这类控制器大多只在空场景 + 平地上训练，所以一旦脚踩到高台、身体坐到椅子上、手里拿重物，机器人受到的接触力和惯性都改变了，原来的控制器往往会把这些变化当成“扰动”而不是“可以利用的环境约束”。

GigaBrain-WBC-0.5 的核心改动是：不再让控制网络只预测下一步动作，而是让它同时预测“下一步自己的状态”和“下一步合理行为指令的概率分布”。于是同一个网络既是策略，又具有一个简化的、面向控制的“世界模型”能力。

可以把整篇论文压缩成三件事：

1. 把 motion tracker 改造成 Behavior World Model（行为世界模型）：同时预测动作、下一状态和下一行为分布。
2. 自动从已有重定向动作反推出 3D 地形/支撑几何：解决大规模“动作 + 场景几何”配对数据不足的问题。
3. 用世界模型自己预测的行为分布做 OOD 指令过滤：遇到当前环境下明显不可能完成的指令，不是急停，也不是直接拒绝，而是把指令回缩到“当前情况下最接近、但仍属于模型学过的可执行行为”。



原文图1：整体能力与行为世界模型概览

图解读：左侧是“由动作自动生成地形”，中间是行为世界模型，底部展示其最终希望统一获得的四类能力：精确全身跟踪、环境交互、鲁棒恢复和跨机器人本体迁移。

2. 输入、网络和输出：一帧到底怎么走？

论文控制的是 29 自由度 Unitree G1，控制频率 50 Hz，即每 20 ms 做一次决策。每一步 t ，策略有三类输入：

输入	维度	含义
本体感知状态 S_t	67	投影重力、基座角速度、躯干线加速度、关节位置和关节速度
上一步动作 a_{t-1}	29	上一个时刻输出的 29 维关节目标
潜在行为指令 z_t	64	由未来 10 帧参考动作编码得到的行为表示

因此送进核心 Transformer 的逐帧向量为：

$$e_t = [s_t, a_{t-1}, z_t] \in R^{160}.$$

它先被映射到 256 维，然后进入一个 **6 层、4 头、带 RoPE 的因果 Transformer**。每一层只关注最近 32 帧，并使用 KV cache 做单步增量推理。由于局部注意力跨层逐渐扩展，6 层堆叠后的有效感受野是 187 帧，按 50 Hz 计算约为 3.74 秒。

Transformer 最终接三个线性输出头：

- **Policy head（策略头）：**输出 $a_t \in R^{29}$ ，即下一步 PD 关节目标；
- **State head（状态头）：**预测 $\hat{s}_{t+1} \in R^{67}$ ；
- **Behavior head（行为头）：**输出一个 4 分量对角高斯混合模型 GMM，描述下一时刻潜在行为指令 $z_{t+1} \in R^{64}$ 的分布。

每个 GMM 分量包含 1 个混合权重、64 维均值和 64 维对数标准差，所以输出维度是 $4 \times (1+64+64)=516$ 。




Figure 2. GigaBrain-WBC-0.5 overview. (a) The reference window c_t is perturbed with noise and mask for the

原文图2：GigaBrain-WBC-0.5 网络与部署流程

3. 参考动作如何变成 64 维“潜在行为指令”？

上游系统不会直接向 Transformer 塞 10 帧完整动作，而是先构造一个**未来 10 帧参考窗口** c_t 。每一帧间隔 0.02 s，每帧包含：

1. 29 维参考关节位置；
2. 参考根节点相对于机器人当前根节点的 6D 旋转；
3. 参考根节点相对上一参考帧的 3D 平移；
4. 参考根节点相对机器人当前根节点的 3D 平移；
5. 世界向下方向在参考根节点坐标系中的 3D 表示。

单帧共 $29+6+3+3+3=44$ 维，10 帧正好得到 $c_t \in R^{440}$ 。

随后：

$$z_t^{raw} = E(c_t + \epsilon_t) \in R^{64},$$

其中 E 是 MLP 编码器，64 维表示按两个 32 维 token 组织。

这里有一个很重要的设计：**真正送给策略的是连续、未量化的 z_t ；FSQ（有限标量量化）只出现在训练期辅助重建分支。** 量化后的潜变量通过一个小型运动学 MLP Decoder 重建干净的 440 维参考窗口，再把重建结果重新编码，与原连续潜变量做循环一致性对齐。

这样做的目的不是把动作离散化，而是“**整理潜空间**”：如果编码器把大量信息挤在少数维度里，经过每维 32 级的量化后会丢失信息，无法重建；于是编码器会倾向于把信息更均匀地分布在潜空间中。结果是：控制仍保持连续精细，但 64 维潜空间更平滑、更分散，便于后面的 GMM 去建模“哪些行为当前是合理的”。

4. 为什么根节点平移要在训练时随机遮掉？

地形交互非常怕全局漂移。比如上楼梯时，机器人真实根节点如果已经比参考位置偏了几厘米，下一脚就可能踩不到参考中对应的台阶位置。

最直接的办法是给控制器持续提供“机器人真实全局位置与参考位置的差”，也就是参考窗口中的第 (iv) 类特征。但真实机器人往往没有可靠的全局根位置，因此论文不能让策略依赖这个信号。

作者的做法是：训练时这部分信号**约 1/3 的时间可见，2/3 时间置零**，每个环境每 2-5 秒重新采样一次；部署时则始终置零。这样策略会同时学会两件事：

- 大多数时候没有全局定位也能继续跟踪；
- 一旦偶尔得到定位信息，就会重新把自己“锚定”回参考轨迹。

这也是为什么论文宁可保持长 episode，让 187 帧的历史上下文真正发挥作用，而不是像很多跟踪方法那样频繁重置机器人到参考状态。

5. “Behavior World Model”到底世界模型在哪里？

这篇论文的 world model 不是常见的“输入图像，预测未来视频帧”的视觉世界模型，也不是一个显式构建完整物理场景的仿真器。它是一个**嵌在低层控制策略内部的一步行为/动力学预测模型**。

关键在两个辅助预测头：

5.1 预测下一本体状态：学“当前环境如何改变我的动力学”

当机器人从平地踩到 18 cm 高台时，地面反作用力的作用位置变了；当手里拿起重物时，质心和惯量变了。若网络只需要输出动作，它可以在很多情况下靠反应式控制“硬跟踪”。但现在它还必须预测 s_{t+1} ，就被迫在隐藏状态中表示：**当前有哪些接触、负载和动力学变化正在影响身体**。

5.2 预测下一行为分布：学“当前环境允许我接下来做什么”

在平地上可以横向跨一大步，但在窄台阶上可能做不到；“向后坐下”的动作在有椅子时合理，在平地上却没有物理意义。因此可执行动作集合不是固定的，而是**随环境条件变化的条件分布**。

行为头预测 $p(z_{t+1} | history_t)$ ，相当于让模型持续估计“在当前身体状态、接触历史和行为上下文下，下一步有哪些行为是训练分布内的、合理的”。作者用 4 分量 GMM 保留多模态性，因为走路速度、方向、起跳方式等不同模式本来就位于潜空间不同区域，不能用一个高斯把它们糊成一个大椭圆。

所以，这里的“世界模型”可以概括为：

网络不仅决定下一步怎么动，还显式预测“动完以后我会是什么状态”以及“在当前世界里下一步什么行为是可能的”。

6. 自动 3D 地形标注：没有场景数据，怎么学环境交互？

大规模人体动作数据通常只有动作，没有对应的椅子、台阶、平台等场景模型。论文的一个关键贡献是：**从动作本身反推出它曾经接触过的几何**。




Figure 3. From motion to spatial terrain. (a) A retargeted motion is replayed kinematically. (b) Contact detection flags frames where a sampled surface point’s normal and tangential velocity fall below threshold (arrows show incoming velocity at the moment of contact). (c) Detected contacts accumulate into a 3D point

原文图3：由动作自动恢复空间地形

流程可以拆成五步：

1. **运动学回放**：在 MuJoCo 中仅按重定向轨迹回放机器人，不做动力学控制；
2. **接触检测**：在脚踝等可能接触的连杆表面均匀采样点，观察每个点的法向/切向速度；法向速度 $< 0.2 \text{ m/s}$ 、切向速度 $< 0.3 \text{ m/s}$ ，并且前 10 帧至少 2 帧具有 $> 1 \text{ m/s}^2$ 的法向减速度时，判为接触；
3. **累积接触点云**：把多个时刻检测到的接触点积累成 3D 点云；
4. **全身穿透过滤 + 聚类**：任何可能让机器人历史轨迹穿进“虚构物体”的候选支撑都会被删掉，再用法向一致性和 DBSCAN 聚类；
5. **拟合 3D 几何原语**：每个簇拟合成带方向的薄盒体，并通过 PCA、递归切分和安全扩张得到台阶、平台、座椅等可直接放入 Isaac Lab 的静态刚体。

与 2.5D 高度图不同，这种结果是真正的空间几何，因此可以表达“椅面下面是空的”“桌边”“扶手”“不同高度的阶梯踏面”等全身交互需要的结构。

7. OOD 指令过滤：模型怎么知道“这个动作现在做不了”？

这是论文最巧妙的一部分。

在时刻 t ，上游输入新的参考窗口 c_t ，编码器先得到原始潜在指令 z_t^{raw} 。但是判断这个指令是否合理时，**不能用当前步刚刚预测出来的 GMM G_t** ，否则 z_t^{raw} 已经进入网络，等于“拿包含题目答案的信息来判断题目是否异常”。

因此作者严格使用上一时刻产生的 G_{t-1} ：

$$c_t \rightarrow E \rightarrow z_t^{raw} \xrightarrow{G_{t-1}} z_t^{\hat{c}} \rightarrow \pi \rightarrow (a_t, \hat{s}_{t+1}, G_t).$$

这形成一个天然的一步延迟闭环。

7.1 先选当前最可能的行为模式

GMM 有 4 个分量。作者用一个 MAP 风格的规则选择 $k^{\hat{c}}$ ，既考虑混合权重 π_k ，也考虑当前 z_t^{raw} 到各高斯分量的标准化距离。这样可以优先选择“世界模型认为当前情形最可能出现”的行为模式，而不是误选一个方差特别大的分量。

7.2 再用马氏距离判断是否分布外

对选中的分量，定义平方马氏半径：

$$M_k^2(z) = \sum_{i=1}^{64} \left(\frac{z_i - \mu_{k,i}}{\sigma_{k,i}} \right)^2.$$

若

$$M_{k^{\hat{c}}}^2(z_t^{raw}) \leq R_{safe}^2,$$

则认为当前指令仍在可接受区域，直接执行；否则判为 OOD。

7.3 不是丢弃，而是沿径向回缩到安全椭圆边界

当指令越界时，作者没有用高斯均值替代指令，因为均值只是一个分布中心，不一定是一段应该执行的动作。相反，它沿“从该模式中心指向操作者原始指令”的方向进行缩放：

$$z_t^i = \mu_{k^i} + \sqrt{\frac{R_{safe}^2}{M_{k^i}^2(z_t^{raw})}} (z_t^{raw} - \mu_{k^i}).$$

这样新的 z_t^i 恰好落在安全椭圆边界上，仍保留“操作者想往哪个方向做”的意图，因此机器人会以 **best-effort**（尽力而为）的方式继续尝试，而不是急停或僵住。

该过滤器每步只包含闭式计算，计算量 $O(1)$ ，论文称耗时远低于 1 ms，相对于 20 ms 的控制周期几乎可以忽略。部署时唯一需要调节的参数是安全半径 R_{safe} ：值越小，过滤越保守、鲁棒性越强，但跟踪精度下降；值越大，则更接近完全不过滤。论文最终使用 $R_{safe}=3$ 。

8. 训练目标：PPO 只是主体，世界模型能力来自辅助损失

总损失为：

$$L = L_{PPO} + 0.01 L_{recon} + 1.0 L_{cycle} + 0.01 \|\hat{s}_{t+1} - s_{t+1}\|_2 - 0.005 \log G_t(z_{t+1}).$$

可以理解为五部分：

1. L_{PPO} ：学习真正能在动力学里执行并跟踪动作；
2. L_{recon} ：量化潜变量仍要能重建参考窗口；
3. L_{cycle} ：重建后重新编码的潜变量要与原连续潜变量对齐；
4. 下一状态预测误差：逼迫隐藏状态学习接触与动力学；
5. GMM 负对数似然：逼迫网络学习下一行为潜变量的条件分布。

训练数据来自三套大规模重定向人体动作数据：Bones-Seed 288 h、MotionMillion 900 h、MotionDecode 1000 h，总计 2188 h；其中自动识别出的空间地形交互分别为 12.50 h、22.22 h、37.85 h，总计约 72.57 h。

训练在 Isaac Lab 中使用 PPO。平地阶段用 4096 个并行环境；加入异构地形原语和摔倒初始化后降到 512 个环境。为了增强鲁棒性，作者还加入：

- 从不同躯干倾角直到完全趴倒的合成摔倒姿态初始化；
- 恢复期间平滑关闭高精度跟踪惩罚，避免机器人还没站起来就因为跟不上参考而被惩罚；
- 手腕/躯干随机持续外力，模拟负载和接触力；
- 摩擦、恢复系数、质量、质心、关节零位、推力、力矩等域随机化。

9. 整个部署闭环可以这样理解

上游行为源（VR / 规划器 / 离线动作）

- 未来 10 帧参考窗口 c_t
- MLP 编码为 z_t^{raw}
- 用上一帧 GMM G_{t-1} 做 OOD 检查
- 必要时投影到安全椭球得到 z_t^i
- 与 s_t, a_{t-1} 一起进入因果 Transformer
- 策略头输出 29 维关节目标执行
- 状态头预测 $\hat{s}_{t+1}$
- 行为头输出 G_t ，供下一帧过滤使用。

因此它是一个“控制 - 预测 - 约束下一条指令 - 再控制”的在线闭环。

10. 它真正的新意在哪里？

从方法逻辑看，论文最重要的不是单独用了 Transformer、GMM、PPO 或马氏距离，这些组件都不新。真正的新意是把它们组织成一个统一逻辑：

环境交互能力和异常指令鲁棒性，本质上都要求控制器理解“当前环境条件下什么行为是可实现的”。

状态预测让控制器理解环境如何改变自身动力学；行为分布预测让控制器理解当前环境允许哪些下一行为；自动地形生成给它提供大规模接触数据；OOD 投影再把这种“理解”直接用于部署时的安全修正。


这使它和传统“大动作库 motion tracker”的区别非常明确：传统方法主要通过扩大无条件参考动作分布来提高泛化，而 GigaBrain-WBC-0.5 开始显式建模**环境条件下的可行行为分布**。

11. 论文结果怎么读？

论文与 SONIC、HoloMotion-1、Humanoid-GPT 三个大规模跟踪器进行 sim-to-sim 对比：


- 平地 Standard：96.3% 成功率，MPKPE 76.6 mm；
- Terrain：81.3% 成功率，而最强基线仅 18.7%，约 4.3 倍；
- OOD 不可能参考动作：83.1% 成功率；
- 从摔倒姿态恢复：99.3%，而基线只有 0.7%-5.9%。

硬件实验还展示了坐箱子、上平台、抱箱、提 2 kg 灭火器、负载行走、缺失椅子/平台时的 best-effort 响应，以及被踢倒后由同一个跟踪策略自行起身。



A filter that never intervenes is useless, and one that always intervenes destroys precision. Sweeping the single knob R_{safe} of Section 3.4 traces the achievable frontier between survival under commands the policy was not trained for and fidelity under commands it was. The deployed radius $R_{\text{safe}} = 3$ sits at the knee: tightening it from the unfiltered limit (dashed) buys 2.9 points of OOD survival for 12.7 mm of Standard MPKPE, and the remainder of the sweep down to $R_{\text{safe}} = 1$ trades a further 2.2 points against 46.7 mm.

Figure 6. Robustness versus precision as a function of the safety radius. Standard-split MPKPE (in-distribution fidelity) and OOD success rate against the single filter parameter R_{safe} . Small R_{safe} shrinks the admissible ellipsoid and projects more aggressively, buying OOD survival at the cost of in-distribution tracking; large R_{safe} approaches the unfiltered policy (dashed). The circled radius $R_{\text{safe}} = 3$ is the operating point reported in Table 3.



原文图6-7：安全半径的精度-鲁棒性权衡与鲁棒行为示例

12. 需要注意的局限

论文自己明确给出三类限制：

1. OOD 过滤器主要在仿真中验证，换 checkpoint 或机器人平台后需要重新标定 R_{safe} ；
2. 它检测的是“是否偏离训练经验”，不是直接计算“物理风险”，所以只能高概率拦截不可行指令，不能保证绝对安全；
3. 自动地形恢复只能重建动作实际接触过的支撑面，场景中存在但没有碰到的物体不会被恢复，因此得到的是“支撑几何”，还不是完整环境世界模型。

从研究路线看，下一步最自然的方向就是：把状态预测进一步连接到显式物理风险/碰撞风险/稳定性指标，以及把“接触支撑几何恢复”扩展为更完整的环境建模。

第二部分 全文中文翻译

题目

GigaBrain-WBC-0.5：用于环境交互鲁棒全身控制的行为世界模型

Ziyang Cheng^{1,2}, Tianshu Tang^{1,2}, Jinxin Lan^{1,2}, Xinze Chen², Yuhan Gong², Zhichao Liu², Changzhong Wu², Yahao Mao^{2,3}, Zongyan Deng^{2,4}, Mingxuan Ma^{2,4}, Huasen Xi^{2,5,6}, Yilong Liu^{1,2}, Yutong Wu², Xiaofeng Wang², Yang Wang², Yun Ye², Guan Huang², Xiaojie Jin⁴, Zheng Zhu^{2,#}, Jiwen Lu^{1,#}

¹ 清华大学; ² GigaAI; ³ 上海理工大学; ⁴ 北京交通大学; ⁵ 中国科学院自动化研究所; ⁶ 中国科学院大学。# 通讯作者。

项目主页：原文标注为 “this link”（PDF 内嵌超链接）。

摘要

全身运动跟踪策略能够把人形机器人变成一种鲁棒的控制接口：遥操作人员或上游模型只需要提供粗略的运动意图，而低层策略负责维持机器人平衡并保证运动在物理上可行。现有跟踪器只能在平地上提供这种接口：它们在空场景中训练，从未学习地形和物体接触如何重塑自身动力学；同时，它们通常通过不断扩大参考动作语料库，试图教会策略在任何指令下保持平衡，但当可行动作开始依赖环境时，这种方法便失效了。本文提出 GigaBrain-WBC-0.5，据我们所知，这是首个用于人形机器人全身控制的行为世界模型（Behavior World Model, BWM）。与纯反应式跟踪器不同，我们训练一个因果 Transformer，使其联合预测下一动作、下一状态以及下一潜在行为指令的概率分布，从而让“负责执行动作的网络”同时建模环境会如何影响它下一步能做什么。我们进一步提出自动地形标注流程，从重定向动作中恢复完整的 3D 接触几何，使地形标注能够扩展到现有大规模运动数据集的规模。部署时，模型预测的分布被再次利用，用于在线检测不合理指令，并将其回缩到模型已经学会的行为区域，使机器人以“尽力而为（best-effort）”的方式继续尝试任务。最终得到一个统一策略：它能够接收实时指令、与环境交互，并对不合理指令、摔倒和外部扰动保持鲁棒。与三个大规模跟踪器基线相比，GigaBrain-WBC-0.5 在四种测试情形下均获得最高成功率：地形交互成功率为 81.3%（是最强基线的 4.3 倍），不合理指令下为 83.1%，摔倒恢复率为 99.3%（是最强基线的 16.8 倍）。真实硬件实验表明，在支撑缺失和外部扰动条件下，该方法仍能稳定完成交互；此外，Unitree G1 上训练的 checkpoint 经过简单微调即可迁移到 Maker L01 机器人。

1 引言

人形机器人的价值在于，它们能够在为人类设计的环境中同时使用双手和双脚，并具备穿越复杂地形的潜力。要实现这种能力，需要一个能够在线接收全身指令的低层控制器。大规模运动跟踪方法 [5, 8, 21, 23, 30, 52] 已经证明这一点是可以做到的：在统一目标下模仿数十万段重定向人体动作，就能得到一个能够行走、奔跑、下蹲、跳舞和起身的统一策略。这样的跟踪器并不仅仅是一个展示敏捷性的系统，

它本质上是一种控制接口。因为策略承担了平衡和物理可行性的负担，所以无论指令来自 VR 设备中的人类操作者 [14, 44]、运动学规划器，还是视觉-语言-动作模型 [3]，上游只需要表达粗略的运动意图，而不必给出高频、动力学一致的控制信号。正因为如此，这类控制器既可用于采集全身示范数据 [45]，也可以作为学习型高层策略之下的执行层 [23]。

然而，这类接口基本都生活在平地上。几乎所有此类控制器都在空场景和平坦地面中训练和评估，因此机器人从未被要求踩上物体、坐到物体上，或搬运重物。策略也从未被要求意识到自身动力学已经发生变化——例如地面反作用力现在从高出 18 cm 的位置作用，或者负载已经改变了系统质心——更没有学习如何利用这种变化。问题的瓶颈在数据：一个能够与环境交互的跟踪器，需要大规模、几何一致的“地形/物体几何 + 参考动作”成对数据，而这类数据十分稀缺。Chen 等人 [7] 正是针对这一瓶颈，从动作反推场景，这与我们的整体方向一致。然而，他们地形采用 2.5D 高度图，无法表达全身交互所需要的空间几何，例如下方具有空隙的椅面、桌沿、扶手等；他们的数据仅包含 7.5 小时特定交互动作，而且策略需要每个连杆的接触标签作为指令，而这种指令并不是操作人员能够提供的。

第二个不那么显眼但同样关键的问题是：在平地上用于提高跟踪器鲁棒性的常见做法，无法直接迁移到环境交互中。一个动作是否可行、是否像人类动作，取决于环境施加的动力学约束。在平地上，领域内通常通过扩大参考动作分布，让策略在几乎任何指令下都保持平衡 [5, 23, 30]。但当环境变化时，这一策略不再成立：在平地上可行的大跨度侧跨，在狭窄台阶上可能不可行；而向后靠坐到椅子上的动作，在没有椅子的平地上则毫无意义。可行行为集合变成了**依赖环境条件的集合**。与此同时，一旦输入指令偏离训练分布，强化学习策略本身就可能产生不可预测的行为，而地形会显著放大这种风险，因为无论怎样扩大一个“无条件”的动作数据集，都无法覆盖一个由环境决定的条件可行集合。

因此，我们需要一种在线机制，能够识别这类指令，并生成“尽力而为”的替代动作，而不是急停或退化为原地站立。后两种处理都会中断操作者的任务，并且在楼梯上甚至可能比继续运动更危险。Cheng 等人 [9] 表明，对于全身移动操作，这类无限时域问题可以化简为每个控制步都执行的一次低成本测试；我们沿用类似思想构建过滤器，但过滤依据直接来自世界模型自身的预测。


这一需求还有另一面：有时指令本身不可执行，有时则是机器人的身体已经处于指令没有预期到的状态——例如已经摔倒在地。起身本身就是一项独立能力 [17]，但决定操作者任务能否继续的关键在于：这项能力位于哪里。如果把控制权交给一个独立的起身控制器，那么任务会像摔倒本身一样被中断。因此，我们直接在跟踪器训练中加入摔倒初始化，使恢复成为该统一策略的一种行为。**当指令不可行时仍保持可驱动，以及当身体已经倒地时仍保持可驱动，是鲁棒全身控制的两个互补方面；本文所称的鲁棒全身控制，就是让这两种能力存在于同一个策略中。**

我们提出 GigaBrain-WBC-0.5，据我们所知，这是首个用于人形机器人全身控制的行为世界模型（BWM）：它不再只学习复现动作，而是学习建模自身未来行为。策略采用因果 Transformer，从参考编码器接收潜在行为指令，并在每个控制步同时输出动作、自身下一本体感知状态的预测，以及下一潜在行为指令的混合概率分布。以这种方式训练控制器，会改变网络必须表示的信息：预测下一状态要求它内化当前作用在身体上的接触动力学；预测下一指令分布则要求它建模当前环境允许哪些行为——这些都

是平地跟踪器既不需要也不会获得的能力。而环境交互与极端鲁棒性正是本文关注的两项能力，并且它们来自同一个模型，而不是通过额外挂接模块实现。

本文贡献如下：

- 提出一个行为世界模型，在输出动作的同时预测自身下一状态和下一指令分布，从而得到一个能够与地形和物体交互、同时仍可由实时操作者驱动的统一因果策略。
- 提出自动空间地形标注流程，直接从重定向轨迹中恢复该动作必然依赖的几何环境。不同于高度图，该方法输出真实 3D 几何——例如椅子、桌子、箱体和阶梯踏面——从而可以按照现有大规模动作数据集的规模构建“地形-动作”配对语料。
- 提出由世界模型自身预测分布驱动的在线过滤器，用于识别分布外指令，并将其投影到策略能够执行的最接近行为，而不是直接拒绝指令。该方法无需独立分类器或备用控制器，就能产生连续的 best-effort 动作。过滤器无状态且具有闭式解，只暴露一个可在运行时调节的安全半径，用于根据任务需求在精度和鲁棒性之间进行权衡。



原文图1：GigaBrain-WBC-0.5 概览

图 1. GigaBrain-WBC-0.5：首个用于人形机器人全身控制的行为世界模型。 GigaBrain-WBC-0.5 将自动“动作-地形”标注与因果行为世界模型结合起来。从普通重定向动作中恢复完整 3D 接触几何，使空间约束下的交互训练能够超越仅平地动作语料，并让策略学习利用环境接触。联合预测动作、下一本体感知状态和下一指令分布，使同一个网络在执行动作的同时建模接下来可能发生什么，并将其预测分布变成在线判据，用于把不合理指令回缩为 best-effort 行为。最终的实时指令控制器同时具备精确跟踪、物体/地形交互、无需独立控制器的摔倒恢复，以及通过微调从 Unitree G1 迁移到 Maker L01 的能力。

2 相关工作

2.1 全身运动跟踪与行为基础模型

全身控制（Whole-Body Control, WBC）是指协调人形机器人的整个身体，以实现给定控制目标的通用问题；其中最主流的形式，也是本文采用的形式，是全身运动跟踪，即把参考动作作为目标。基于物理的动作模仿 [28, 29] 已成为这一问题的标准做法，因为动作捕捉能够提供逐帧密集监督，而无需针对每

个任务人工设计奖励，随后该方向不断向大规模训练扩展。SONIC [23] 使用 128 块 GPU 在 1 亿帧数据上训练，并把异构输入映射到共享量化 token 空间；HoloMotion-1 [5] 使用稀疏 Mixture-of-Experts Transformer 和 KV-cache 推理，对来自视频的大规模混合语料进行扩展；Humanoid-GPT [30] 将一组强化学习动作专家蒸馏到 GPT 风格的因果 Transformer 中，并在 20 亿帧数据上训练。其他互补方向分别推进了动态技能敏捷性 [13, 15]、扰动抑制 [52]、通过扩散或掩码补全获得的多功能性 [21, 33]、跨形态和跨指令模式的通用性 [16, 37, 42]，以及跟踪精度与动作多样性之间的权衡 [36]；遥操作系统 [1, 14, 44, 45] 则把这类跟踪器进一步变成数据采集接口。行为基础模型 [43] 将同样的预训练思想扩展到运动跟踪之外，例如通过在行为语料上做掩码蒸馏，让一个策略支持多种控制模式 [46]，或学习跨动作、目标和奖励共享的潜在表示 [20]，不过后者目前的数据规模仍然更小。

这类工作反复面临两个限制。第一，这些模型通常在空场景和平地上训练 [5, 8, 20, 23, 30, 46]，因此其行为分布本质上是自由空间运动——表达能力强，但除了地面以外从不与任何东西接触。第二，实际泛化能力仍然小于目标愿景。Wang 等人 [36] 总结了一个“通用性障碍”：随着动作库规模增长，跟踪保真度会明显下降；Tessler 等人 [33] 和 Luo 等人 [22] 在基于物理的角色控制中也报告了覆盖范围和精度之间相同的张力。唯一已经实现一定场景交互的通用跟踪器 [7]，也只使用了 7.5 小时特定交互数据。GigaBrain-WBC-0.5 保留可扩展的因果跟踪框架，但改变了策略需要表示的对象：从“复现参考”转变为“建模当前环境允许发生什么”。

表 1. 能力比较。 遥操作一列要求方法必须具备因果、低延迟接口，并且只使用操作者能够在线提供的信号，而不能依赖逐连杆接触提示或特权状态。最后一列要求摔倒后由跟踪策略本身恢复：机器人自行站起并继续跟踪参考，不使用独立恢复控制器，也不进行人工重置。

方法	多样全身跟踪	全身遥操作	地形交互	物体交互	对 OOD 鲁棒	对摔倒鲁棒
GMT [8]	✓	✗	✗	✗	✗	✗
TWIST [44]	✓	✓	✗	✗	✗	✗
SONIC [23]	✓	✓	✗	✗	✗	✗
HoloMotion-1 [5]	✓	✓	✗	✗	✗	✗
Humanoid-GPT [30]	✓	✓	✗	✓	✗	✗
PHP [39]	✗	✗	✓	✗	✗	✗
GALLANT [2]	✗	✗	✓	✗	✗	✗
OmniRetarget [41]	✗	✗	✓	✓	✗	✗
SceneBot [7]	✓	✗	✓	✓	✗	✗
CMP [9]	✓	✓	✗	✓	✓	✗
BFM-Zero [20]	✓	✓	✗	✗	✗	✓
GigaBrain-WBC-0.5 (本文)	✓	✓	✓	✓	✓	✓

2.2 面向地形与物体交互的全身控制

另一条研究路线直接针对环境交互，从经典的接触感知轨迹优化、模型预测控制和落脚点规划 [11, 19]，发展到学习式的楼梯、斜坡和 3D 受限地形感知运动 [2, 48, 50, 54]。通过 motion matching 串联人体

技能 [39], 以及从单目视频重建耦合的“动作-地形”数据 [49], 已经实现了跑酷级别的敏捷能力; 场景感知的重定向和保持交互的数据生成方法 [38, 41, 47, 53] 则支持大物体操作跟踪; 地形感知运动学生成器还可以与跟踪器联合训练 [40, 51]。

本文不直接把 GigaBrain-WBC-0.5 与上述工作作为同类方法比较, 原因有两点。第一, 这类地形穿越策略通常是面向单一技能族的专用策略, 并且正如 Chen 等人 [7] 的综述所指出, 它们通常通过低维根速度或导航接口进行控制 [2, 50, 54]。这种接口只能说明机器人基座应该往哪里移动, 却无法指定手臂、躯干和手应该做什么, 因此不能充当通用全身操作系统的低层控制接口。第二, 那些能够在场景几何上跟踪完整全身参考的工作 [18, 38, 41, 53], 往往依赖成对的场景资产, 并且按单条轨迹进行展示, 而不是作为通用控制器使用。与本文最接近的工作是 SceneBot [7]: 它通过逐连杆接触标签进行条件控制, 并在事后重建 2.5D 高度地形, 从而在一个跟踪策略中统一了自由空间动作、地形交互与物体交互。GigaBrain-WBC-0.5 与其有三点不同: 本文的标注恢复完整空间几何而非高度场; 本文的指令通道是操作者可在线提供的参考窗口; 本文把策略训练为世界模型, 而不是依赖外部提供的接触提示。

2.3 对分布外指令和摔倒的鲁棒性

全身运动跟踪中的鲁棒性, 过去主要通过扩大训练分布来实现, 例如域随机化、对抗推力和事后扰动 [6, 15, 52]。Cheng 等人 [9] 则选择在线过滤指令, 将原本的无限时域约束简化为每个控制步执行的一次测试; 他们同时研究了两种方案: 一种轻量过滤器只标记训练分布外的指令, 另一种更复杂的方法通过额外学习模块估计策略实际上已经掌握了哪些指令。结果表明后者更有效, 但会增加系统复杂性。也有工作通过把行为约束在学习到的动作先验中, 对潜空间施加限制 [22, 33], 但这些方法虽然限制了可被指令到的行为, 却没有在线可接受性测试。

GigaBrain-WBC-0.5 采用相同的“单步、基于分布”的思想, 但不需要额外模块: 行为世界模型本身已经免费输出下一潜在指令的混合分布, 因此可以直接识别分布外指令, 并将其投影回该分布附近, 而无需额外机制。

不可执行指令是鲁棒性的一面, 机器人已经倒在地上则是另一面, 而后者通常由专门技能处理。HoST [17] 通过多 critic 课程学习, 在多样地面姿态下学习起身, 并部署在本文相同的 G1 平台上; SafeFall [25] 关注更早的阶段, 即预测不可避免的摔倒并调整冲击姿态, 以保护硬件。问题在于, 这种恢复能力被放在哪里, 会决定操作者的任务能否在摔倒后继续: 如果把控制权切换给专用起身控制器, 任务就会像摔倒本身一样被打断。BFM-Zero [20] 表明恢复能力不一定要成为一个独立模式——其无监督潜在策略在被拉倒后能够自行恢复并继续跟踪。本文采取同样立场, 直接把摔倒初始化纳入跟踪器训练 (第 3.5 节), 使起身成为统一策略的一种行为, 而不是退出跟踪模式后的额外流程。当指令本身不可执行时仍保持可驱动, 以及当身体不在指令预期状态时仍保持可驱动, 是同一需求的两个互补部分; 本文把二者放在同一策略中, 并将其定义为鲁棒全身控制。




Figure 2. GigaBrain-WBC-0.5 overview. (a) The reference window c_t is perturbed with noise and for the

原文图2: GigaBrain-WBC-0.5 总体框架

图 2. GigaBrain-WBC-0.5 总览。(a) 参考窗口 c_t 先加入噪声，其中机器人相对根节点平移特征会被间歇性掩码，再通过 MLP 编码器映射为潜在行为指令 z_t^{raw} ；有限标量量化器和解码器重建干净参考，仅用于训练期循环一致性损失（虚线）。(b) $[s_t, a_{t-1}, z_t]$ 经带 KV cache 的 6 层因果 Transformer 处理；三个输出头分别给出动作 a_t 、下一本体感知状态 s_{t+1} （与并行仿真器 rollout 对齐）以及下一潜在指令的高斯混合模型 G_{t+1} 。(c) 部署时，无状态马氏距离测试将 z_t^{raw} 与前一步输出的混合分布 G_t 比较，并在真正送入策略前，把分布外指令沿径向回缩到所选分量安全椭圆边界。右下角真实机器人帧展示了该部署路径在硬件上的指令执行结果。

3 方法

3.1 问题设置

本文以 50 Hz 控制一台具有 29 个驱动自由度的 Unitree G1 人形机器人。在每个时刻 t ，策略接收本体感知观测 $s_t \in \mathbb{R}^{67}$ （投影重力、基座角速度、躯干线加速度、关节位置和关节速度）、上一动作 $a_{t-1} \in \mathbb{R}^{29}$ ，以及覆盖未来 10 帧的参考窗口 c_t ；策略输出 PD 关节目标 $a_t \in \mathbb{R}^{29}$ 。参考窗口由实际驱动机器人的上游来源在线产生——可以是 VR 遥操作、运动学规划器或离线回放——因此，不论上游能够提供什么样的参考，策略都必须保持可持续驱动。图 2 总结了整体架构。

3.2 行为世界模型

参考窗口由指令源提供的动作构成。对于未来 10 帧、每帧间隔 0.02 s 的参考，我们依次取：(i) 29 维参考关节位置；(ii) 参考根节点相对机器人当前根节点的 6D 旋转；(iii) 参考根节点相对上一参考帧根节点的平移；(iv) 参考根节点相对机器人当前根节点的平移；(v) 世界向下方向在参考根节点坐标系中的表示。由此得到 $c_t \in \mathbb{R}^{440}$ ；其中第 (v) 块无需全局定位即可提供绝对重力对齐信息。每个特征块都叠加均匀噪声，随后 MLP 编码器 E 生成连续潜在行为指令

$$z_t^{raw} = E(c_t + \epsilon_t) \in \mathbb{R}^{64},$$

该潜变量表示为两个 32 维 token。

潜空间如何被塑造，会影响后续所有模块，因此我们不通过策略网络进行重建，而是让重建路径经过量化器。训练阶段，在编码器旁连接有限标量量化器 [26] 和一个小型运动学 MLP 解码器：解码器把量化后的潜变量映射回干净、未掩码的 440 维参考窗口，再将该重建窗口重新编码，并与原始连续潜变量对齐。策略本身始终接收未量化的连续潜变量。

这种路由在两个方向上都很重要。SONIC [23] 在通往动作解码器的主路径上同样做了量化，我们发现这会让精细动作分辨率不足；反过来，如果完全去掉量化器，直接从 Transformer 输出头重建参考窗口——这是另一个自然选择——潜变量本身就没有受到足够约束，我们发现其空间结构明显更差。把量化限制在辅助分支中，会使其成为纯粹的正则化手段：当每个维度只有 32 个量化级别时，如果潜变量把太多信息挤在太少维度上，量化取整后这些信息会变得不可区分，导致重建失败，因此编码器必须把信息分散到更多维度，并使潜空间保持相对松散。控制分辨率仍然保持连续，而潜空间获得了更平滑、更充分展开的结构，正好适合第 3.4 节中的混合分布建模。

在这些输入块中，第 (iv) 块需要特别处理。地形交互无法容忍全局漂移：如果机器人根节点偏离参考期望位置，那么脚下几何就不再与参考动作匹配，在爬楼梯等长时程任务中误差会持续积累。常见做法是把长动作切成短片段，并频繁把机器人重置回参考轨迹，从结构上限制漂移。但我们不能这样做：6 层、每层 32 帧局部注意力堆叠后具有 187 帧的有效感受野，如果 episode 短到需要频繁重置以限制漂移，网络将永远无法填满这一历史范围，也就不会学会利用它能看到的历史。

因此，我们保持长 episode，并通过输入处理控制漂移。第 (iv) 块正是用于纠正漂移的信号，但真实硬件通常无法获取机器人准确根节点全局位置，所以不能始终提供它。训练时，这一信息约有三分之一的时间可见，其余时间被置零；每个环境每 2-5 s 重新采样一次。这样策略既能学习在没有该信息时继续运行，也能在该信息短暂出现时重新锚定到参考轨迹。部署时，该输入块始终置零。

经过掩码处理的潜变量随后进入核心网络。逐帧输入

$$e_t = [s_t, a_{t-1}, z_t] \in R^{160}$$

首先映射为 256 维，再由 6 层因果 Transformer [35] 处理。网络具有 4 个注意力头，并使用旋转位置编码 [32]；一个掩码同时施加因果约束、32 帧窗口限制和 episode 边界限制。Rollout、评估和部署均采用单步推理，并在每层保留 KV cache，因此长上下文带来的边际计算成本只相当于一帧。

最终隐藏状态接三个线性输出头：

$$a_t \in R^{29}, \hat{s}_{t+1} \in R^{67}, G_t = \{\pi_k, \mu_k, \log \sigma_k\}_{k=1}^K \in R^{516}.$$

其中 $K=4$ ，每个分量都是针对下一潜在行为指令 $z_{t+1} \in R^{64}$ 的对角高斯。第一个输出头就是策略，另外两个输出头使网络成为世界模型。预测 s_{t+1} 迫使网络表示当前作用在身体上的接触动力学——例如机器人踩上箱体或拿起负载时发生的变化；预测 $p(z_{t+1} | history_t)$ 则迫使网络表示当前情形允许哪些行为，因为在楼梯上的下一指令可达集合与平面上的集合并不相同。

混合分布被有意设计为多模态：不同的行为模式——例如不同速度和方向的行走、不同风格的起跳——占据潜空间不同区域。如果把它们压成单高斯，这些区域会被混在一起，那么第 3.4 节用于投影的单一可接受区域就可能跨过当前情形实际上不允许的行为。

完整目标函数把 PPO 损失与四个辅助项结合：

$$L = L_{PPO} + 0.01 L_{recon} + 1.0 L_{cycle} + 0.01 \|\hat{s}_{t+1} - s_{t+1}\|_2 - 0.005 \log G_t(z_{t+1}).$$

两个下一步预测项在跨 episode 边界处都会被掩码，以避免监督不存在的伪转移。

3.3 自动空间地形标注

上述方法首先假设策略确实能够在地形上训练，但普通动作捕捉数据并不包含场景。我们通过“事后反推”解决这个问题：如果一段动作是在楼梯上采集的，那么它自身的运动学轨迹中就包含了楼梯所在位置的证据。我们的流程（图 3）自动把这种证据转换为可直接用于仿真的几何，从而能够按照现有动作数据集的规模构建“动作-地形”配对数据，而不再受限于专门的场景采集规模。




Figure 3. From motion to spatial terrain. (a) A retargeted motion is replayed kinematically. (b) Contact detection flags frames where a sampled surface point’s normal and tangential velocity fall below threshold (arrows show incoming velocity at the moment of contact). (c) Detected contacts accumulate into a 3D point

原文图3：从动作恢复空间地形

图 3. 从动作到空间地形。 (a) 对重定向动作进行运动学回放。 (b) 接触检测：当采样表面点的法向和切向速度低于阈值时标记接触帧，箭头表示接触瞬间的入射速度。 (c) 检测到的接触累积成 3D 点云。 (d) 经过全身穿过滤后，将点划分为碰撞安全的簇。 (e) 对每个簇拟合合适几何原语，得到用于训练的 3D 地形。它是真正的空间几何而非高度场，因此能够表达椅子、桌子、箱体和阶梯踏面。

我们首先在与接触相关连杆的碰撞几何表面上均匀采样点——默认使用两个脚踝连杆，也可以扩展到手、膝、肘、骨盆和躯干背部——然后在 MuJoCo [34] 中以运动学方式回放重定向轨迹，从而获得每帧每个采样点的世界坐标位置和外法向。经过 Savitzky-Golay 平滑后，为每个采样点运行一个状态机：当法向速度低于 0.2 m/s、切向速度低于 0.3 m/s，并且前 10 帧中至少有 2 帧的法向减速度超过 1 m/s² 时，标记为一次接触。这一减速特征用来区分真正的支撑事件与“肢体恰好暂时很慢”的情况。当采样点漂移超过 5 cm 或开始滑动时，接触结束；持续少于 10 帧的接触会被丢弃。

随后把检测到的接触转换为几何。高度低于 10 cm 或法向朝下的点被视为普通地面或非支撑表面而丢弃，其余点在 1 mm 体素网格上去重。然后，把每一个保留点放回整段机器人轨迹中进行全身检测：只有当在该处放置一个沿法向向外偏移至少 5 cm 的支撑物，并且该支撑物在所有帧都不会与机器人任何身

体部分相交时，该点才会保留。正是这个穿透过滤器，避免了重建算法凭空生成机器人历史上“本应穿过去”的虚假几何。

接下来，根据点对之间的亲和关系把点组成平面支撑：两个点只有在法向夹角不超过 40° 、且沿法向方向的相互偏移小于 10 cm 时才连接，因此即便不同高度的阶梯踏面横向相邻，DBSCAN 仍可将它们分离。每个簇拟合成一个 1 cm 厚的定向箱体：其平面内轴由切向投影的 PCA 得到，法向偏移与最低接触点对齐，从而避免浅接触被拟合成过深几何；如果一个簇的包围盒内部比点实际占据区域空得多，就沿主轴递归分割，将 L 形或环形支撑拆成多个紧致矩形。最后，每个几何原语通过保证无穿透的二分搜索向侧向扩张，为机器人在原始足迹周围提供一定余量。

在 Isaac Lab [27] 中，每个环境的这些原语以静态刚体形式生成，并与该环境对应的参考动作共同放置。由于不同动作的原语数量和尺寸不同，地形只在动作重新采样边界处重建，并且一个 epoch 内动作采样保持冻结，从而保证参考动作和几何始终一致。地形类别来自已经标注的数据语料，各类地形按可配置概率采样，使地形动作和平地动作以受控比例 0.2 混合训练。

3.4 分布外指令过滤

强化学习策略一旦输入偏离训练分布，就可能产生不可预测行为。第 1 节已经解释了，到了地形场景后，不可能单纯依靠扩大一个固定、与环境无关的训练分布来解决这个问题。部署时，上一控制步输出的混合分布 G_{t-1} 是在看到当前 c_t 之前，对“机器人当前情形下哪些行为指令与训练经验一致”的预测。我们把它作为训练分布的实时、一步近似，并按照 Cheng 等人 [9] 的单步化方法，对新到来的指令进行检查。

处理顺序必须严格为：

$$c_t \rightarrow E \rightarrow z_t^{raw} \xrightarrow{G_{t-1}} z_t^{\hat{c}} \rightarrow \pi \rightarrow (a_t, \hat{s}_{t+1}, G_t).$$

如果使用当前步才产生的混合分布去过滤当前潜变量，就会把指令本身泄漏进它自己的可接受性测试。第一控制步没有前驱混合分布，因此不做过滤；在任何会丢弃 G_{t-1} 而不是继续传递它的事件之后——例如显式行为切换、时间重置，或与直接 PD 控制之间切换——第一步也不做过滤。

一个自然方案是：只有当 z 在 G_{t-1} 下的对数似然高于固定阈值时才接受。但这种做法不可用，因为条件混合分布可能足够“平”，导致没有任何 z 能达到阈值，于是可接受集合为空。我们改为对每个分量利用平方马氏半径定义分布内区域：

$$M_k^2(z) = \sum_{i=1}^D \left(\frac{z_i - \mu_{k,i}}{\sigma_{k,i}} \right)^2, D=64,$$

其中 $\sigma_{k,i} = \exp(\log \sigma_{k,i})$ 。使用前把 $\log \sigma_{k,i}$ 截断在 $[-3, 10]$ ，避免退化输出头把定义的区域压缩到零或放大到无穷。定义

$$Z_k = \{z : M_k^2(z) \leq R_{safe}^2\},$$

该集合始终包含 μ_k ，因此永远非空。

由于每个分量对应一个行为模式，我们首先判断新指令最可能属于哪个模式，然后只针对该分量进行检查，并在需要时投影。分量选择规则为

$$k^i = \arg \max_k \left[\log(\pi_k + 10^{-10}) - \frac{1}{2D} \sum_{i=1}^D \left(\left(\frac{z_i - \mu_{k,i}}{\sigma_{k,i}} \right)^2 + 2 \log \sigma_{k,i} + \log 2\pi \right) \right].$$

这是一个 MAP 风格规则：高斯对数密度在 $D=64$ 个潜维度上取平均，而混合权重对数保持原尺度，因此行为模式先验在选择中的权重，比完全按维度一致缩放时更高。这样有意让选择更偏向世界模型认为当前情形下更可能的模式，而不是仅仅选择协方差最松的模式。如果允许任意一个分量都可以“接住”当前命令，那么某个不相关但方差较大的模式可能刚好靠近一个 OOD 指令，从而让异常指令悄悄绕过修正；作者发现这是一个重要失败模式。

一旦选定分量，每帧只需要检查一个不等式：当且仅当

$$M_{k^i}^2(z_t^{raw}) > R_{safe}^2$$

时，命令被判为分布外。当过滤触发时，我们不把命令直接替换为该分量均值——均值只是条件分布中心，并不等于应执行的动作——而是沿径向向 μ_{k^i} 回缩，刚好落在 Z_{k^i} 边界：

$$z_t^i = \mu_{k^i} + \sqrt{\frac{R_{safe}^2}{M_{k^i}^2(z_t^{raw})}} (z_t^{raw} - \mu_{k^i}).$$


按构造可知， $M_{k^i}^2(z_t^i) = R_{safe}^2$ 精确成立。这个点并不是椭球表面上的欧氏最近点；若要求欧氏最近点，每一帧都需要求解一个拉格朗日乘子。这里使用的是沿“行为模式中心 - 原始命令”射线的闭式缩放。回缩后的命令仍从可信行为模式指向操作者原本想要的方向，因此机器人会继续尝试任务，而不是冻结。

过滤器是无记忆的：每一帧都使用最新的 G_{t-1} 重新选择 k^i ，并独立重新判断不等式，因此随着情形变化，可接受区域也会持续跟踪条件混合分布。整个流程最终只包含两个闭式表达式。其每步复杂度为 $O(1)$ ，在 20 ms 控制周期内耗时远低于 1 ms，可忽略不计。系统还只保留一个可调参数——安全半径 R_{safe} 。操作者无需重新训练，就能在运行时调节它，沿图 6 所示前沿在跟踪保真度与鲁棒性之间取舍。

3.5 训练

我们使用三套大规模重定向人体运动数据：Bones-Seed [4] (288 h)、MotionMillion [12] (900 h) 和 MotionDecode [10] (1000 h)。其中分别识别出 12.50 h、22.22 h 和 37.85 h 包含空间地形交互的动作，并为每段动作标注其涉及的地形类型。这个识别出的子集随后经过清洗和过滤，去除重定向伪影以及第 4.3 节人工审计发现的地形标注失败样本，然后再以受控比例和平地动作混合训练，从而在学习丰富接触行为的同时保留自由空间跟踪质量。

3.5 Training



We draw on three large retargeted human-motion corpora: Bones-Seed [4] (288 h), MotionMillion [12] (900 h) and MotionDecode [10] (1000 h). Within them we identify 12.50 h, 22.22 h and 37.85 h respectively as containing spatial terrain interaction, each clip labelled with the terrain type it involves. This identified subset is cleaned and filtered—removing retargeting artifacts and the annotation failures caught by the audit of Section 4.3—before being mixed with flat-ground motion at a controlled rate for training, so that free-space tracking quality is preserved while contact-rich behavior is learned.

Figure 4. Source corpora and identified terrain coverage. The outer ring is the total duration of each corpus, the inner ring the duration identified as terrain interaction; the two are independent pies, so the inner ring reads as the terrain composition rather than a slice of the total. Corpus identity is carried by color across the rings.

原文图4：数据语料和地形交互时长

图 4. 源数据语料与识别出的地形覆盖。 外环表示每个语料库的总时长，内环表示识别为地形交互的时长；两个环是相互独立的饼图，因此内环表达的是地形交互数据的组成，而不是总时长中的一个很窄扇区。颜色在两个环之间保持一致，用于表示语料来源。

我们在 Isaac Lab [27] 中对图 4 所示数据混合使用 PPO [31] 优化，并采用序列级更新：每次更新时，带梯度重新计算当前 rollout 片段，同时连接 rollout 开始时保存并停止梯度的各层 KV 前缀，因此更新期间网络看到的注意力上下文与策略实际执行动作时完全一致。平地 rollout 使用 4096 个并行环境；当启用地形几何和摔倒状态初始化后降为 512 个，因为每个环境生成不同静态几何原语会增加粗阶段碰撞检测成本。

两项设计直接针对鲁棒性。首先，一部分平地 episode 从合成摔倒姿态开始，并对躯干倾角进行课程学习，逐步扩展到完全俯卧；一个经过验证的全身碰撞代理把机器人放置在与地面接触的位置。同时，精确跟踪奖励通过一个相对目标的平滑恢复门控进行控制，使策略在仍处于站起过程时不会因为跟不上参考动作而受到惩罚。其次，在手腕和躯干上施加持续随机外力，用来模拟负载和接触力。

迁移到第二种机器人本体时，完全复用同样训练方案。把语料重新重定向到 Maker L01 人形机器人，并在单个 8-GPU 节点上对 G1 checkpoint 进行微调，就能够很快恢复新机器人的全身动作跟踪；而在 L01 上从头训练相同架构则收敛很慢。这表明行为世界模型似乎携带了“人形机器人如何与环境交互”的结构知识，而这种知识并不专属于某一组具体连杆长度。第 4.5 节展示结果中有一部分来自 L01。

每一个跟踪项都把误差 e 映射为：

$$r = \exp(-\|e\|^2/\sigma^2).$$

因此，奖励项的权重与核宽度 σ 就能完整定义奖励；表 2 同时给出这些参数与域随机化范围。锚点项作用于根节点，相对身体项作用于根节点坐标系中所有被跟踪连杆，局部项作用于根坐标系中的头部代理点、手腕和双脚——这些也是 VR 操作者能够提供的点。Critic 在部署时丢弃，它是一个独立 MLP，输入 1756 维特权观测，包括多帧参考目标、根位置和旋转差、身体位置与姿态，以及 10 帧本体感知和动作历史。

表 2a. 奖励项。 跟踪项使用式 (5) 的高斯核，其余项为普通惩罚。

奖励项	权重	σ
锚点位置	1.0	0.30
锚点姿态	0.5	0.40
相对身体位置	1.0	0.30
相对身体姿态	1.0	0.40
身体线速度	1.0	1.00
身体角速度	1.0	3.14
局部头部/手腕点	2.0	0.10
局部手腕姿态	2.0	0.30
局部双脚位置	1.0	0.15
动作变化率	-1e-1	-
关节限位	-10.0	-
非期望接触	-1e-1	-
防抖角速度	-5e-3	-
脚踝关节加速度	-2.5e-6	-

表 2b. 域随机化。“startup” 表示在场景构造时每个环境只随机一次，其余量按所列周期重采样。

随机量	范围	重采样
静摩擦系数	[0.3, 1.6]	startup
动摩擦系数	[0.3, 1.2]	startup
恢复系数	[0.0, 0.5]	startup
手腕/躯干质量	$\times[0.8, 2.5]$	startup
躯干质心 x	± 0.025 m	startup
躯干质心 y, z	± 0.05 m	startup
关节默认位置偏移	± 0.01 rad	startup
x,y 方向线速度推扰	± 0.5 m/s	4-6 s
z 方向线速度推扰	± 0.2 m/s	4-6 s
roll,pitch 角速度推扰	± 0.52 rad/s	4-6 s
yaw 角速度推扰	± 0.78 rad/s	4-6 s
手腕/躯干外力	± 5 N	2-5 s
手腕/躯干外力矩	± 0.3 N·m	2-5 s
根平移掩码	以 2/3 概率遮蔽	2-5 s
参考窗口噪声	± 0.05	每一步

4 实验

我们评估三个核心主张。第一，把跟踪器训练成行为世界模型，能否在保持强平地跟踪能力的同时，获得地形能力，并在从未训练过的指令下存活（第 4.2 节）。第二，自动地形标注是否足够准确，可以真正用于训练；由此得到的策略是否会主动与真实环境交互，而不只是“容忍”环境存在（第 4.3 节）。第三，分布外过滤器是否能把策略没有训练过的指令转换成仍可存活的行为，并且其精度代价是否可接受；同时，由于安全半径可以运行时调节，这个代价应当是操作者可选择的，而不是设计时固定的（第 4.4 节）。本文版本先报告核心比较；更广泛的评估，包括真实机器人延迟测量和组件消融，将在未来补充。

4.1 实验设置

基准与指标。 我们在四个留出测试集上评估，每个测试集针对一种不同失败模式。

- **Standard:** AMASS [24] 测试划分，用于普通平地跟踪，共 136 段动作。

- **OOD**: MotionMillion [12] 的测试子集, 包含物理上不合理的参考动作, 例如自穿透、重定向伪影, 以及该形态人形机器人根本无法执行的动作, 用于评估输入指令偏离训练分布时控制器会如何处理, 共 136 段。
- **Terrain**: Bones-Seed [4] 的测试子集, 动作需要穿越或交互地形, 并在评估时加载自动标注几何, 共 150 段。
- **Fall**: 复用 136 段 Standard 动作, 但机器人从摔倒姿态初始化。

SR (成功率) 采用相对参考动作偏差判据, 在普通测试中摔倒始终算作失败。即使发生失败, rollout 也不会提前结束: 每段动作都会播放到末尾, 误差指标在完整参考时段上累计, 因此策略无法通过提前终止难以处理的动作来人为减小误差。Fall 是唯一例外: 机器人一开始就在地面上, 如果把“处于倒地状态”本身直接算失败, 那么所有 episode 开始前就已经失败。因此 Fall 测试允许机器人倒地; 一旦机器人重新站起并恢复跟踪参考, 就算成功。Fall SR 实际上是恢复率, 不能与其他三个 SR 直接比较。

MPKPE 是所有被跟踪连杆上的平均关键点位置误差, 单位 mm; RootPos 和 RootVel 分别表示根位置和线速度跟踪误差, 单位为 mm 和 mm/s; Jerk 是关节 jerk 平均幅值, 单位 rad/s^3 。

并不是每个测试划分都由同一组指标决定, 在所有场景都报告全部指标反而会掩盖真正重要的数字。Standard 中对根节点使用速度误差评分, 而 Terrain 中使用位置误差, 原因与第 3.2 节根平移块被掩码相同: 平地上根节点绝对位置没有明确场景意义, 主要关心速度轮廓; 但在地形上, 即使几厘米绝对漂移, 也可能让脚撞上参考动作没有预期的几何。OOD 中的参考本来就被构造为不可执行, 因此“精确跟踪它”并不是目标, 对一个不可能轨迹计算根速度误差也没有可解释性; 真正重要的是机器人能否在不应被给出的指令下保持不倒, 其次是执行动作仍与原意相差多少, 因此只报告 SR 和 MPKPE。Fall 中则关注策略能否起身, 以及起身过程是否过于剧烈——真实硬件无法容忍激进起身产生的扭矩尖峰——因此报告恢复率与关节 jerk, 后者决定一次恢复能否真正部署, 而不只是能否在仿真中成功。

基线与协议。我们与 SONIC [23]、HoloMotion-1 [5] 和 Humanoid-GPT [30] 比较, 它们是公开描述中最强的三种大规模全身运动跟踪器。所有策略, 包括本文方法, 都在 MuJoCo [34] 中进行 sim-to-sim 评估, 使用相同失败标准和相同完整时长 rollout, 因此没有方法能够因为“在自己训练所用仿真器中评估”而获益。评估时, 不给任何策略提供真实硬件上无法获得的信号: 第 3.2 节中的参考根平移块对应机器人真实根位置, 而真实 G1 不测量该量, 因此整个评估中始终被掩码; 它只在训练中以 1/3 概率出现。

由于基线使用不同的数据语料与重定向流程, 这种比较主要用于说明泛化能力以及环境感知训练带来的影响, 而不是严格的数据匹配消融。GigaBrain-WBC-0.5 按照真实部署状态进行评估, 即启用第 3.4 节过滤器并取 $R_{safe}=3$ 。该过滤器是控制器的一部分, 而不是外接包装器, 因此本文报告的就是实际发布系统, 而不是一个部署时不会使用的“无过滤”变体。

表 3a. MuJoCo sim-to-sim 对比: Standard 与 Terrain。 MPKPE、RootPos 单位 mm; RootVel 单位 mm/s; SR 单位 %。

方法	Standard MPKPE↓	Standard RootVel↓	Standard SR↑	Terrain MPKPE↓	Terrain RootPos↓	Terrain SR↑
SONIC [23]	82.3	189.6	94.1	331.2	294.7	15.3
HoloMotion-	109.4	121.3	89.0	330.0	280.7	18.7

方法	Standard MPKPE↓	Standard RootVel↓	Standard SR↑	Terrain MPKPE↓	Terrain RootPos↓	Terrain SR↑
1 [5]						
Humanoid-GPT [30]	90.9	205.8	91.9	283.3	326.7	14.0
GigaBrain-WBC-0.5 (本文)	76.6	211.1	96.3	93.3	100.7	81.3

表 3b. MuJoCo sim-to-sim 对比：OOD 与 Fall。 Jerk 单位 rad/s^3 。Fall 的 SR↑ 使用恢复判据：允许摔倒，只要机器人能够重新恢复到参考跟踪就算成功；其他 SR 中摔倒都算失败。本文方法全程使用部署设置 $R_{safe}=3$ 。

方法	OOD MPKPE↓	OOD SR↑	Fall SR↑↑	Fall Jerk↓
SONIC [23]	327.6	50.0	5.9	1295.5
HoloMotion-1 [5]	248.7	67.7	0.7	2000.0
Humanoid-GPT [30]	208.0	70.6	2.9	3598.1
GigaBrain-WBC-0.5 (本文)	158.0	83.1	99.3	1050.6

4.2 不同情形下的运动跟踪

表 3 给出了四种策略在第 4.1 节四类测试集上的结果。Standard 场景中，把跟踪器训练成行为世界模型没有牺牲自由空间能力：本文方法 MPKPE 为 76.6 mm、SR 为 96.3%，在四种方法中同时具有最高精度和最高可靠性，甚至在基线最擅长的纯平地情形下也领先 SONIC（82.3 mm、94.1%）。本文唯一没有领先的指标是根线速度误差（211.1 mm/s，而 HoloMotion-1 为 121.3 mm/s）。我们把这一现象归因于第 3.2 节的间歇式根平移掩码：一个三分之二时间都必须在没有绝对根反馈情况下运行的策略，会通过小幅重新锚定修正位置，而不是连续精确匹配参考速度轮廓。这是为了让控制器能够被不提供全局位置的上游指令源驱动所付出的代价，但并没有反映到关键点跟踪精度上。

Terrain 测试中，环境感知训练的优势变得非常明显。三个基线的 SR 都下降到 14%-19%，MPKPE 达到 283-331 mm——因为它们从未经历过除地面以外的接触，会把台阶或座椅当成需要抵抗的扰动，而不是可以承载力的支撑面，于是参考动作与实际执行几帧内就会分离。本文策略在地形上仍保持 81.3% SR 和 93.3 mm MPKPE，相比最强基线，存活率提高 4.3 倍，跟踪误差降低约 3 倍。更有解释力的是与自身平地结果比较：从平地到地形，本文 MPKPE 仅增加 22%（76.6 $\rightarrow$ 93.3 mm），而基线误差增加到原来的 3-4 倍。也就是说，地形对本文策略来说是一种“训练过的工作模式”，而对基线来说则是分布外事件。

后两个测试集考察当指令或初始状态本身就是策略没有训练过的情况。OOD 中，每条参考都在物理上不可执行，GigaBrain-WBC-0.5 仍能在 83.1% 的动作中保持成功，而基线为 50.0%-70.6%；同时本文执行动作与原意的偏差最小（158.0 mm，而最好基线为 208.0 mm）。这说明过滤器没有简单丢弃指令，而是把它回缩到策略能够执行、同时最接近原意的行为。Fall 场景的差距不是渐进式，而是质变：基线只能从 0.7%-5.9% 的摔倒初始化中恢复，本文达到 99.3%。基线的 jerk 为 1295-3598 rad/s^3 ，更多反映的是倒地后的挣扎，而不是真正恢复的代价；本文不仅成功率最高，而且 jerk 最低，为 1050.6 rad/s^3 ，这也是作者愿意把该行为真正运行到硬件上的原因。

4.3 环境交互

第 3.3 节的标注流程是无监督的，因此在用于训练前必须对输出进行审计。该审计必须由人完成：自动检查能够捕获的错误——尤其是几何原语与身体相交——正是穿透过滤器本身已经排除的错误，因此自动规则不能再拿来做自身评测。剩下需要判断的是：阅读动作本身的意图，判断该意图所隐含的接触是否物理合理，并检查动作与地形放在一起时是否像一个人真的会做出的动作。


三个源数据集的重定向质量不同，Bones-Seed [4] 是其中最干净的一套——只有少部分手部动作重定向较差——因此在它上面做审计可以更好隔离“地形标注流程本身产生的错误”，而不是上游重定向噪声。我们因此选择 Bones-Seed 进行审计：对于表 4 的四类地形，各随机采样 50 段已标注动作，由人工判断重建的几何原语是否与动作一致——即机器人所依赖的每个支撑是否都位于正确位置和方向，并且不会与身体相交，从而让动作在该标注场景下看起来物理可行。

表 4. 自动地形标注的人工审计。 一段动作只有在其依赖的所有支撑都被正确位置和方向恢复，且没有引入伪几何原语时，才算正确。

地形类别	抽样数	正确率	主要失败模式
楼梯/台阶	50	92%	落脚过快，使减速度特征不明显
椅子/座椅	50	94%	躯干摆动导致靠背接触位置偏移
箱体/平台	50	98%	接触过稀，无法形成几何原语
其他	50	84%	手部重定向噪声掩盖速度下降
总体	200	92%	-

四类地形总体标注可靠率为 92%。箱体和平台最容易，正确率 98%：踩上抬高表面会产生持续时间长且减速度明显的接触，少数失败通常是接触太短，没能积累出拟合原语所需的点。阶梯踏面（92%）和座椅（94%）的错误主要因为脚或躯干移动太快，使减速度特征变模糊，从而导致踏面或靠背缺失或偏移。“其他”类别最弱，为 84%，主要原因并不完全来自标注流程：这一类大量由手部支撑动作构成，而手腕重定向误差恰好会扰动接触检测所依赖的速度信号。

所有失败类型仍然是保守的，因为穿透过滤器只会删除候选几何，不会主动增加几何。因此错误最多是让某个支撑缺失或位置不准，而不会凭空产生一个机器人将撞上的障碍。无论如何，这些人工审计发现的失败样本都会在训练前从数据集中移除（第 3.5 节）。



原文图5：真实硬件环境交互

图 5. 硬件环境交互。 (a)-(d) 为匹配硬件对比：左侧是 SONIC [23]，右侧是 GigaBrain-WBC-0.5，两者同时接收同一操作者指令。(a) 本文策略把箱体作为座椅承重，而 SONIC 停留在半蹲状态。(b) 本文策略踩上平台并稳定，SONIC 无法完成攀上平台。(c) 本文策略举起并稳定保持箱体，而 SONIC 无法保持稳定抓持。(d) 本文策略通过跪姿到站立的过渡举起 2 kg 灭火器，而 SONIC 在起身过程中摔倒。(e) 本文策略搬运一个大型箱体，向前走上平台后再下到地面。

表 3 的 Terrain 结果已经表明，使用自动标注几何进行训练在仿真中确实有效；图 5 展示了同一个策略在真实硬件上的表现，此时场景是真实的，并且控制器事先没有得到任何场景模型。为了在受控输入下评估相对于强全身跟踪器的优势，图 5(a)-(d) 使用同一操作者的同一实时指令，对 GigaBrain-WBC-0.5 和 SONIC 进行比较。

差异非常具有诊断意义：当接触从平地转移到座椅或台阶时，SONIC 仍表现得像一个只在自由空间训练的跟踪器，无法建立承重支撑；而 GigaBrain-WBC-0.5 会利用产生的环境接触完成目标动作。举箱和灭火器实验进一步表明，这种优势能够扩展到在上半身负载变化时，持续维持接触力并保持平衡。最显著的是图 5(e)，它同时结合两类困难：机器人一边搬运长黑色箱体，一边向前走上平台，再继续走下到地面，全程没有掉落物体。这些硬件结果提供了定性证据，说明地形配对训练带来的是通用交互能力，而不是一组按场景脚本化的特定技能。

4.4 鲁棒性

表 3 的 OOD 列使用部署设置 $R_{safe}=3$ ；图 6 给出了这个设置所来自的权衡前沿。由于过滤器无状态，而且 R_{safe} 是运行时读取的参数，而不是训练时固定的常量，因此这条曲线并不是只能在设计阶段选一次：操作者可以在机器人运行过程中只调一个标量，就沿着这条曲线移动——环境更苛刻时加大过滤力度，精度更重要时则放宽过滤。

一个从不介入的过滤器没有意义，而一个始终介入的过滤器又会破坏精度。扫描第 3.4 节中的唯一参数 R_{safe} ，就得到“面对未训练指令时的生存能力”和“面对正常训练分布指令时的跟踪保真度”之间的可实现前沿。部署半径 $R_{safe}=3$ 位于曲线拐点：相对于完全不过滤的极限（虚线），收紧到该半径可用

12.7 mm Standard MPKPE 的代价换取 2.9 个百分点的 OOD 成功率；继续收紧到 $R_{safe}=1$ ，还能再增加 2.2 个百分点，但需要再付出 46.7 mm MPKPE。





Figure 6. Robustness versus precision as a function of the safety radius. Standard-split MPKPE (in-distribution fidelity) and OOD success rate against the single filter parameter R_{safe} . Small R_{safe} shrinks the admissible ellipsoid and projects more aggressively, buying OOD survival at the cost of in-distribution tracking; large R_{safe} approaches the unfiltered policy (dashed). The circled radius $R_{safe} = 3$ is the operating point reported in Table 3.



原文图6-7：精度-鲁棒性前沿和异常指令/物理扰动示例


图 6. 安全半径函数下的鲁棒性-精度权衡。 图中同时绘制 Standard 测试 MPKPE（分布内跟踪保真度）与 OOD 成功率，横轴为唯一过滤参数 R_{safe} 。较小的 R_{safe} 会缩小可接受椭球并更积极地投影指令，以牺牲分布内跟踪性能换取更高 OOD 生存率；较大的 R_{safe} 则逐渐接近无过滤策略（虚线）。圈出的 $R_{safe}=3$ 是表 3 使用的工作点。

图 7. 对不安全指令和物理扰动的鲁棒性。 (a,b) 移除椅子或平台后，原始指令失效，但策略没有急停，而是收敛到稳定的 best-effort 行为；如果急停，正在搬运的物体反而会掉落。(c) 同一个跟踪策略在被踢倒后，无需独立恢复控制器就能自行站起。(d,e) 在仿真中给定相同的、具有自干涉且难度较高的旋转踢参考动作，关闭安全过滤器时机器人会尝试完成踢腿并摔倒（之后仍可恢复）；打开过滤器后，策略保留了参考中的转身意图，抑制困难踢腿，并保持站立。

图 7 给出了对应的定性结果。硬件实验说明，要让跟踪器始终保持可驱动，需要两种互补能力：失败发生前主动适应，以及失败发生后恢复。在失败前，如果原本预期存在的环境支撑突然缺失，参考动作无法按原样实现；图 7(a,b) 中，策略不会真的向不存在的接触点提交动作，而是产生稳定的 best-effort 响应。失败之后，图 7(c) 表明同一个跟踪器能够自行站起并恢复控制，无需把任务交给专用恢复模式。

仿真比较还展示了另一种“失败前机制”，这次发生在指令空间中：对于同一段高度动态、存在自干涉的旋转踢参考，关闭过滤器时机器人会执行该踢腿并摔倒，随后再恢复；启用过滤器则在保留指令中转身意图的同时避免摔倒，以 best-effort 方式完成。这个提前修正直接来自世界模型：上一时刻输出的混合分布定义一个条件马氏椭圆，并把分布外潜变量回缩到其边界，从而在执行前过滤偏离已学习条件行为的不安全指令。

4.5 全身运动能力



原文图8：敏捷动作、家庭任务和工业任务

图 8. 全身运动能力。 同一个实时全身指令跟踪策略完成敏捷运动、家庭任务和工业任务。每帧标注对应机器人：控制器直接运行在 Unitree G1 上；经过第 3.5 节微调后，也运行在 Maker L01 上。

图 8 汇总了控制器在上述核心测试之外的能力。使用同一个实时全身指令接口，策略能够跟踪高难动作，包括深蹲跳、高踢腿和低重心太极姿态。相同跟踪器还能在实时指令下完成家庭与工业行为，在不切换到任务专用操作栈的情况下协调移动与物体交互。对 G1 checkpoint 微调后，部分家庭与物流实验运行在 Maker L01 上，表明该控制器并不绑定于单一机器人本体。

5 结论

本文提出 GigaBrain-WBC-0.5，一个用于人形机器人全身控制的行为世界模型。其基本出发点是：现有全身跟踪器缺少的两种能力——**与环境交互**，以及在**被要求执行环境不允许的动作时仍保持良好行为**——其实是同一能力的两个侧面，而两者都可以通过让控制器预测自身未来，而不是只输出下一动作来获得。

围绕这一思想，我们构建了一个自动流程，可以从普通重定向动作中恢复空间接触几何；同时提出无状态、闭式的一步投影方法，把模型自身预测的指令分布转化成只由一个标量半径控制的在线 OOD 过滤器。

在 sim-to-sim 评估中，与三个大规模跟踪器基线相比，最终策略在四类测试场景中都取得最高成功率。地形交互达到 81.3%（是最强基线的 4.3 倍），在物理上不合理的 OOD 指令下达到 83.1%，从摔倒初始化中恢复则从基线的个位数水平提升到 99.3%。在真实硬件上，策略本身能够跟踪敏捷动作、与真实环境交互，并对支撑缺失和物理扰动保持鲁棒。当某个指令在当前环境条件下不可执行时，它会收敛到稳定的 best-effort 响应；在仿真中，其未来预测过滤器同样会在执行前把偏离已学习行为的指令回缩。如果最终仍发生摔倒，同一个策略可以自行站起并恢复控制，而不需要独立恢复控制器。进一步微调还可以把 G1 checkpoint 迁移到 Maker L01，用于家庭和物流任务。

据我们所知，本文首次把行为世界模型引入人形机器人全身控制，为同时结合环境交互和鲁棒执行的控制器提供了一个有前景的新方向。

不过仍存在若干限制。过滤器主要在仿真中得到验证，在真正依赖其硬件安全性之前，需要针对不同 checkpoint 和机器人平台重新标定安全半径；它识别的是“与策略训练经验不同的指令”，而不是直接推理物理风险，因此对不可行指令的拦截是高概率的，而非必然保证。地形标注来自接触证据，因此只能恢复动作真正接触过的几何：场景中存在但没有被使用的表面不会被重建，最终场景更像是“支撑集合”，而不是完整环境。未来自然的方向包括把重建扩展到非支撑几何，以及把世界模型的状态预测连接到更直接的物理风险定义。

参考文献（按原文保留）

- [1] Qingwei Ben, Feiyu Jia, Jia Zeng, Junting Dong, Dahua Lin, and Jiangmiao Pang. HOMIE: Humanoid Loco-Manipulation with Isomorphic Exoskeleton Cockpit. arXiv preprint arXiv:2502.13013, 2025.
- [2] Qingwei Ben, Botian Xu, Kailin Li, Feiyu Jia, Wentao Zhang, Jingping Wang, Jingbo Wang, Dahua Lin, and Jiangmiao Pang. GALLANT: Voxel Grid-Based Humanoid Locomotion and Local-Navigation across 3D Constrained Terrains. arXiv preprint arXiv:2511.14625, 2025.
- [3] Johan Bjorck, Fernando Castaneda, Nikita Cherniadev, Xingye Da, Runyu Ding, Linxi Fan, Yu Fang, Dieter Fox, Fengyuan Hu, Spencer Huang, et al. GR00T N1: An Open Foundation Model for Generalist Humanoid Robots. arXiv preprint arXiv:2503.14734, 2025.
- [4] Bones Studio. Bones-Seed: A large-scale human motion capture dataset, 2026. <https://huggingface.co/datasets/bones-studio/seed>.
- [5] Maiyue Chen, Kaihui Wang, Bo Zhang, Xihan Ma, Zhiyuan Yang, Yi Ren, Qijun Huang, Zihao Zhu, Yucheng Wang, and Zhizhong Su. HoloMotion-1 Technical Report. arXiv preprint arXiv:2605.15336, 2026.
- [6] Sirui Chen, Zi-ang Cao, Zhengyi Luo, Fernando Castaneda, Chenran Li, Tingwu Wang, Ye Yuan, Linxi Fan, C Karen Liu, Yuke Zhu, et al. CHIP: Adaptive Compliance for Humanoid Control through Hindsight Perturbation. arXiv preprint arXiv:2512.14689, 2025.
- [7] Sirui Chen, Shibo Zhao, Zhen Wu, Jiaman Li, Guanya Shi, and C. Karen Liu. SceneBot: Contact-Prompted General Humanoid Whole Body Tracking with Scene-Interaction. arXiv preprint arXiv:2606.27581, 2026.
- [8] Zixuan Chen, Mazeyu Ji, Xuxin Cheng, Xuanbin Peng, Xue Bin Peng, and Xiaolong Wang. GMT: General Motion Tracking for Humanoid Whole-Body Control. arXiv preprint arXiv:2506.14770, 2025.
- [9] Ziyang Cheng, Haoyu Wei, Hang Yin, Xiuwei Xu, Bingyao Yu, Jie Zhou, and Jiwen Lu. CMP: Robust Whole-Body Tracking for Loco-Manipulation via Competence Manifold Projection. arXiv preprint arXiv:2604.07457, 2026.
- [10] ChingMu. MotionDecode: Chingmu 1000-hour embodied motion dataset, 2026. <https://huggingface.co/datasets/CMRobot/MotionDecode>.
- [11] Robin Deits and Russ Tedrake. Footstep Planning on Uneven Terrain with Mixed-Integer Convex Optimization. In IEEE-RAS International Conference on Humanoid Robots, pages 279-286. IEEE, 2014.
- [12] Ke Fan, Shunlin Lu, Minyue Dai, Runyi Yu, Lixing Xiao, Zhiyang Dou, Junting Dong, Lizhuang Ma, and Jingbo Wang. Go to Zero: Towards Zero-Shot Motion Generation with Million-Scale Data. In Proceedings of the IEEE/CVF International Conference on Computer Vision, pages 13336-13348, 2025.
- [13] Jinrui Han, Weiji Xie, Jiakun Zheng, Jiayuan Shi, Weinan Zhang, Ting Xiao, and Chenjia Bai. KungfuBot2: Learning Versatile Motion Skills for Humanoid Whole-Body Control. arXiv preprint arXiv:2509.16638, 2025.
- [14] Tairan He, Zhengyi Luo, Xialin He, Wenli Xiao, Chong Zhang, Weinan Zhang, Kris Kitani, Changliu Liu, and Guanya Shi. OmniH2O: Universal and Dexterous Human-to-Humanoid Whole-Body Teleoperation and Learning. arXiv preprint arXiv:2406.08858, 2024.
- [15] Tairan He, Jiawei Gao, Wenli Xiao, Yuanhang Zhang, Zi Wang, Jiashun Wang, Zhengyi Luo, Guanqi He, Nikhil Sobanbab, Chaoyi Pan, et al. ASAP: Aligning Simulation and Real-World Physics for Learning Agile Humanoid Whole-Body Skills. arXiv preprint arXiv:2502.01143, 2025.
- [16] Tairan He, Wenli Xiao, Toru Lin, Zhengyi Luo, Zhenjia Xu, Zhenyu Jiang, Jan Kautz, Changliu Liu, Guanya Shi, Xiaolong Wang, et al. HOVER: Versatile Neural Whole-Body Controller for Humanoid Robots. In 2025 IEEE International Conference on Robotics and Automation (ICRA), pages 9989-9996. IEEE, 2025.
- [17] Tao Huang, Junli Ren, Huayi Wang, Zirui Wang, Qingwei Ben, Muning Wen, Xiao Chen, Jianan Li, and Jiangmiao Pang. Learning Humanoid Standing-up Control across Diverse Postures. arXiv preprint arXiv:2502.08378, 2025.
- [18] Yifeng Jiang, Yuting Ye, Deepak Gopinath, Jungdam Won, Alexander W. Winkler, and C. Karen Liu. Transformer Inertial Poser: Real-Time Human Motion Reconstruction from Sparse IMUs with Simultaneous Terrain Generation. In SIGGRAPH Asia Conference Papers, pages 1-9, 2022.

- [19] Scott Kuindersma, Robin Deits, Maurice Fallon, Andres Valenzuela, Hongkai Dai, Frank Permenter, Twan Koolen, Pat Marion, and Russ Tedrake. Optimization-Based Locomotion Planning, Estimation, and Control Design for the Atlas Humanoid Robot. *Autonomous Robots*, 40(3):429-455, 2016.
- [20] Yitang Li, Zhengyi Luo, Tonghe Zhang, Cunxi Dai, Anssi Kanervisto, Andrea Tirinzoni, Haoyang Weng, Kris Kitani, Mateusz Guzek, Ahmed Touati, Alessandro Lazaric, Matteo Pirota, and Guanya Shi. BFM-Zero: A Promptable Behavioral Foundation Model for Humanoid Control Using Unsupervised Reinforcement Learning. *arXiv preprint arXiv:2511.04131*, 2025.
- [21] Qiayuan Liao, Takara E Truong, Xiaoyu Huang, Guy Tevet, Koushil Sreenath, and C Karen Liu. BeyondMimic: From Motion Tracking to Versatile Humanoid Control via Guided Diffusion. *arXiv preprint arXiv:2508.08241*, 2025.
- [22] Zhengyi Luo, Jinkun Cao, Josh Merel, Alexander Winkler, Jing Huang, Kris Kitani, and Weipeng Xu. Universal Humanoid Motion Representations for Physics-Based Control. *arXiv preprint arXiv:2310.04582*, 2023.
- [23] Zhengyi Luo, Ye Yuan, Tingwu Wang, Chenran Li, Sirui Chen, Fernando Castaneda, Zi-Ang Cao, Jiefeng Li, David Minor, Qingwei Ben, et al. SONIC: Supersizing Motion Tracking for Natural Humanoid Whole-Body Control. *arXiv preprint arXiv:2511.07820*, 2025.
- [24] Naureen Mahmood, Nima Ghorbani, Nikolaus F. Troje, Gerard Pons-Moll, and Michael J. Black. AMASS: Archive of Motion Capture As Surface Shapes. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2019.
- [25] Ziyu Meng, Tengyu Liu, Le Ma, Yingying Wu, Ran Song, Wei Zhang, and Siyuan Huang. SafeFall: Learning Protective Control for Humanoid Robots. *arXiv preprint arXiv:2511.18509*, 2025.
- [26] Fabian Mentzer, David Minnen, Eirikur Agustsson, and Michael Tschannen. Finite Scalar Quantization: VQ-VAE Made Simple. *arXiv preprint arXiv:2309.15505*, 2023.
- [27] Mayank Mittal, Pascal Roth, James Tighe, Antoine Richard, Octi Zhang, Peter Du, Nikita Rudin, et al. Isaac Lab: A GPU-Accelerated Simulation Framework for Multi-Modal Robot Learning, 2025.
- [28] Xue Bin Peng, Pieter Abbeel, Sergey Levine, and Michiel Van de Panne. DeepMimic: Example-Guided Deep Reinforcement Learning of Physics-Based Character Skills. *ACM Transactions on Graphics*, 37(4):1-14, 2018.
- [29] Xue Bin Peng, Ze Ma, Pieter Abbeel, Sergey Levine, and Angjoo Kanazawa. AMP: Adversarial Motion Priors for Stylized Physics-Based Character Control. *ACM Transactions on Graphics*, 40(4), 2021.
- [30] Zekun Qi, Xuchuan Chen, Dairu Liu, Chenghuai Lin, Yunrui Lian, Sikai Liang, Zhikai Zhang, Yu Guan, Jilong Wang, Wen Yao Zhang, Xinqiang Yu, He Wang, and Li Yi. Humanoid-GPT: Scaling Data and Structure for Zero-Shot Motion Tracking. *arXiv preprint arXiv:2606.03985*, 2026.
- [31] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal Policy Optimization Algorithms. *arXiv preprint arXiv:1707.06347*, 2017.
- [32] Jianlin Su, Murtadha Ahmed, Yu Lu, Shengfeng Pan, Wen Bo, and Yunfeng Liu. RoFormer: Enhanced Transformer with Rotary Position Embedding. *Neurocomputing*, 568:127063, 2024.
- [33] Chen Tessler, Yunrong Guo, Ofir Nabati, Gal Chechik, and Xue Bin Peng. MaskedMimic: Unified Physics-Based Character Control Through Masked Motion Inpainting. *ACM Transactions on Graphics*, 43(6):1-21, 2024.
- [34] Emanuel Todorov, Tom Erez, and Yuval Tassa. MuJoCo: A Physics Engine for Model-Based Control. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 5026-5033. IEEE, 2012.
- [35] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention Is All You Need. *Advances in Neural Information Processing Systems*, 30, 2017.
- [36] Yunshen Wang, Shaohang Zhu, Peiyuan Zhi, Yuhan Li, Jiaxin Li, Yong-Lu Li, Yuchen Xiao, Xingxing Wang, Baoxiong Jia, and Siyuan Huang. OmniXtreme: Breaking the Generality Barrier in High-Dynamic Humanoid Control. *arXiv preprint arXiv:2602.23843*, 2026.
- [37] Yuxuan Wang, Ming Yang, Weishuai Zeng, Yu Zhang, Xinrun Xu, Haobin Jiang, Ziluo Ding, and Zongqing Lu. From Experts to a Generalist: Toward General Whole-Body Control for Humanoid Robots. *arXiv preprint arXiv:2506.12779*, 2025.
- [38] Haoyang Weng, Yitang Li, Nikhil Sobanbabu, Zihan Wang, Zhengyi Luo, Tairan He, Deva Ramanan, and Guanya Shi. HDMI: Learning Interactive Humanoid Whole-Body Control from Human Videos. *arXiv preprint arXiv:2509.16757*, 2025.

- [39] Zhen Wu, Xiaoyu Huang, Lujie Yang, Yuanhang Zhang, Koushil Sreenath, Xi Chen, Pieter Abbeel, Rocky Duan, Angjoo Kanazawa, Carmelo Sferrazza, et al. Perceptive Humanoid Parkour: Chaining Dynamic Human Skills via Motion Matching. arXiv preprint arXiv:2602.15827, 2026.
- [40] Michael Xu, Yi Shi, KangKang Yin, and Xue Bin Peng. PARC: Physics-Based Augmentation with Reinforcement Learning for Character Controllers. In SIGGRAPH Conference Papers, pages 1-11, 2025.
- [41] Lujie Yang, Xiaoyu Huang, Zhen Wu, Angjoo Kanazawa, Pieter Abbeel, Carmelo Sferrazza, C Karen Liu, Rocky Duan, and Guanya Shi. OmniRetarget: Interaction-Preserving Data Generation for Humanoid Whole-Body Loco-Manipulation and Scene Interaction. arXiv preprint arXiv:2509.26633, 2025.
- [42] Kangning Yin, Weishuai Zeng, Ke Fan, Minyue Dai, Zirui Wang, Qiang Zhang, Zheng Tian, Jingbo Wang, Jiangmiao Pang, and Weinan Zhang. UniTracker: Learning Universal Whole-Body Motion Tracker for Humanoid Robots. arXiv preprint arXiv:2507.07356, 2025.
- [43] Mingqi Yuan, Tao Yu, Wenqi Ge, Xiuyong Yao, Huijiang Wang, Jiayu Chen, Bo Li, Wei Zhang, Wenjun Zeng, Hua Chen, and Xin Jin. A Survey of Behavior Foundation Model: Next-Generation Whole-Body Control System of Humanoid Robots. arXiv preprint arXiv:2506.20487, 2025.
- [44] Yanjie Ze, Zixuan Chen, Joao Pedro Araujo, Zi ang Cao, Xue Bin Peng, Jiajun Wu, and C. Karen Liu. TWIST: Teleoperated Whole-Body Imitation System, 2025.
- [45] Yanjie Ze, Siheng Zhao, Weizhuo Wang, Angjoo Kanazawa, Rocky Duan, Pieter Abbeel, Guanya Shi, Jiajun Wu, and C Karen Liu. TWIST2: Scalable, Portable, and Holistic Humanoid Data Collection System. arXiv preprint arXiv:2511.02832, 2025.
- [46] Weishuai Zeng, Shunlin Lu, Kangning Yin, Xiaojie Niu, Minyue Dai, Jingbo Wang, and Jiangmiao Pang. Behavior Foundation Model for Humanoid Robots. arXiv preprint arXiv:2509.13780, 2025.
- [47] Chong Zhang, Wenli Xiao, Tairan He, and Guanya Shi. WoCoCo: Learning Whole-Body Humanoid Control with Sequential Contacts. arXiv preprint arXiv:2406.06005, 2024.
- [48] Chong Zhang, Victor Klemm, Fan Yang, and Marco Hutter. AME-2: Agile and Generalized Legged Locomotion via Attention-Based Neural Map Encoding. arXiv preprint arXiv:2601.08485, 2026.
- [49] Qiang Zhang, Jiahao Ma, Peiran Liu, Shuai Shi, Zeran Su, Zifan Wang, Jingkai Sun, Wei Cui, Jialin Yu, Gang Han, Wen Zhao, Pihai Sun, Kangning Yin, Jiaxu Wang, Jiahang Cao, Lingfeng Zhang, Hao Cheng, Xiaoshuai Hao, Yiding Ji, Junwei Liang, Jian Tang, Renjing Xu, and Yijie Guo. MeshMimic: Geometry-Aware Humanoid Motion Learning through 3D Scene Reconstruction. arXiv preprint arXiv:2602.15733, 2026.
- [50] Yuanhang Zhang, Younggyo Seo, Juyue Chen, Yifu Yuan, Koushil Sreenath, Pieter Abbeel, Carmelo Sferrazza, Karen Liu, Rocky Duan, and Guanya Shi. RPL: Learning Robust Humanoid Perceptive Locomotion on Challenging Terrains. arXiv preprint arXiv:2602.03002, 2026.
- [51] Zewei Zhang, Kehan Wen, Michael Xu, Junzhe He, Chenhao Li, Takahiro Miki, Clemens Schwarke, Chong Zhang, Xue Bin Peng, and Marco Hutter. Learning Whole-Body Humanoid Locomotion via Motion Generation and Motion Tracking. arXiv preprint arXiv:2604.17335, 2026.
- [52] Zhikai Zhang, Jun Guo, Chao Chen, Jilong Wang, Chenghuai Lin, Yunrui Lian, Han Xue, Zhenrong Wang, Maoqi Liu, Huaping Liu, et al. Track Any Motions under Any Disturbances. arXiv preprint arXiv:2509.13833, 2025.
- [53] Siheng Zhao, Yanjie Ze, Yue Wang, C Karen Liu, Pieter Abbeel, Guanya Shi, and Rocky Duan. ResMimic: From General Motion Tracking to Humanoid Whole-Body Loco-Manipulation via Residual Learning. arXiv preprint arXiv:2510.05070, 2025.
- [54] Shaoting Zhu, Ziwen Zhuang, Mengjie Zhao, Kun-Ying Lee, and Hang Zhao. Hiking in the Wild: A Scalable Perceptive Parkour Framework for Humanoids. arXiv preprint arXiv:2601.07718, 2026.