

HIL：面向动态运动控制的混合模仿学习

全文中文翻译、方法原理、网络框架图与机器人控制启示

原文：HIL: Hybrid Imitation Learning for Dynamic Athletic Control

Jiashun Wang 等, ACM Transactions on Graphics, 2026



Fig. 1. We propose a Hybrid Imitation Learning (HIL) framework that is able to train a unified controller to master a diverse range of parkour skills and execute agile life-like interactions with various obstacles. In this example, a physically simulated character employs five distinct parkour skills to successfully clear the obstacle course.

原论文图 1：统一控制器连续组合五种跑酷技能穿越障碍序列。

说明：正文部分按论文结构逐节翻译；“分析与解读”部分属于补充讲解，不是原文。

阅读导航

部分	内容
第一部分	论文核心信息与结论速览
第二部分	全文中文翻译：摘要、正文、实验、讨论与附录
第三部分	方法框架与图 2 逐模块详细讲解
第四部分	主要公式、奖励函数与训练流程解析
第五部分	方法优缺点、可复现要点及对 BUMI3 舞蹈控制的启示

术语约定

Motion Tracking 译为“动作跟踪”；Adversarial Imitation Learning 译为“对抗式模仿学习”；Style Reward 译为“风格奖励”；Goal Condition 译为“目标条件”；Mode Collapse 译为“模式坍塌”；Affordance 结合场景含义译为“可交互属性/可供性”。

第一部分 论文核心信息与结论速览

1. 论文要解决的核心矛盾

现有物理角色控制方法通常在“动作忠实度”和“任务适应性”之间二选一：逐帧动作跟踪能够高度复现参考动作，但面对参考数据中不存在的障碍布局、动作衔接和目标条件时不够灵活；对抗式模仿学习只匹配动作分布，允许策略偏离具体轨迹，却容易模式坍塌，只反复使用少数简单技能。HIL 的目标是让一个统一策略同时具备两种能力。

2. HIL 的五个关键设计

- 1. 并行的双训练模式：一半环境执行动作跟踪，另一半环境执行带任务目标的对抗式模仿学习。
- 2. 统一目标条件观测：两种模式都使用角色状态、场景信息和目标条件，不再依赖只在参考动作中存在的相位变量或未来目标姿态。
- 3. 共享统一策略：同一个策略在两类环境中更新，因此参考动作知识可以迁移到新场景。
- 4. 场景条件判别器：判别器不仅判断动作是否自然，还判断该动作是否适合当前障碍或场景。
- 5. 扰动状态初始化 PSI：在参考状态上加噪声，训练策略从偏离参考轨迹的状态恢复并衔接下一技能。

3. 最重要的实验结论

- 跑酷任务中，HIL 的技能准确率为 0.66、跟踪误差为 0.31，均优于所有对比方法；任务完成率为 0.74，虽不是最高，但在动作自然性与完成率之间取得最佳平衡。
- Warm Start 的 AMP 完成率可达 0.85，但严重依赖少数翻越动作，出现明显模式坍塌。
- 去掉判别器、PSI、判别器中的场景信息或 critic 的任务指示变量，都会显著降低性能。
- 任务条件跟踪器即使不输入未来姿态，也能在 heading 任务中学会有效跟踪，证明目标条件可以承担“隐式相位”的作用。

一句话理解 HIL

先用动作跟踪保证“会做且做得像”，再在训练过程中始终保留跟踪约束，同时用任务奖励和场景条件判别器训练“会变、会接、会适应”。

第二部分 全文中文翻译

论文题目与作者

题目：HIL：面向动态运动控制的混合模仿学习。

作者：Jiashun Wang（卡内基梅隆大学）、Yifeng Jiang（NVIDIA）、Haotian Zhang（NVIDIA）、Chen Tessler（NVIDIA）、Davis Rempe（NVIDIA）、Jessica Hodgins（卡内基梅隆大学）、Xue Bin Peng（西蒙菲莎大学与 NVIDIA）。

图 1 说明：本文提出一种混合模仿学习（HIL）框架，能够训练一个统一控制器掌握多样化跑酷技能，并与不同障碍物进行敏捷、逼真的交互。在图示例子中，物理仿真角色使用五种不同的跑酷技能成功穿越整个障碍路线。

摘要

利用深度强化学习的数据驱动方法，已经成为开发物理仿真角色控制器的主流范式，使角色能够产生自然、类人的行为。然而，这些数据驱动方法通常难以适应新环境，也难以组合多种技能来完成更复杂的环境交互任务。

为解决这些问题，本文提出混合模仿学习（Hybrid Imitation Learning, HIL）框架，将用于精确复现技能的动作跟踪，与用于增强适应性和技能组合能力的对抗式模仿学习结合起来，从而实现高度运动化行为的鲁棒动态控制。

该混合学习框架通过并行多任务环境和统一观测空间实现，并利用目标条件表示促进不同并行环境之间的知识共享。本文在跑酷式障碍穿越任务和朝向控制任务上验证了 HIL 的有效性。该框架训练出的统一控制器既能保持参考动作数据的自然性，又能有效泛化到具有挑战性的新环境。

在程序化生成任务和多种基线方法上的评估表明，与以往学习式方法相比，HIL 能够提高动作质量、增加技能多样性，并取得具有竞争力的任务完成率。论文结果最适合结合补充视频观看。

CCS 概念：计算机方法——动画。

关键词：基于物理的角色动画、对抗式模仿学习、强化学习。

1 引言

能够复现人类行为的物理仿真角色，在动画、虚拟现实和机器人领域具有广泛应用。这些应用可以从更高的物理真实感中获益：在虚拟环境中，真实感能够提升用户参与度；在机器人领域，真实感和物理一致性能改善任务表现。近年来，数据驱动的物理角色动画方法在生成跑步、拳击和网球等敏捷行为方面取得了显著进展。深度强化学习简化了控制结构的设计，使研究者更容易构建在视觉和功能上都具有真实感的仿真角色。

尽管近期方法展现出很大潜力，但仍有一个关键挑战：如何开发一个统一控制策略，使其能够携带多样化运动技能适应新的场景。动作跟踪技术可以精确复现大量运动技能，但往往缺乏将技能适配到新环境中的灵活性，例如难以重新排序、衔接和组合不同技能。相反，基于分布匹配的通用方法，如对抗式模仿学习，更容易修改和适配技能以应对新场景；但这类方法容易出现模式坍塌，产生不够自然且重复的行为。

这些问题在具有复杂场景交互的动态运动任务中尤其明显，例如跑酷。角色必须连续执行多个动态技巧，并根据环境障碍调整动作。在此类场景中，动作跟踪方法难以将技能泛化到参考轨迹之外；对抗式模仿学习则可能退化成重复的交互策略，忽略特定场景所提供的可交互属性。

为克服上述局限，本文提出一种简单但有效的混合模仿学习方法 HIL。HIL 在两种模式下联合训练同一个控制器：第一种是动作跟踪模式，用于精确复现不同跑酷技能；第二种是对抗式模仿学习模式，用于增强技能之间的平滑过渡，以及跨场景适应能力。

该混合框架通过并行多任务环境实现，两种模式共享统一观测空间。共享表示使从参考数据中学到的技能更容易迁移到目标驱动的新场景，同时缓解模式坍塌。因此，HIL 能够训练一个统一控制器，在新颖且具有挑战性的环境中组合多种运动技能，产生敏捷、逼真的行为。

对于跑酷这类缺乏“动作与场景几何严格对齐数据”的任务，本文从在线视频中获取参考动作片段；对于朝向控制这类更常见的任务，则使用已有动作捕捉数据集。作者在大量多样化的程序生成环境中系统评估模型，并与多种已有基线比较。结果显示，HIL 提高了动作质量，减轻了模式坍塌，并扩大了技能覆盖范围。

2 相关工作

数据驱动方法推动了角色动画的发展。若拥有完整动作数据集，动作图、动作匹配等运动学方法可以生成逼真动画，后续深度学习模型进一步提升了动作合成能力。然而，这些方法面对动态交互和未知场景时泛化有限，因此研究逐渐转向基于物理的方法。

基于物理的模型通过模拟力和动力学产生物理上合理的行为。借助参考动作片段，这些方法能够生成更逼真的角色运动，而如何使用参考动作一直是研究重点。

动作跟踪是常用方法，通常通过优化跟踪目标，使控制器紧密追随参考轨迹。但仅复现参考动作不足以适应新场景。可以使用运动学规划器合成或检索新参考，但在需要大量交互的新场景中，这些参考往往缺乏物理可行性。加入任务目标可以产生新行为，但逐帧跟踪奖励会限制策略为了完成任务而必须进行的偏离，因此削弱适应性。

对抗式模仿学习的引入是一个重要进展。AIL 通过判别器学习参考动作分布，提供风格模仿目标，鼓励生成自然动作。由于它匹配的是参考数据分布，而不是固定轨迹，因此允许策略偏离参考数据去完成更广泛的的目标，具有更好的任务适配能力。

近年来，分层方法在物理角色动画中取得显著进展。典型做法是两阶段训练：先训练低层控制器模仿大量参考动作，并用潜变量模型表示技能；随后训练高层控制器输出潜变量，引导低层控制器完成下游任务。然而，分层方法经常难以适应分布外场景，在需要灵活动态动作的环境中面临挑战。

MaskedMimic 等工作通过掩码条件和从动作跟踪教师策略蒸馏来学习统一策略，但训练条件仍来源于参考数据本身。与之不同，HIL 显式构建更一般的目标条件场景，并在保留动作跟踪训练的同时学习超出参考分布的适应能力。

角色—场景交互方面，早期工作通过动作图串联参考片段生成交互，但受限于原始采集场景。近期深度网络与扩散模型可以生成场景感知或文本条件的人体交互动作，但运动学方法无法保证交互的物理可行性。基于物理的控制方法通过动力学仿真提供更自然的交互。已有研究训练了座椅、跑酷等控制器，也使用对抗式模仿学习合成室内场景交互。

机器人领域已有多项地形穿越和跑酷工作，主要强调障碍的可通行性。本文的不同之处在于：使用一个统一控制器执行大量视觉上显著不同的跑酷技巧，形成高度多样、动态的角色—环境交互。

3 方法概述

本文提出 HIL 框架，目标是在新环境和新条件下同时提升虚拟角色的真实感与通用性。通过 HIL，可以训练一个统一控制器，在无缝适应未知场景的同时执行多样化运动行为。

动作跟踪模式保证控制器能够精确复现参考动作，从而保持参考数据的自然性；对抗式模仿学习模式则赋予控制器修改、衔接和组合这些技能的自由度，使其能够应对参考数据中未出现的条件。

为了在两种模式之间实现有效训练，作者设计了并行多任务环境。动作跟踪模式被实现为标准动作跟踪任务，对抗式模仿学习模式则采用 AMP。传统动作跟踪控制器通常需要时间相位或未来目标姿态作为输入，而对抗式模仿模式没有对应参考动作，因此无法获得这些输入。不同条件输入会阻碍两种模式共享同一个策略。

为此，本文提出统一的“条件驱动观测空间”，在两种模式中都以一致形式编码场景上下文和任务目标。在动作跟踪模式中，目标位置、朝向和场景几何等目标条件限定了可行动作集合，并隐式表明角色在参考动作中的进度；在对抗式模仿模式中，同一表示提供适应新环境所需的任务信息。共享条件机制使参考动作中学到的行为更有效地迁移到一般目标驱动场景。

4 预备知识：目标条件强化学习

本文所有控制器均使用目标条件强化学习（GCRL）训练。智能体与环境交互，以优化由任务目标条件决定的奖励函数。时间步 t 时，智能体观察环境状态 s_t 和目标描述 g_t ，并从策略 $\pi(a_t | s_t, g_t)$ 中采样动作 a_t 。执行动作后，环境按照动力学转移到新状态 s_{t+1} ，并得到奖励 $r_t = r(s_t, a_t, s_{t+1}, g_t)$ 。

学习目标是得到最大化期望折扣回报的策略：

$$J(\pi) = E_{\{p(\tau|\pi)\}} [\sum_{t=0}^{T-1} \gamma^t r_t] \quad (1)$$

式意：轨迹概率由初始状态分布、环境动力学和策略共同决定； T 为时间范围， $\gamma \in [0,1]$ 为折扣因子。

其中， $p(\tau|\pi)$ 表示在策略 π 下产生轨迹 τ 的概率， $p(s_0)$ 为初始状态分布。

5 混合模仿学习

HIL 结合两种训练模式：动作跟踪和对抗式模仿学习。作者观察到，单独使用任一技术都会产生次优结果，包括模式坍塌、动作质量下降，或无法适应场景变化。混合框架利用两者优势，使控制器既能复现数据集中的行为，又能把这些行为适配到新环境和新任务条件。

HIL 通过并行多任务环境实现。在动作跟踪模式中，控制器逐帧跟踪参考动作；在对抗式模仿模式中，控制器完成带目标条件的任务，例如穿越障碍或维持指定行进方向。后者将角色暴露于参考数据中未出现的目标和场景，以增强鲁棒性和适应性。两类任务并行训练，使模型既获得精确技能，又能泛化到新场景。

5.1 动作跟踪

以往动作跟踪系统通常使用时间相位或目标姿态。但为了让统一控制器适应多样场景，本文不能依赖这些输入，因为在没有参考数据的新环境中它们并不存在。统一观测空间会迫使控制器在动作跟踪和对抗式模仿两种模式下采用一致的条件机制。

因此，作者构造目标条件观测，以统一形式编码场景几何、目标位置和方向提示。实验发现，这种表示与角色状态结合后，已经足以让控制器隐式推断动作片段中的进度，即使没有显式目标姿态和相位变量，也能完成有效动作跟踪。

控制器输入角色状态 s_t 和目标条件 g_t ，输出动作 a_t 。训练使用标准动作跟踪目标，鼓励角色在每个时间步最小化当前状态与参考动作状态之间的差异：

$$r_t^{\text{track}} = w_p e^{-\alpha_p ||\hat{p}_t - p_t||} + w_r e^{-\alpha_r ||\hat{q}_t - q_t||} + w_v e^{-\alpha_v ||\hat{\dot{p}}_t - \dot{p}_t||} + w_\omega e^{-\alpha_\omega ||\hat{\dot{q}}_t - \dot{q}_t||} + w_h e^{-\alpha_h ||\hat{h}_t - h_t||} + w_e \sum_j ||\tau_j - \dot{q}_j|| \quad (2)$$

式意：奖励分别约束关节位置、关节旋转、线速度、角速度和根节点高度；最后一项为能耗惩罚，用于平滑动作并减少抖动。

式中， w 与 α 是用于平衡不同奖励项的权重和尺度。该奖励鼓励角色模仿参考动作指定的位置 $\hat{p}$ 、旋转 $\hat{q}$ 、线速度 $\hat{\dot{p}}$ 、角速度 $\hat{\dot{q}}$ 与根节点高度 $\hat{h}$ 。能量惩罚用于鼓励更平滑的动作并减轻抖动。

在混合训练中加入动作跟踪，可以推动控制器复现更广泛的参考行为。由于不同障碍对应不同参考动作，跟踪目标会鼓励策略根据任务条件采用不同交互模式。两种模式共享观测表示，也建立了一致的条件接口。

5.2 对抗式模仿学习

对抗式模仿学习模式用于增强控制器的适应能力，使其在参考数据中不存在的新条件和新场景下仍能产生自然行为。该模式的目标由任务奖励和风格奖励组成。

任务奖励采用目标条件形式，具体定义随任务而变化。例如，它可以鼓励角色向指定目标移动，或维持期望朝向。任务奖励提供任务层指导，使角色解决环境特定目标，而不是简单复制示范。

风格奖励来自判别器 $D(s_{t-n:t}, c_{t-n:t})$ 。判别器区分从参考数据集采样的“真实”数据与策略生成的“伪”数据。输入包括过去 n 步状态历史和场景条件，并判断这些状态转移来自参考动作数据集 M ，还是来自策略 π 。

将目标/场景条件加入判别器后，判别器不仅能评价动作本身是否自然，还能评价动作是否适合当前条件。判别器使用二分类损失训练，并加入梯度惩罚正则项：

$$\min_D -E_{\{d_M\}}[\log D(s_{t-n:t}, c_{t-n:t})] -E_{\{d_\pi\}}[\log(1-D(s_{t-n:t}, c_{t-n:t}))] + w_{gp} E_{\{d_M\}}[\|\nabla_\phi D(\phi)\|^2] \quad (3)$$

式意：前两项分别要求真实样本判为真、策略样本判为假；梯度惩罚稳定判别器训练。

与 AMP 类似，风格奖励定义为 $r_t^{\text{style}} = -\log(1-D(s_{t-n:t}, c_{t-n:t}))$ 。它鼓励策略生成更自然的动作，并为特定场景选择合适技能。

$$r_t = w^{\text{task}} r_t^{\text{task}} + w^{\text{style}} r_t^{\text{style}} \quad (4)$$

式意：对抗式模仿模式的最终奖励是任务奖励与风格奖励的加权和。

为了连接两种训练模式，动作跟踪模式中也把相同权重的风格奖励加入跟踪奖励。这样，判别器既约束新场景下动作的自然性，也成为两类任务之间的共享优化信号，推动控制器根据需要适配和组合数据集中的技能。

6 任务与系统设计

本文目标是得到一个统一控制器，它既能复现精确运动技能，又能把这些技能适配到多样化环境。除并行多任务环境外，系统还采用若干共享设计。

角色状态

仿真角色基于 SMPL 人体模型。状态 $s_t = (h_t, p_t, q_t, \dot{p}_t, \dot{q}_t)$ 描述角色身体构型：

- h_t ：根节点到地面的高度；
- p_t ：局部坐标系下各关节位置；
- q_t ：局部坐标系下各关节旋转；
- $\dot{p}_t$ ：局部坐标系下各关节线速度；
- $\dot{q}_t$ ：局部坐标系下各关节角速度。


骨盆被定义为根节点。角色局部坐标系原点位于根节点，x 轴沿根链接朝向，z 轴与全局竖直方向一致。

目标条件

为了建立适用于两种训练模式的统一观测空间，策略以任务特定目标变量 g_t 为条件。不同任务采用不同形式的 g_t 。

动作

仿真人形角色由比例—微分（PD）控制器驱动。策略 $\pi(a|s,g)=N(\mu_\pi(a|s,g),\Sigma_\pi)$ 为多维高斯分布；模型预测均值 μ_π ，协方差使用人工设定的固定标准差 $\sigma_\pi=0.055$ 。



原论文图 2：策略、价值网络（critic）和判别器的网络结构。

6.1 跑酷任务

跑酷任务聚焦敏捷场景交互与障碍穿越。

目标条件：观测包含以角色为中心的点云 c_t ，即场景中距离角色根节点最近的 N 个点，以及目标位置 l_t 。在动作跟踪模式中， l_t 从参考轨迹上未来 1~2 秒的根节点位置采样；在对抗式模仿模式中，以对应的未来根位置为中心，在即将到来的障碍附近采样目标，并加入 $N(0,0.2)$ 的高斯扰动。

任务奖励鼓励根位置 p_t^{root} 朝目标位置 l_t 移动：

$$r_t^{\text{task}} = w^{\text{prog}} (\|p_{t-1}^{\text{root}} - l_{t-1}\|_2 - \|p_t^{\text{root}} - l_t\|_2) + w^{\text{reach}} r_t^{\text{reach}} \quad (5)$$

式意：第一项奖励每一步朝目标缩短的距离；第二项是在到达目标时给予一次性奖励。

该形式鼓励角色稳定向目标推进，并奖励成功穿越障碍。

模型结构：跑酷策略采用 Transformer。PointNet 从最近 N 个场景点中提取特征，并将 N 个点编码为 N 个 token；两个 MLP 分别把角色状态和目标位置编码为 token；随后由 Transformer 融合多模态观测并输出动作分布。

策略使用 Transformer，而 critic 使用简单 MLP。由于混合训练中两种模式采用不同奖励结构，critic 额外接收二值任务指示变量 k 。该特权信息只提供给 critic，用于区分训练模式，不提供给策略。角色状态、点云、目标位置和任务指示被展平并拼接，critic 输出价值 V 。

判别器使用另一个 MLP，输入为展平拼接后的角色状态转移和场景点云，输出判别 logits D ，用于计算风格奖励。

数据集：跑酷训练需要同时包含人体动作和对应场景。由于跑酷动作捕捉数据稀缺，作者从在线视频中提取动作。首先用 TRAM 估计人体姿态，但 TRAM 在复杂跑酷动作中难以精确估计地面。作者利用身体朝向提示，根据图像平面中视角上方向与人体上方向的夹角估计三维身体上向量，从而修正人体相对地面的全局朝向。

为构建仿真场景，作者开发交互式场景标注工具，让标注者手动放置基本长方体几何，复现视频中的交互表面和可交互属性。

动作与场景标注仍存在人体穿透障碍、抖动和不自然滑移等问题，因此作者使用基于物理的动作跟踪器进一步优化。优化后的高质量动作被用于计算跟踪奖励、采样可靠的扰动状态初始化，也作为对抗运动先验的正样本。

作者从 YouTube 收集了 19 个带障碍参考片段，总时长约 30 秒，共包含 15 种技能，每个片段展示一种单独技能。训练时随机抽取五个障碍形成序列，用于目标跟随任务；动作跟踪任务则跟踪序列中的单个参考片段。

6.2 朝向控制任务

为展示框架的通用性，作者还将 HIL 应用于朝向任务，该任务关注运动方向和身体朝向控制。

目标条件采用 ASE 的形式：控制器输入目标行进方向 $\hat{d}_t$ 和目标面朝方向 $\hat{f}_t$ ，两者都是地面平面上的二维单位向量。目标是让角色沿 $\hat{d}_t$ 移动，同时使身体朝向与 $\hat{f}_t$ 对齐。

模型结构从跑酷任务简化而来，去掉 PointNet 和场景点云；策略与 critic 的目标位置输入被替换为目标行进方向和目标朝向特征。

奖励鼓励速度 v_t 在目标速度 v^* 下匹配目标方向，并使身体朝向 $\hat{q}_t$ 与目标面朝方向对齐：

$$r_t^{\text{heading}} = w^{\text{vel}} \exp[-\alpha(v^* - \hat{d}_t^T v_t)^2] + w^{\text{face}}(\hat{f}_t^T \hat{q}_t) \quad (6)$$

式意：第一项控制沿目标方向的速度投影，第二项用方向余弦控制身体朝向。

数据集使用 sword-and-shield 动作捕捉数据，约 7 分钟，规模与多样性都显著大于跑酷数据。数据自然包含向对手前进、后退、转身、移动时维持朝向等行为，适合学习方向与面朝控制。

6.3 扰动状态初始化与提前终止

参考状态初始化（RSI）能够显著提高动作跟踪训练效率，但直接从参考动作状态初始化有两个问题：一是对扰动的适应能力有限；二是技能衔接困难。例如技能 A 的结束状态若与技能 B 的起始状态差异较大，纯跟踪方法很难完成过渡。

为获得能够从更广泛初始状态执行技能的鲁棒控制器，作者使用扰动状态初始化（PSI）：对从参考动作采样的初始状态加入高斯噪声。该方法使控制器适应更大状态范围，也改善不同技能之间的转换。

实验上，PSI 提升了对抗模式的任务完成率并缓解模式坍塌。当技能转换难以学习时，强化学习策略往往采用一种“通用但简单”的动作处理各种障碍，只依赖少量技能。PSI 降低了技能转换难度，促使策略使用更广泛的技能。

提前终止（ET）在两种模式中采用不同规则。动作跟踪模式中，若任一关节位置与参考动作偏差超过 0.5 米，或跟踪完成，则终止回合。跑酷对抗模式中，若角色摔倒或偏离目标超过 2 米，则终止。朝向任务中，若头部高度低于 0.3 米，则终止。提前终止既提高样本效率，也抑制不良行为。

7 实验设置

所有环境使用 Isaac Gym 仿真。实验在 4 张 NVIDIA V100 上训练，仿真频率为 120 Hz，策略运行频率为 30 Hz。策略由 PyTorch 实现，使用 PPO 优化，并采用 GAE 估计优势函数。

训练分两阶段：首先只进行动作跟踪训练，共使用 40 亿样本；随后同时训练两种模式，共使用 20 亿样本，其中一半并行环境运行动作跟踪，另一半运行对抗式模仿学习。该策略让控制器先掌握单项技能，再学习把技能适配到多样化场景。

7.1 对比方法

方法	原文定义与主要局限
Task Reward	仅用 PPO 和任务奖励，不使用参考动作。能够穿越障碍，但往往产生不自然、不真实的行为。
Task Reward with Warm Start	从 HIL 使用的目标条件动作跟踪策略初始化，然后只用任务奖励继续训练。
AMP	使用判别器提供风格奖励，鼓励类人行为；由于训练中不保留动作跟踪，常出现模式坍塌。
AMP with Warm Start	从同一动作跟踪策略初始化，再只用对抗式模仿学习训练；相当于删除 HIL 的跟踪模式。

方法	原文定义与主要局限
ASE	从无结构动作数据学习可复用技能嵌入，但并非为场景条件控制设计，难以处理显式环境交互。
MaskedMimic	基于 CVAE 的蒸馏框架，由动作跟踪教师策略训练学生策略；由于师生都只在跟踪条件下训练，对参考分布外目标和未知技能过渡适应较弱。

图 4 说明：仅任务奖励的方法产生异常动作；AMP 常尝试绕过障碍；ASE 常停在障碍前；MaskedMimic 经常在第一次交互后摔倒；HIL 能以多样且自然的动作穿越长障碍序列。

图 5 说明：Warm Start 的 Task Reward 为尽快通关会产生不自然行为；去掉判别器的 HIL 难以为特定障碍选择合适技能；没有 Warm Start 的 AMP 严重模式坍塌；完整 HIL 生成更自然、与场景匹配且多样的行为。

图 6 说明：Task Reward 和 AMP 的技能使用频率明显偏向少数技能，而 HIL 的技能覆盖更广、更均衡。

7.2 评价指标

跑酷任务从自然性和任务表现两方面评价。自然性包括技能覆盖和动作质量。技能准确率判断控制器对每种障碍是否使用了正确技能；跟踪误差衡量生成动作与参考动作的偏差。

由于角色穿越障碍序列时，生成动作与参考动作并不同步，无法直接逐帧比较，因此采用动态时间规整（DTW）进行时间对齐。作者计算生成动作与所有参考动作的 DTW 距离，用最相似参考动作推断所执行的技能；若技能与该障碍期望的参考技能一致，则记为正确。跟踪误差则是生成动作与该障碍对应真实参考动作之间的 DTW 距离。

任务性能用平均任务完成率衡量：角色是否成功穿越随机五障碍序列并到达终点。为了测试场景变化鲁棒性，评估时对障碍位置和朝向加入 $N(0,0.03)$ 噪声，对障碍尺度加入 $N(1,0.03)$ 噪声。

朝向任务报告方向得分和面朝得分，均为相应单位向量之间的余弦相似度，并报告平均评估回报。

表 1：未知噪声场景下的定量结果

方法	技能准确率 ↑	跟踪误差 ↓	任务完成率 ↑
Task Reward	0.00	1.82	0.81
AMP	0.06	1.49	0.11
ASE	0.03	1.63	0.00
MaskedMimic	0.50	0.41	0.00

方法	技能准确率 ↑	跟踪误差 ↓	任务完成率 ↑
Task Reward w/ ws	0.15	0.54	0.86
AMP w/ ws	0.54	0.37	0.85
HIL (本文)	0.66	0.31	0.74

表 2：消融实验

方法	技能准确率 ↑	跟踪误差 ↓	任务完成率 ↑
去掉判别器 D	0.53	0.36	0.62
去掉 PSI	0.50	0.37	0.52
判别器无场景信息	0.38	0.39	0.75
critic 无任务指示 k	0.52	0.40	0.73
完整 HIL	0.66	0.31	0.74

8 跑酷实验结果

HIL 在自然性和任务性能之间取得最佳平衡：技能准确率最高（0.66），跟踪误差最低（0.31），同时保持较强任务完成率（0.74）。这些结果来自带位置、朝向和尺度扰动的程序化障碍序列，说明 HIL 能把参考技能适配到未见过的障碍配置。但当扰动很大、障碍配置与训练分布差异显著时仍可能失败。

仅任务奖励的基线可以获得很高完成率，却会利用异常策略。没有 warm start 时，角色常躺在地面“爬过”障碍；有 warm start 后动作更协调，但仍可能无视场景可供性，以不自然方式快速穿越。原因之一是仿真 SMPL 人体并不完全真实，执行器能力过强；纯任务优化策略还会利用仿真简化和漏洞。

AMP 的完成率只有 0.11。角色往往走到障碍前停留，最终尝试绕行。加入 warm start 后完成率升到 0.85，动作也更自然，但策略只使用很窄的技能集合，无论障碍类型如何都反复使用相同翻越动作，表现出严重模式坍塌。

ASE 仅依赖判别器奖励，没有任务引导，因此无法产生有意义的障碍交互，常停在障碍前，完成率为 0。它在平地运动中有效，但动态跑酷场景需要明确任务信号。

MaskedMimic 完成率同样为 0。其教师和学生都只在参考序列条件下训练，面对连续技能过渡等新条件时无法适应，常在完成第一个障碍后摔倒。即使额外做第三阶段微调，其本质也类似 warm-start 基线，而实验表明，仅从预训练跟踪策略出发再做任务微调不足以保持自然性和技能多样性。

HIL 在适应训练过程中持续保留动作跟踪，使跟踪目标始终充当正则化信号。目标条件观测允许在不输入目标姿态的情况下训练跟踪策略，并为 AMP、Task Reward 等基线提供更好初始化；但完整优势来自在统一观测空间内联合训练动作跟踪和对抗式模仿。

8.1 消融实验

去掉判别器后，控制器仍同时训练跟踪与任务模式，但没有风格奖励，技能准确率和任务完成率显著下降。判别器帮助为不同障碍选择合适技能，也提供促进多任务协同的共享奖励信号。没有它，两类任务更像各自独立优化，任务模式难以产生自然有效的行为。

去掉 PSI 后，所有指标明显下降。PSI 通过训练策略处理偏离参考的初始状态，提高恢复能力和连续技能组合能力。一个动作结束状态通常不等于下一动作的理想初始状态，PSI 可使策略容忍这种差异。它还能缓解模式坍塌：当复杂技能转换难学时，策略倾向只执行简单技能；PSI 降低了过渡学习难度，从而扩大技能使用范围。

从判别器中移除场景信息后，任务完成率变化不大，但技能准确率和跟踪误差变差。没有场景上下文，判别器只判断动作孤立地看是否自然，无法判断动作是否适合当前障碍，因此会奖励“动作自然但场景不匹配”的交互。

去掉 critic 的任务指示 k 后，性能下降。两种模式奖励结构不同，critic 若不知道当前样本属于哪种模式，就难以准确估计价值。作者观察到去掉 k 后 critic 损失增大约 5 倍。

8.2 多样性、鲁棒性与通用性

图 3 展示了控制器用多种跑酷技能与不同障碍交互。图 9 表明，同一种技能可根据障碍尺寸、位置和朝向变化进行调整。


图 7 通过逐渐增加障碍噪声评估鲁棒性。位置和朝向加入 $N(0, \sigma)$ ，尺度加入 $N(1, \sigma)$ 。当 $\sigma=0.05$ 时，任务完成率仍超过 70%；当 $\sigma=0.1$ 时仍超过 50%。

图 8 测试更长序列泛化。虽然训练只使用五障碍序列且无扰动，模型在 $\sigma=0.03$ 的二十障碍序列上仍有约 40% 完成率。

为了验证超出跑酷领域的通用性，作者把跑酷数据与 SAMP 数据集中的坐下动作结合，训练策略连续完成动态跑酷并最终坐到椅子上。椅子几何也比简单箱体障碍复杂，说明框架可以融合不同动作域和交互类型。

9 朝向控制结果

12 • Jiashun Wang, Yifeng Jiang, Haotian Zhang, Chen Tessler, Davis Rempe, Je



原论文图 11：使用任务条件而非未来目标姿态，仍可学习有效跟踪。

为验证任务条件是否足以支持动作跟踪，作者比较了两种跟踪器：标准姿态条件跟踪器输入未来目标姿态；任务条件跟踪器只输入从参考动作导出的目标行进方向和面朝方向。

图 11 报告训练中的跟踪成功率，成功定义为策略未触发提前终止并跟踪到参考动作结束。任务条件跟踪器学习更慢，最终成功率略低于姿态条件跟踪器，但整体仍很接近。这说明只用任务层条件也能支持参考引导跟踪，并能自然扩展到随机目标条件分布，形成从参考动作跟踪到一般目标驱动控制的统一端到端框架。

在朝向任务中，角色需要同时让速度对齐目标行进方向，并让身体朝向对齐目标面朝方向。ASE 的技能嵌入有助于保留自然动作，但任务表现较弱；AMP 的平均回报更高，但动作常不够自然；两者都只使用参考数据中的有限行为子集。MaskedMimic 无法泛化到新方向目标，角色很快失衡摔倒。

朝向任务使用更大规模的运动与战斗数据。HIL 能利用更广的参考分布，表现出前进、后退、转向和挥剑等多种行为模式来满足方向目标，表明该框架可以扩展到更大的动作数据集。

表 3：朝向任务定量结果

方法	方向得分 ↑	面朝得分 ↑	平均评估回报 ↑
AMP	0.95	0.94	266
ASE	0.54	0.78	147
MaskedMimic	0.79	0.72	17
HIL（本文）	0.94	0.97	227

10 讨论与局限

本文提出一种简单有效的动态运动控制混合模仿学习框架，将动作跟踪与对抗式模仿结合。为提高训练效率，作者设计了并行多任务环境、统一目标条件观测空间和扰动状态初始化。方法能够生成高质量动作，使用多样技能，并取得有竞争力的任务性能。

仍有若干局限。生成动作总体忠实，但角色被障碍绊倒时偶尔出现不自然恢复动作。当前跑酷场景由顺序排列的简单箱体构成，限制了对复杂、非线性场景和更丰富交互模式的泛化。尽管策略和判别器都使用点云场景上下文，能学到的交互多样性仍受参考数据限制。

朝向任务初步证明 HIL 能扩展到更大动作数据集。更多动作覆盖可提升自然性和行为多样性。但跑酷扩展更难，因为数据不仅要包含动作，还必须包含对应场景几何和交互可供性。当前动作—场景对通过人工简化标注构建，大规模收集成本高。未来可以借助三维重建和人体动作估计，从视频自动收集配对数据，减少人工标注，并扩展到非顺序布局和复杂几何。

HIL 不限于跑酷和朝向控制。它适合需要无缝技能组合并适应新环境的目标条件交互任务。与依赖时间相位或目标姿态的传统跟踪不同，HIL 统一使用角色状态、任务目标和场景几何。对本文任务而言，这些空间和任务约束足以保证行为连贯推进，同时保留对无参考轨迹新环境的适应能力。

该框架还可能扩展到室内交互、多人协作等更复杂环境。向真实人形机器人迁移也是有前景的方向，但需要解决仿真到现实迁移、感知驱动全身控制，以及对真实动力学和传感噪声的鲁棒性问题。

附录 A 修订说明

修订版把论文范围从跑酷特定技能学习扩展为更一般的动态运动控制框架，并增加朝向控制任务。作者引入统一的目标条件观测空间以连接动作跟踪与对抗式模仿学习，加入更完整基线，包括 Task Reward、AMP、ASE、MaskedMimic 及 Task Reward/AMP 的 warm-start 版本；同时重组任务章节、完善数据集构建和实现细节。

附录 B 控制器表示

B.1 点云表示与体素表示比较

障碍主要为箱体。作者在每个物体表面均匀采样 15 个点，使用 $N=60$ 个点作为输入，因此点云维度为 180。

作者也测试了 $10 \times 10 \times 10$ 、每个体素边长 20 cm 的体素网格，但表现较差，甚至动作跟踪都难以复现全部参考动作。体素表示存在感知范围与空间分辨率的矛盾：较细体素能描述细节，却会导致维度和显存需求急剧增加；20 cm 体素的 1000 维表示只能覆盖 $2 \text{ m} \times 2 \text{ m} \times 2 \text{ m}$ 范围，对跑酷远处障碍不足。

跑酷中的物体主要提供交互表面，而非需要精细识别的复杂几何，因此点云表示更高效，也已在 3D Diffusion Policy、DexPoint 等控制模型中广泛使用。

B.2 判别器观测

判别器同时输入角色状态与距离根节点最近的 N 个场景点，用于评价动作在周围环境中的自然性。为提供足够时间信息，状态转移由过去 10 步组成。每一步包括：

- 局部坐标系下根节点线速度和角速度；
- 各关节局部旋转；
- 各关节局部速度；
- 手、脚等末端执行器的局部三维位置；
- 距离根节点最近的 N 个场景点。

连续 10 步特征拼接为判别器输入，使其能够评价动作动态、流畅性以及场景的对齐关系。朝向任务中不使用点云。

B.3 动作与 PD 控制

每个自由度由 PD 控制器驱动。第 i 个关节的动作 $a_{t,i}$ 表示期望关节位置，力矩计算为：

$$\tau_i = k_p(a_{t,i}-q_{t,i}) - k_d \dot{q}_{t,i}$$

式意：q 与 $\dot{q}$ 分别为关节位置和速度；策略输出期望关节位置，而不是直接输出力矩。

策略动作分布为固定协方差的多维高斯分布，每个动作维度标准差均为 0.055。

附录 C 训练与评估细节

C.1 超参数

项目	设定
折扣因子 γ	0.99
GAE 参数	0.95
策略学习率	2×10^{-5}
critic 学习率	1×10^{-4}
判别器学习率	1×10^{-4}
并行环境数	4096
单回合长度	400 步
GPU	4×NVIDIA V100
每张 GPU 更新 batch	4096

跑酷目标推进奖励中，作者把“前一步到目标距离减去当前距离”截断在 [0,0.05]，避免控制器为了尽快完成任务而产生极端不自然动作。

$$w_{\text{vel}}=0.7, w_{\text{face}}=0.3, \alpha=0.25, v^*=1.2 \quad (7)$$

式意：朝向任务奖励超参数。

$$w_p=2.5, w_r=1.5, w_v=0.5, w_\omega=0.5, w_h=1, w_e=0.001; \alpha_p=1.5, \alpha_r=0.3, \alpha_v=0.12, \\ \alpha_\omega=0.05, \alpha_h=20 \quad (8)$$

式意：动作跟踪奖励的权重和指数尺度。

跟踪/任务奖励与风格奖励的总权重都设为 0.5。Transformer 潜在维度为 256，前馈层为 512，包含 2 层和 2 个自注意力头。角色状态与目标位置编码器为隐藏层 [512,256] 的 MLP；PointNet 为共享 MLP [512,256]；critic 和判别器为 [1024,512] 的 MLP；所有隐藏层使用 ReLU。

C.2 障碍生成

训练时直接从参考数据采样障碍，每条路线由五个障碍组成。相邻障碍间距为 2~3 米，相对朝向随机采样于 $-20^\circ \sim 20^\circ$ 。训练时不加入扰动，评估时再加入不同噪声测试鲁棒性。

C.3 动态时间规整 (DTW)

DTW 用于衡量两条时间序列在时序不对齐或速度不同情况下的相似度。参考动作 A 与生成动作 B 分别表示为特征序列 $a=[a_1, \dots, a_T]$ 与 $b=[b_1, \dots, b_{T'}]$ 。

首先构造代价矩阵 C，其中 $C(i,j)$ 是 a_i 与 b_j 的欧氏距离；随后寻找满足边界条件、连续性和时间单调性的最优规整路径 W，使累计代价最小。该累计代价就是两条动作的 DTW 距离。本文使用与判别器角色状态描述相同的动作特征，并将 DTW 距离除以 1000 后作为报告的跟踪误差。

由于生成动作连续穿越多个障碍，必须先把长序列切分为各障碍对应的子动作。作者比较生成根轨迹与参考根轨迹，以生成动作中最接近参考片段首帧和末帧根位置的时刻确定子片段边界，从而把每段交互与相应参考动作对齐。

参考文献说明

论文第 13~14 页为完整参考文献列表。书目信息、作者姓名和论文标题通常按原文保留，因此本译文未逐条翻译全部文献条目；正文中的引用编号和作者年份含义均保持不变。

第三部分 方法框架与图 2 逐模块详细讲解

1. HIL 不是“先跟踪、再完全切换到任务训练”

最容易误解的地方，是把 HIL 看成普通 warm start：先训练一个动作跟踪策略，再关掉跟踪奖励，只做任务微调。论文通过 AMP w/ warm start 和 Task Reward w/ warm start 证明，这种做法会分别导致模式坍塌或动作不自然。HIL 的关键在于第二阶段仍然保留动作跟踪环境，使参考动作约束在适应训练全过程中持续存在。

核心训练结构

阶段 1：只训练动作跟踪，先让策略掌握各个单项技能。阶段 2：一半环境继续动作跟踪，另一半环境进行任务+风格训练；两个环境池共享同一个 policy 和同一个判别器。

2. 图 2 的三条网络支路




图 2 原图。上方为 policy，左下为 critic，右下为 discriminator。

模块	输入	输出	为什么这样设计
Policy	角色状态 s_t 、场景点云 c_t 、目标位置 l_t	高斯动作分布的 μ_t 、 σ_t	策略必须在部署时可用，因此只接收可观测信息；不输入训练模式 k ，保证同一行为接口。
Critic	s_t 、 c_t 、 l_t ，加任务指示 k_t	状态价值 V_t	两种模式奖励尺度和语义不同， k_t 帮助价值函数区分“跟踪回报”和“任务/风格回报”。

模块	输入	输出	为什么这样设计
Discriminator	过去 n 步状态 $s_{[t-n:t]}$ 与 场景 $c_{[t-n:t]}$	真实/伪造判别 D_t	10 步历史用于看动态流畅性；场景输入用于判断动作是否与障碍匹配。

3. Policy：多模态 token 融合

1. 角色状态 s_t 经过 MLP，得到角色状态 token。
2. 场景点云 c_t 的每个点经共享 PointNet/MLP 编码，得到 N 个场景 token。
3. 目标位置 l_t 经 MLP 编码为目标 token。
4. 所有 token 输入 Transformer Encoder，通过自注意力学习“当前身体状态—障碍几何—目标位置”之间的关系。
5. Transformer 输出动作分布参数。策略均值由网络预测，探索噪声标准差固定为 0.055。

Transformer 的必要性在于：障碍点云不是固定语义向量，不同点与不同身体部位、目标方向之间存在动态关系。自注意力可以根据当前状态选择重要场景点，例如起跳前关注障碍前缘、腾空阶段关注落地点。

4. 统一目标条件如何替代相位与未来姿态

传统跟踪输入未来姿态，相当于直接告诉策略“下一帧身体应该长什么样”；HIL 则只告诉策略“你当前在哪里、周围障碍怎样、接下来要去哪里”。在参考场景中，这些空间约束往往足以唯一或近似唯一地决定动作进度。

- 例如翻越一个固定障碍时，角色相对障碍的位置、根速度和目标点共同隐含“助跑—起跳—支撑—越过—落地”的阶段。
- 动作跟踪模式的目标点来自参考轨迹未来 1~2 秒，因此目标条件与参考动作进度稳定对应。
- 对抗模式使用同样形式的目标点，只是加入噪声并适配新障碍，因此策略不需要切换输入格式。

为什么这是论文最关键的桥梁

如果跟踪模式输入目标姿态，而任务模式只输入目标位置，那么 policy 很容易学成两套内部子策略，知识难以共享；统一观测把两种模式压到同一条件空间，使“参考技能”能够迁移为“场景适应技能”。

5. Critic 为什么需要 k ，而 Policy 不需要

Policy 的任务是根据同一种可观测条件输出动作，因此不应知道自己处在跟踪环境还是对抗环境，否则可能学会模式切换而不是行为统一。Critic 只在训练时估计回报，它面对两套不同奖励定义：跟踪模式主要由姿态/速度误差决定，对抗模式主要由目标推进和判别器风格决定。

若 critic 不知道模式，同一个近似状态可能对应完全不同的未来回报分布，价值估计会产生冲突，导致优势估计噪声增大。任务指示 k 相当于给价值函数增加一个“奖励语义标签”。该信息是训练特权信息，不进入部署策略。

6. 判别器为什么必须看场景

普通 AMP 判别器只看人体运动，它只能说“这个动作像不像人”，不能说“这个动作是否适合眼前障碍”。例如，一个漂亮的侧手翻在空地上很自然，但面对低矮平台时可能不是正确交互。HIL 把点云加入判别器，使风格奖励变成条件风格奖励：自然性与场景适配性同时被评价。

消融结果验证了这一点：去掉场景信息后任务完成率仍为 0.75，但技能准确率从 0.66 降到 0.38。说明任务奖励仍能让角色通过障碍，但所选技能与障碍类型明显不匹配。

7. 奖励如何在两种模式间形成耦合

训练模式	主要奖励	共同奖励	作用
动作跟踪环境	位置、旋转、速度、根高度、能耗	场景条件风格奖励	持续固定技能质量和数据覆盖，防止适应训练遗忘复杂动作。
对抗任务环境	目标推进/到达，或方向/朝向奖励	场景条件风格奖励	允许偏离逐帧参考，以完成新场景任务，同时保持自然性与技能选择。

风格奖励同时出现在两种模式，是连接两类梯度的重要纽带。动作跟踪环境提供“高质量、覆盖广”的状态分布；任务环境提供“适应新场景”的状态分布；判别器把两者映射到共同的动作自然性与场景适配目标。

8. PSI 是技能组合的关键，而不只是普通域随机化

PSI 表面上是初始状态加噪声，但其更深层作用是扩大每个技能的“可进入状态集合”。纯 RSI 训练出的技能可能只在非常窄的起始状态附近有效；一旦前一技能结束状态略有偏差，下一技能就无法启动。PSI 让策略学会从周围状态收敛回技能流形，因此技能之间更容易拼接。

- 提高扰动恢复能力；
- 扩大技能入口区域；
- 降低复杂技能过渡的学习难度；
- 减少强化学习退化为少数简单通用动作的倾向。

9. 训练数据管线

1. 从在线视频收集跑酷片段。
2. 用 TRAM 从单目视频估计 SMPL 人体运动。

3. 用身体上方向提示修正地面和全局姿态。
4. 人工用简单箱体标注交互场景。
5. 用物理动作跟踪器清理穿透、抖动和滑移，得到物理一致参考动作。
6. 把高质量动作同时用于跟踪奖励、PSI 初始状态采样和判别器真实样本。

该流程说明 HIL 并不能完全摆脱高质量参考数据。判别器和跟踪器共享同一数据源，一旦参考动作包含脚滑、穿透或接触错误，这些缺陷会同时污染两种训练信号。

10. 完整训练流程

1. 构建动作—场景配对数据和角色动力学模型。
2. 阶段 1 在 4096 并行环境中训练目标条件动作跟踪策略，共 40 亿样本。
3. 阶段 2 把环境平均分成跟踪组与对抗任务组，共再训练 20 亿样本。
4. 每次 rollout 中，同一 policy 在两类环境采样动作；critic 根据 k 分别估值。
5. 判别器从参考动作历史和策略生成历史中学习条件分类。
6. 根据任务奖励、跟踪奖励和风格奖励计算 PPO 优势并更新统一 policy。

第四部分 主要公式、奖励函数与训练机制解析

1. 跟踪奖励的实际含义

项	约束对象	权重/尺度	对控制表现的影响
位置项	各关节局部位置	$w_p=2.5, \alpha_p=1.5$	保证人体整体构型和末端位置接近参考。
旋转项	各关节局部旋转差	$w_r=1.5, \alpha_r=0.3$	约束姿态形状，避免只靠位置凑动作。
线速度项	关节线速度	$w_v=0.5, \alpha_v=0.12$	保持动作速度与节奏，减少慢动作或过冲。
角速度项	关节角速度	$w_\omega=0.5, \alpha_\omega=0.05$	保持旋转动态，尤其影响翻滚、腾空和挥臂。
根高度项	骨盆离地高度	$w_h=1, \alpha_h=20$	指数非常敏感，强约束蹲起、腾空和落地高度。
能耗项	$\sum \tau_j \dot{q}_j $	$w_e=0.001$	惩罚机械功率，抑制高频抖动和无效关节调整。

注意原式最后一项在排版上写为“+ $w_e \sum ||\tau_j \dot{q}_j||$ ”，但文字称其为能量惩罚。实现中通常应以负号加入总奖励，或把 w_e 设为负值；复现代码时必须核对实际符号。

2. 为什么指数奖励常用于模仿学习

指数形式 $e^{-\alpha e}$ 在误差较小时提供高奖励，在误差增大后快速衰减。它比简单负平方误差更容易把不同量纲奖励归一到 0~1 范围，并可通过 α 控制容忍区间。但 α 过大时奖励会很尖锐，策略一旦偏离参考就几乎得不到梯度，因此需要与 PSI、提前终止和分阶段训练配合。

3. 跑酷任务奖励只奖励“进展”，不直接指定技能

式（5）比较相邻两步到目标的距离差，只要角色向目标接近就获得奖励；到达目标再得到一次性奖励。它没有指定必须跳、翻、撑或侧翻。具体技能由参考跟踪和场景条件风格奖励共同塑造。

设计哲学

任务奖励定义“做成什么”，跟踪与判别器定义“应该怎样做”。如果任务奖励直接写死每个障碍的姿态轨迹，就会退化回缺乏适应性的动作跟踪。

4. 朝向奖励可同时控制运动方向与身体朝向

行进方向 $\hat{d}$ 和面朝方向 $\hat{f}$ 可以不同，例如角色向后退但仍面向对手。速度项只约束根速度在 $\hat{d}$ 方向上的投影，面朝项约束身体正向与 $\hat{f}$ 的余弦，因此能够表达前进、后退、横移、转身和边移动边面向目标等行为。

5. 判别器损失与风格奖励

判别器学习二分类：参考动作历史为正样本，策略动作历史为负样本。策略得到 $-\log(1-D)$ 奖励；当判别器认为策略动作像参考动作且适合场景时， D 增大，风格奖励也增大。梯度惩罚限制判别器对输入变化过于敏感，改善对抗训练稳定性。

6. 为什么任务奖励与风格奖励各占 0.5 不代表同等实际贡献

不同奖励的数值范围、方差和稀疏程度不同。即使总权重都为 0.5，实际梯度贡献也可能差异很大。复现时需要记录每项奖励均值、标准差、优势相关性和梯度范数，而不能只比较配置中的系数。

7. 训练规模与优化难度

- 总训练样本约 60 亿步，其中 40 亿用于单独跟踪预训练，20 亿用于混合训练。
- 仿真 120 Hz、策略 30 Hz，意味着每个策略动作保持约 4 个物理子步。
- 策略学习率 2×10^{-5} ，明显小于 critic 和判别器的 1×10^{-4} ，说明作者在混合训练中非常谨慎地更新策略，避免破坏已学动作。
- 4096 环境与四 GPU 表明该方法训练成本较高，尤其判别器还要处理 10 步历史与点云。

第五部分 方法评价、复现要点与对 BUMI3 舞蹈控制的启示

1. 方法的真正创新点

- 不是简单把 Motion Tracking 与 AMP 奖励相加，而是建立两类并行环境并共享策略。
- 用目标条件替代跟踪专属的相位/目标姿态，使两种模式具备同构输入。
- 让判别器看场景，使其从“动作自然性判别器”升级为“动作—场景匹配判别器”。
- 用 PSI 扩大技能可进入状态集合，从优化层面解决技能组合和模式坍塌。
- critic 使用任务指示，解决混合奖励语义下的价值估计冲突。

2. 方法局限与需要谨慎理解的结果

- HIL 的任务完成率 0.74 低于两个 warm-start 基线的 0.85/0.86，论文优势是自然性和技能多样性的综合平衡，而不是单纯最高通关率。
- 跑酷数据只有 19 个片段、30 秒、15 种技能，技能规模仍较小；强结果部分依赖精心配对的场景与物理清理数据。
- 训练时没有障碍扰动，但评估时加入噪声，泛化主要来自统一条件表示、任务训练和 PSI；对更复杂拓扑和非箱体环境尚未充分验证。
- 仿真 SMPL 人体执行器过强，策略可能利用非真实动力学；直接迁移人形机器人需要严格的力矩、接触、关节速度和安全限制。
- 判别器训练可能不稳定，且风格奖励容易被策略利用；需要监控判别准确率、真实/伪样本分数和奖励饱和。

3. 复现时最容易遗漏的实现细节

1. 两阶段样本量差异很大：先 40 亿跟踪，再 20 亿混合，而不是从头同时训练。
2. 混合阶段环境比例为 1:1。
3. 动作跟踪模式也包含 style reward。
4. 判别器输入 10 步历史，且跑酷任务必须包含场景点云。
5. critic 接收任务指示 k，policy 不接收。
6. 目标推进差值被截断到 $[0, 0.05]$ 。
7. 动作是 PD 目标关节位置，固定动作标准差 0.055。
8. 训练障碍不加噪声，评估才加噪声。
9. 高质量物理优化参考动作同时用于跟踪、PSI 与判别器正样本。

4. 对你当前 BUMI3 舞蹈任务的直接启示

你当前的的问题包括落地重、脚底小动作多、动作不够稳、跨机台差异、简单动作不抬腿等。HIL 的思想可以改造成“精确舞蹈跟踪 + 鲁棒稳定/恢复”双模式训练，而不必照搬跑酷点云。

HIL 元素	在 BUMI3 舞蹈中的对应设计	可能改善的问题
动作跟踪模式	继续使用当前 reference motion tracking, 保持关节、末端、根姿态、速度等模仿奖励。	保证舞蹈内容、抬腿幅度和节奏不被稳定性优化抹掉。
对抗/任务模式	构建不要求逐帧严格跟踪的稳定任务: 目标根速度/朝向、COM 支撑裕度、足底接触、落地后稳定、扰动恢复。	减轻落地后持续小调整, 增强偏差恢复与实机适应。
统一观测	两种模式都输入本体状态、参考的低维目标条件, 如根速度、面朝、期望接触脚、关键末端目标。	避免一个模式依赖完整未来姿态、另一个模式完全无参考造成输入断裂。
critic 任务指示	critic 增加 tracking/stability 二值或多类 mode id, policy 不输入。	降低混合奖励导致的 value loss 冲突。
PSI	对根姿态、根速度、关节状态和落地接触状态加入小扰动, 并从动作片段中段初始化。	提高跨机台与落地偏差恢复, 减少失败后乱调脚。
能耗/平滑项	使用机械功率、关节加速度、动作差分、足端滑移与接触切换惩罚。	直接抑制脚底高频小动作和落地后的震荡。

5. 建议的 BUMI3-HIL 训练结构

1. 阶段 A: 用现有舞蹈跟踪任务训练到动作覆盖稳定, 保留你当前表现较好的 checkpoint。
2. 阶段 B: 并行分配环境, 例如 60% 精确跟踪、40% 鲁棒稳定模式; 初期不要直接 50/50, 可逐步增加稳定模式比例。
3. 跟踪环境: 保持完整参考跟踪, 同时加入轻量能耗、足端滑移和落地冲击约束。
4. 稳定环境: 参考目标只保留低维任务条件, 如期望根速度、朝向、根高度、接触计划和关键末端位置, 允许关节轨迹偏离以恢复平衡。
5. critic 输入 mode id; policy 不输入 mode id, 但两类环境必须使用同维度观测, 缺失目标用合理掩码而不是换网络。
6. 使用 PSI 对落地前后状态重点扰动, 并对仿真动力学、延迟、关节阻尼、摩擦和足底接触参数做域随机化。
7. 若加入判别器, 先只判别本体运动和接触历史, 再考虑加入参考条件; 机器人任务中判别器不应奖励人类不可能由机器人安全实现的动作。

6. 针对脚底小动作与前倾问题, HIL 不能替代的底层检查

- 检查足底碰撞几何、接触点分布、摩擦、restitution、contact offset/rest offset 和 solver 参数; 若脚掌模型只在前缘接触, 任何上层奖励都可能学出前倾补偿。

- 检查机器人模型的质心、惯量、关节零位、PD 增益和 actuator armature；仿真根姿态稳定不代表实物动力学一致。
- 明确区分“动作参考本身前倾”和“策略为了抵消接触/力矩误差而前倾”。应记录参考与实际的 base pitch、足底 CoP、足端法向力分布和落地冲量。
- 落地冲击约束应与抬脚高度、腾空和跟踪奖励协同设计，过强会导致不抬腿，过弱会导致重落地。最好使用阶段条件或接触事件窗口，而不是全程统一惩罚。

最终判断

HIL 最适合解决“跟踪精确但适应性不足、技能过渡困难、稳定任务导致动作退化”的上层学习矛盾；如果前脚掌接触、足底小动作来自模型接触几何或实物参数偏差，则仍必须先修正资产模型和 sim-to-real 参数。

7. 建议你重点对照论文代码或未来复现的日志

- tracking env 与 task env 各自的 episode return、成功率、终止原因；
- style reward 在两种模式中的均值与分布；
- 判别器真实/伪样本输出和分类准确率，防止过强或饱和；
- critic 分 mode 的 value loss，验证 task indicator 是否有效；
- PSI 扰动幅度与技能成功率曲线；
- 每种技能使用频率，检测舞蹈策略是否只保留简单动作；
- 落地事件窗口内的足端冲量、滑移、base pitch、CoP 与动作差分。

结论

HIL 的核心贡献不是提出一个更复杂的网络，而是重新组织训练问题：用统一目标条件把参考动作跟踪和新场景任务适应放进同一个策略接口；用持续跟踪避免遗忘和模式坍塌；用场景条件判别器约束自然性与技能选择；用 PSI 扩大技能入口并改善衔接。对人形机器人舞蹈控制而言，这套思路最有价值的地方，是能够在不牺牲动作内容的前提下，增加落地恢复、扰动鲁棒性和跨机台适应能力。